

Universidade de São Paulo
Instituto de Física de São Carlos
Departamento de Física e Informática
Grupo de Física Computacional e Instrumentação Aplicada



VILSON VIEIRA

**Um Estudo Quantitativo sobre a Evolução de
Movimentos Artísticos**

São Carlos

2013

VILSON VIEIRA

Um Estudo Quantitativo sobre a Evolução de Movimentos Artísticos

Dissertação apresentada ao Programa de Pós-graduação em Física do Instituto de Física de São Carlos da Universidade de São Paulo, para a obtenção do título de Mestre em Ciências.

Área de Concentração: Física Aplicada

Orientador: Prof. Dr. Gonzalo Travieso

 Colaborador: Prof. Dr. Luciano da Fontoura Costa

Versão Corrigida

(versão original disponível na Unidade que aloja o Programa)

São Carlos

2013

AUTORIZO A REPRODUÇÃO E DIVULGAÇÃO TOTAL OU PARCIAL DESTE
TRABALHO, POR QUALQUER MEIO CONVENCIONAL OU ELETRÔNICO,
PARA FINS DE ESTUDO E PESQUISA, DESDE QUE CITADA A FONTE.

AGRADECIMENTOS

Sinceros agradecimentos ao Prof. Gonzalo Travieso e ao Prof. Luciano da Fontoura Costa. Tenham certeza que foi com vocês que aprendi o que é fazer pesquisa. Foram ensinamentos que guardarei para toda a vida. Além da orientação de excelência, ficará para sempre a amizade.

Aos meus queridos pais, sabem que devo tudo o que sou a vocês. Encontro sempre suas palavras de conforto e sabedoria em cada esquina que cruzo, em cada caminho que percorro. Amo muito vocês.

À minha amada, Gabriela, que esteve ao meu lado em cada momento, bom ou ruim, por seu amparo e cumplicidade.

Aos meus irmãos Renato e Ricardo Fabbri, que me acolhem com tanto carinho e com quem espero viver ainda ótimas passagens.

Ao bom amigo e conselheiro Pedro Kroeger, continuas sendo quem sigo os passos.

A todos do labMacambira.sf.net, por todas as colaborações e aprendizados, seja artisticamente, cientificamente, socialmente, em *software*, em *tinta*, em *notas* ou em espírito.

À Mozilla Foundation e seus colaboradores, em especial Forrest Oliphant, que me mentorou enquanto participante do Googler Summer of Code 2012.

A todos os amigos que fiz no IFSC/USP, em especial Carlos Doro Neto (valeu pelo *Doro's method!*), David Sbrissa (*bit*****!*), prof. Osvaldo “Chu”, prof. Rodrigo Guido, Débora Correa, Mauro Miazaki, Diego, César, Thomás. Aos parceiros do *hacklab do velho*, grande carinho.

Não sei se conseguirei lembrar de todos, mas meu especial agradecimento a Daniel Penalva, Caleb Luporini, Guilherme Lunhani, Geraldo Magela Rocha, Glerm Soares, Chico e Fábio Simões, Daniel Marostegan, Rogério “Zeco” Silva, Gilson Beck, Marcos Mendonça, Danilo Shiga, Edson Corrêa, Vanessa Ferreira, Luis Castelões, Luis Fernando Muniz Cirne, Marília Pisani, Massimo Canevacci. À Teia Casa de Criação e Pontão Nós Digitais, ao MuSA, aos amigos da Udesc, a todos que tive contato real e virtualmente, nas listas de email, AA, IRC e outras redes.

Agradeço às comunidades de cultura e software livre por todos os conhecimentos e tecnologias repassados e que compõem esta contribuição.

“Art is made to disturb. Science reassures. There is only one valuable thing in art: the thing you cannot explain.”

— GEORGES BRAQUE

“Science is what we understand well enough to explain to a computer, art is everything else.”

— DONALD KNUTH

“Todos querem entender de arte. Por que não tentam entender o canto de um pássaro?”

— PABLO PICASSO

RESUMO

VIEIRA, V. **Um Estudo Quantitativo sobre a Evolução de Movimentos Artísticos.** 2013. 253p. Dissertação (Mestrado) - Instituto de Física de São Carlos, Universidade de São Paulo, São Carlos, 2013.

Enquanto muitos estudos são feitos para a análise e classificação de pinturas e outros ramos das Artes, este estudo não se detém somente à classificação. Extende-se aqui um método de análise já aplicado à Música e Filosofia, representando a evolução da Arte como uma série temporal onde relações como *oposição*, *inovação* e *dialética* são medidas quantitativamente. Para isso, um *corpus* de pinturas de 12 artistas reconhecidos dos movimentos Barroco e Moderno foram analisadas. Um conjunto de 93 atributos foi extraído e os atributos que mais contribuíram para a classificação das pinturas foram selecionados. O espaço de projeção obtido a partir desses atributos criou a base para a análise de medidas. Essas medidas quantitativas revelaram observações sobre a evolução dos estilos artísticos, mesmo quando comparados com outros campos das Artes já analisados. Enquanto a Música evoluiu guiada pela tradição mestre-aprendiz (alta dialética) e a Filosofia pela oposição, o Pintura apresenta um outro padrão: aumento constante da inovação, baixa oposição entre membros do mesmo movimento artístico e picos de oposição no momento de transição entre os movimentos. Uma diferença entre os movimentos Barroco e Moderno foi também percebido no espaço projetado: enquanto as pinturas Barrocas aparecem formando um agrupamento sobreposto, as pinturas Modernas apresentam quase nenhuma sobreposição e estão dispostas espalhadas ao longo da projeção, mais que as Barrocas. Essa observação encontra base na história da Arte onde os pintores Barrocos compartilham características estéticas de suas pinturas, enquanto os Modernos tendem a desenvolver seus próprios estilos e, por conseguinte, suas próprias estéticas.

Palavras-chave: Reconhecimento de padrões. Arte. Pintura. Extração de atributos. Criatividade. Arte e tecnologia.

ABSTRACT

VIEIRA, V. **A Quantitative Study about Artistic Movements Evolution.** 2013. 253p. Dissertação (Mestrado) - Instituto de Física de São Carlos, Universidade de São Paulo, São Carlos, 2013.

While many studies were performed for the analysis and classification of paintings and other Art venues, this study does not stop in the classification step. It extends an analysis method already applied to Music and Philosophy, representing the evolution of Art as a time-series where relations like *opposition*, *skewness* and *dialectics* were measured quantitatively. For that, a corpus of paintings of 12 well-known artists from Baroque and Modern Art was analyzed. A set of 93 features was extracted and the features which most contributed to the classification of painters were selected. The projection space obtained from the features provided the basis to the analysis of measurements. This quantitative measures underlie revealing observations about the evolution of Art styles, even when compared with other humanity fields already analyzed. While Music evolved guided by a master-apprentice tradition (high dialectics) and Philosophy by opposition, Painting presents another pattern: constant increasing skewness, low opposition between members of the same movement and opposition peaks in the transition between movements. A difference between Baroque and Modern movements are also observed in the projected “creative space”: while Baroque paintings are presented as an overlapped cluster, the Modern paintings presents minor overlapping and are disposed more scattered in the projection than Baroques. This finds basis in Arts history where Baroque painters were guided by traditional rules while Modern painters tended to “break” these rules and develop their own style.

Keywords: Pattern recognition. Arts. Painting. Feature extraction. Creativity. Arts and technology.

LISTA DE FIGURAS E TABELAS

Figura 1.1 -	Retratação de um dos experimentos de Brunelleschi que permitiu-lhe (re)descobrir a técnica de representação de profundidade pela perspectiva, onde todas as linhas de um objeto convergem a um só ponto. (1)	23
Figura 2.1 -	<i>Judite e Holoferne</i> , c. 1599	30
Figura 2.2 -	<i>Retrato de Isaak Abrahamsz Massa</i> , c. 1626	31
Figura 2.3 -	<i>Uma Dança para a Música do Tempo</i> , c. 1634-1635	32
Figura 2.4 -	<i>Velha Fritando Ovos</i> , c. 1618	32
Figura 2.5 -	<i>A Tempestade no Mar da Galiléia</i> , c. 1633	33
Figura 2.6 -	<i>A Garota com Brinco de Pérola</i> , c. 1665	33
Figura 2.7 -	<i>Quarto em Arles</i> , c. 1889	35
Figura 2.8 -	<i>Em Branco</i> , c. 1923	36
Figura 2.9 -	<i>A mesa de jantar: harmonia em vermelho (quarto vermelho)</i> , c. 1908	36
Figura 2.10 -	<i>Violino</i> , c. 1911-12	37
Figura 2.11 -	<i>O Campo Cultivado</i> , c. 1923-24	38
Figura 2.12 -	<i>Ritmo de Outono</i> , c. 1950	38

Figura 2.13 -	Cálculo dos índices de oposição $W_{i,j}$ e inovação $s_{i,j}$ dados dois estados consecutivos \vec{v}_i e \vec{v}_j	42
Figura 2.14 -	Cálculo da contra-dialética $d_{i \rightarrow k}$ dados os estados consecutivos de tese \vec{v}_i , antítese \vec{v}_j e síntese \vec{v}_k . Quanto maior o valor da distância $d_{i \rightarrow k}$ de \vec{v}_j à síntese ideal formada pela bissetriz $ML_{i,j}$ entre \vec{v}_i e \vec{v}_j , menor a dialética.	43
Figura 2.15 -	Etapas canônicas para processamento e análise de imagens. . . .	44
Figura 2.16 -	Coordenadas das vizinhanças-4 e 8 para um dado pixel p qualquer.	47
Tabela 2.17 -	Os 14 atributos de textura de Haralick, considerando: $p(i,j) = P_d(i,j)$, $p_x(i) = \sum_{j=1}^{N_g} p(i,j)$, $p_y(j) = \sum_{i=1}^{N_g} p(i,j)$, $p_{x+y}(k = i + j) = \sum_{i=1}^{N_g} \sum_{j=1}^{N_g} p(i,j)$, $p_{x-y}(k = i - j) = \sum_{i=1}^{N_g} \sum_{j=1}^{N_g} p(i,j)$. Ainda, $H(X)$ é a entropia de X e $\text{autoval}_2(X)$ é o segundo maior autovalor de X .	61
Figura 2.18 -	<i>a)</i> Imagina da pintura original. <i>b)</i> Uma região segmentada da pintura. <i>c)</i> A curvatura extraída a partir da região segmentada. <i>d)</i> A curva paramétrica $k(t)$ dado um limiar em particular, com os picos em destaque.	63
Tabela 3.1 -	Pintores escolhidos para a análise, exibidos em ordem cronológica, juntamente com o estilo artístico que melhor representa. Divididos em dois grupos: 6 pintores Barrocos e 6 pintores Modernos.	69
Tabela 3.2 -	Algumas das 240 pinturas juntamente com a data de sua criação. . . .	70

Figura 3.3 -	Experimentos realizados para segmentação de pinturas. <i>a</i>) a imagem original, <i>b</i>) segmentação por Watershed, <i>c</i>) Felzenswald, <i>d</i>) SLIC e <i>e</i>) SLIC com parâmetros X. O método SLIC foi escolhido por apresentar, visualmente, melhor separação dos segmentos, e os parâmetros escolhidos contribuíram para a segmentação apresentada.	72
Figura 3.4 -	Um sumário com todos os passos tomados, desde o processamento das imagens das pinturas até a extração de características, assim como a obtenção da série temporal onde foram calculadas as medidas de oposição, inovação e dialética.	73
Tabela 3.5 -	Pares de atributos $F_{N,a}$ e $F_{N,b}$ ordenados por α . Pares com valores maiores de α mostram maior dispersão inter-classe enquanto menor dispersão intra-classe (maior agrupamento). O melhor par de atributos: <i>μ dos picos de curvatura</i> e <i>μ do número de segmentos</i> são selecionados para a análise e cálculo das medidas.	74
Figura 3.6 -	Projeção do <i>espaço criativo</i> considerando o melhor par de atributos <i>μ de picos da curvatura</i> e <i>μ do número de segmentos</i>	75
Figura 3.7 -	Série temporal considerando o melhor par de atributos <i>μ de picos da curvatura</i> e <i>μ do número de segmentos</i>	76
Figura 3.8 -	Matrizes esparsas para cada i -ézimo par de atributos listado na Tabela 3.5 com os maiores valores para α . A primeira projeção (par 1) foi utilizado nesse estudo.	77

Figura 3.9 -	Histogramas dos níveis médios de cinza para todos os pintores barrocos. Vermeer e Velázquez mostram maior similaridade com Caravaggio do que os outros pintores barrocos: a proximidade em contraste encontra fundamento na história, tendo sido ambos pintores influenciados por Caravaggio.	79
Figura 3.10 -	Histogramas nos níveis médios de cinza para os pintores modernos. Há baixa similaridade entre os pintores modernos, diferente do que ocorre para os pintores barrocos.	80
Tabela 3.11 -	Índice de oposição $W_{i,j}$ e inovação $s_{i,j}$ para cada um dos 11 deslocamentos de um pintor a outro.	81
Tabela 3.13 -	Índices de contra-dialética para cada um dos 10 deslocamentos entre tese, antítese e síntese, considerando os dois melhores atributos.	81
Figura 3.12 -	Valores de oposição $W_{i,j}$ e inovação $s_{i,j}$ considerando os dois melhores atributos.	82
Figura 3.14 -	Valores de contra-dialética considerando os dois melhores atributos.	83
Figura 3.15 -	Série temporal resultante da projeção em 2 dimensões do <i>espaço criativo</i> considerando os dois primeiros componentes com maiores autovalores obtidos a partir da transformação LDA na matriz de $N = 93$ atributos.	84
Tabela 3.16 -	Índices de oposição e inovação para cada um dos 11 deslocamentos de um pintor ao outro.	85

Figura 3.17 -	Valores de oposição e inovação considerando a série temporal para todos os $N = 93$ atributos refletidos nos dois primeiros componentes obtidos pelo método LDA. Os mesmos padrões observados quando considerando os dois melhores atributos ainda permanecem nessa observação, como esperado.	86
Tabela 3.18 -	Índices de contra-dialética para cada um dos deslocamentos para os dois melhores componentes do LDA.	87
Figura 3.19 -	Contra-dialética (valores altos indicam baixa incidência de dialética) calculada para os componentes principais obtidos por LDA. O padrão observado anteriormente para o melhor par de atributos apresenta-se ainda mais visível aqui: é possível observar claramente que o maior valor está no ponto de transição dos movimentos artísticos (Van Gogh e Kandinsky).	88
Figura 3.20 -	Matriz de confusão para o método LDA. Metade das pinturas de cada artista é usado como conjunto de treino e a metade restante como conjunto de teste. Os elementos da diagonal principal mostram o número de amostras da classe esperada que correspondem com a classe obtida pelo método. Dada a grande quantidade de valores na diagonal principal, a validação sugere que o método LDA foi suficiente para a classificação das pinturas. Além disso, detalhes já observados nos resultados desse estudo são novamente observados na matriz: deslocamento de Van Gogh e similaridade entre pintores do mesmo movimento, principalmente Barroco.	89
Figura B.1 -	Caravaggio	101

Figura B.2 -	Frans Hals	102
Figura B.3 -	Nicolas Poussin	103
Figura B.4 -	Diego Velázquez	104
Figura B.5 -	Rembrandt Harmenszoon van Rijn	105
Figura B.6 -	Johannes Vermeer	106
Figura B.7 -	Vincent van Gogh	107
Figura B.8 -	Wassilly Kandinsky	108
Figura B.9 -	Henri Matisse	109
Figura B.10 -	Pablo Picasso	110
Figura B.11 -	Joan Miró	111
Figura B.12 -	Jackson Pollock	112
Figura C.1 -	Visualização alternativa das projeções das Figuras 3.6 e 3.7. É possível perceber detalhes de contraste e cor e sua influência no agrupamento e separação dos grupos de pintores.	114
Figura D.1 -	Fotos da exposição realizada no SIFISC 2013 com imagens geradas por algoritmo desenvolvido em paralelo a este estudo.	117

Sumário

1	Introdução	23
1.1	Motivação	27
1.2	Objetivos	27
1.3	Organização	28
2	Fundamentos	29
2.1	Uma breve exploração sobre o Barroco e Arte Moderna	29
2.1.1	Barroco	29
2.1.2	Arte Moderna	34
2.2	Conceitos em Filosofia	39
2.3	Processamento e análise de imagens	42
2.3.1	Conceitos úteis de Geometria Discreta e Morfologia Matemática	45
2.3.2	Pré-processamento	47
2.3.3	Segmentação	49
2.3.4	Pós-processamento	52
2.4	Extração de atributos	54

2.4.1	Atributos de complexidade	55
2.4.2	Atributos de textura	59
2.4.3	Atributos de contorno e forma	60
2.5	Redução de dimensionalidade e classificação	63
3	Desenvolvimentos e Resultados	68
3.1	Pintores escolhidos	68
3.2	Corpus de pinturas	68
3.3	Análise de imagens para extração de atributos	69
3.4	Seleção de atributos	71
3.5	Classificação e medidas de dialética, oposição e inovação	74
3.5.1	Análise por LDA de todos os atributos	82
4	Conclusões	90
REFERÊNCIAS		93
Apêndice A – Tutorial para execução dos <i>scripts Python</i> desenvolvidos para análise		98
Apêndice B – Galeria de imagens das 240 pinturas analisadas		100
Apêndice C – Visualizações complementares		113
Apêndice D – Pinturas generativas por tesselação de Delaunay. Estudo 4		115

1 *Introdução*

A arte, assim como a ciência ou filosofia, deseja compreender, entender, criar modelos que representem a natureza. Assim, acaba por querer resolver seus próprios problemas. Nas artes, o problema da representação da profundidade é visível, Alberti e Brunelleschi apresentam soluções geométricas (1, 2) através do cálculo da perspectiva (Figura 1.1), pois até então as pinturas, afrescos, mozaicos e desenhos não tinham noção alguma de profundidade — os elementos que compunham a pintura eram distribuídos, até então, segundo sua importância espiritual ou temática.

Essa solução não foi suficiente para Cézanne nem seus contemporâneos da Arte Moderna, que não estavam contentes com essa “equação matemática” e usaram graduações de cores para representar a profundidade. Outros meios como o *sfumato* (onde as pinceladas que definem bordas e linhas são removidas com verniz de madeira, comum nas pinturas renascentistas, sendo a “Monalisa” de Leonardo da Vinci seu principal exemplo (3, 4)), as cores venezianas, o movimento, a expressão, foram criados por cada geração de artista

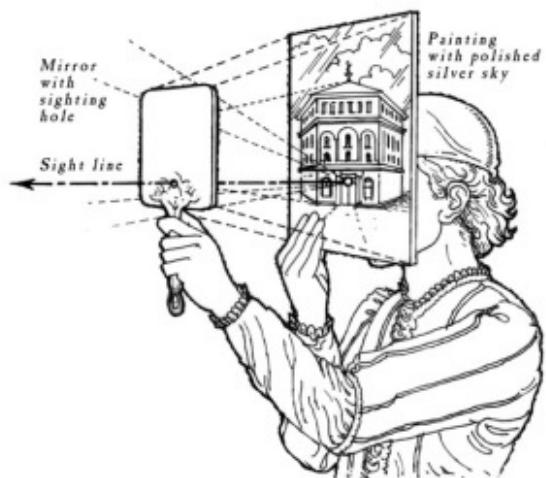


Figura 1.1 – Retratação de um dos experimentos de Brunelleschi que permitiu-lhe (re)descobrir a técnica de representação de profundidade pela perspectiva, onde todas as linhas de um objeto convergem a um só ponto. (1)

em uma tentativa de expressar o mundo ao seu redor. E a cada geração, estes mesmos artistas descobriram que continuavam existindo convenções que os obrigavam a aplicar o que haviam aprendido ao invés de pintarem o que realmente viam. Os “rebeldes” da Arte Moderna acabaram por negar essas convenções, criando novos meios, como os Impressionistas que tentaram apresentar um método com precisão científica para representar na tela o ato da visão. Não queriam mais a “fidelidade à natureza” de Caravaggio ou a “beleza ideal” de Poussin, buscavam “expressividade intensa, clareza de estrutura e uma simplicidade linear na técnica” (5). O século XX presencia a passagem de uma geração de experimentadores, inventores, que davam preferência à originalidade do que à tradição. Como bem dito por Gombrich⁶ “Qualquer afastamento da tradição que interessasse a crítica e atraísse um seguidor era saudado como um novo ‘ismo’ ao qual o futuro pertenceria.”. Essa inquietação moderna é avistada nas linhas retas e arquitetura funcional das casas e prédios do outro lado da rua, apenas para citar uma das influências que a Arte Moderna acabou por tornar presente no dia-a-dia.

Na música isso é também bastante perceptível: o Modal acabou criando o “problema” do trítono, que desempenhou papel importante como tensão a ser resolvida na música Tonal; o contraponto tenta resolver o problema de arranjar várias vozes sem que se cruzem; o Atonalismo e o Serialismo apresentam novas maneiras de se fugir de um tom fundamental e apresentar novas maneiras de se arranjar as notas; a música eletroacústica e eletrônica tenta extrapolar os limites das sonoridades, tentando criar timbres que nunca foram ouvidos. Há sempre a preocupação em expandir o que se entende por realidade, por natureza. (6) Novamente tomando emprestada a história da Música, o que é entendido como Som e até mesmo como Música sofreu alterações durante o tempo. Na Renascença e Barroco, com a supremacia da igreja como instituição que regulamentava o que era Música, a presença do ruído é condenada. Porém, com as épocas modernas, o ruído começa a fazer parte dos elementos sonoros, com Berlioz, Scelsi, a emancipação

da dissonância (Schoenberg), do ritmo (Stravinsky). A percussão, desconsiderada e evitada na liturgia é colocada à frente com Berlioz — que era percussionista. Até então a percussão só servia para pontuar certos momentos. Russolo Ferrari quer trazer os sons da cidade como elemento musical, o discurso mimético através de sons gravados, que transmitem significado; Parmegiani inclui sons da música pop como colagens; Mâche extrapola os instrumentos musicais querendo com eles imitar sons da natureza em uma forma de “onomatopéia musical”; Lachenmann usa apenas ruídos; e mais recentemente, Hendrix revoluciona a Música com a guitarra elétrica, e o uso de ruídos se desenvolve até tal ponto onde há apenas ruído como material musical, no que veio a ser conhecido como movimento ou estilo “noise”. Citando Didier Guigue (7) sobre Stockhausen, Berio, Crumb e Lachenmann: “Cada um, a seu modo, buscou o desenvolvimento de um conceito integrado da totalidade do fenômeno musical por meio de estratégias compostionais capazes de resolver os problemas formais [...]”.

A evolução das artes está concentrada nessa solução de problemas e expansões. Buscar entender como essa evolução se dá de uma maneira quantitativa, através de medidas, é objetivo geral deste estudo. Estas medidas têm como base conceitos centrais no estudo da Filosofia: *oposição, inovação e dialética*. São conceitos originalmente qualitativos. A dialética por exemplo é definida como um método de argumentação onde busca-se a síntese entre dois argumentos contraditórios: a tese e a antítese. O que se promove neste estudo é um ponto de vista alternativo. Tese, antítese e síntese são definidas como estados em uma série temporal pertencente a um espaço vetorial. E a dialética torna-se assim uma medida geométrica: o inverso da distância entre o estado de síntese e a bissetriz formada pelos estados de tese e antítese. Quanto menor a distância, maior a dialética. Pode-se agora falar em *quanto* um argumento apresenta dialética. Ou se um dado argumento possui dialética maior ou menor que outro.

Para ser possível tal análise, é necessária a representação dos agentes envolvidos — nesse caso, pintores e suas obras — em um espaço geométrico onde as medidas são então realizadas. Esse

mapeamento começa com a seleção de imagens de pinturas. Um grupo de 12 pintores foi selecionado, sendo 6 pintores representantes reconhecidos do movimento Barroco e outros 6 pintores da era Moderna. Um total de 20 pinturas de cada pintor foi escolhido aleatoriamente, formando um conjunto de 240 pinturas a serem analisadas. Métodos de processamento e análise de imagens são aplicados para extrair vetores de atributos que caracterizam cada pintura. Através da análise de matriz de espalhamento e LDA, os atributos que melhor classificam as pinturas em seus respectivos pintores são selecionados. Esses vetores de atributos, agora com dimensões reduzidas, formam então o espaço vetorial. Considerando tais vetores em ordem cronológica tem-se uma série temporal e é nessa série que se dá o cálculo das medidas sugeridas.

Enquanto valores numéricos, tais medidas revelam padrões que encontram paralelo na história das artes. Um exemplo marcante é o contraste encontrado nos grupos de estados dos pintores Barrocos e Modernos. Enquanto todo o grupo Barroco apresenta sobreposição entre seus pintores, o grupo de pintores Moderno apresenta quase nenhuma sobreposição. Essa observação encontra base na história das artes, onde os pintores Barrocos reconhecidamente compartilham técnicas uns com os outros — e portanto, compartilham também características estéticas em suas pinturas — enquanto os Modernos são marcados pelo individualismo, cada qual definindo seu próprio estilo.

As medidas assim como o *framework* sugerido é independente de domínio, o que possibilita seu uso para a análise de diversas áreas humanas. Até então, Filosofia, Música e Artes Plásticas foram avaliadas, porém aplicações em Cinema, Literatura ou Arquitetura são possíveis. Tal flexibilidade permite também a comparação entre as medidas obtidas para cada área de conhecimento. Por exemplo, é possível notar que na Música há grande valores para dialética, enquanto na Filosofia, a oposição é o caráter predominante. Já na Pintura, há constante inovação e ambas oposição e dialética possuem maior valor no momento de transição de um movimento artístico ao outro. Novamente, cada um desses resultados encontra fundamento na história e nas

características de cada um de seus atores e obras.

1.1 Motivação

A subjetividade da análise da história das artes sugere métodos objetivos que complementem tal análise. É importante ressaltar que tal método de forma alguma pretende esgotar ou suplantar a análise subjetiva, humana, mas sim, complementá-la, somar ao ferramental metodológico já existente. Da mesma forma, conceitos como a dialética possuem grande importância nas Ciências Humanas, mas não são comumente tratados de maneira quantitativa.

Ainda, a possibilidade de automatizar o cálculo dos atributos usados para análise também motivou esse estudo. No estudo anterior (8), os atributos eram fornecidos por críticos (os próprios autores) através de notas dadas a uma determinada característica de uma obra (e.g. presença ou não de complexidade rítmica em uma peça musical). Aqui buscou-se automatizar esse processo, com o uso de processamento e análise de imagens para extrair atributos das pinturas. Buscou-se ainda expandir o domínio de aplicação do método para mais uma área além da Música e Filosofia, no caso, as Artes Plásticas. Procurava-se assim investigar se nesse nova área de aplicação haveriam similaridades com as áreas já analisadas.

1.2 Objetivos

Em uma única sentença, modelar artefatos produzidos por artistas (no caso, pinturas, mas poderiam ser peças musicais ou poemas) como um conjunto de características passíveis de serem projetadas em um espaço geométrico onde conceitos subjetivos — antes apenas de domínio das Ciências Humanas — como dialética, oposição e inovação podem ser calculadas como medidas quantitativas, oferecendo uma forma complementar à interpretação da evolução da história artística e, porque não, da evolução da criatividade humana.

1.3 Organização

No Capítulo 2 são descritos os fundamentos, algoritmos, métodos canônicos e detalhes históricos sobre os quais se construiu este estudo, assim como trabalhos correlacionados e de interessante leitura. O Capítulo 3 apresenta os desenvolvimentos realizados nesse estudo: como as pinturas foram processadas a ponto de fornecerem um conjunto de características que tornou possível a representação da evolução artística em um plano geométrico assim como o cálculo de medidas de dialética, oposição e inovação. Ainda, são apresentadas essas projeções e medidas geométricas, assim como sua interpretação em um contexto histórico e crítico. Por fim, o Capítulo 4 faz uma revisão do que foi discutido e aponta as principais contribuições e conclusões desse estudo, além de refletir sobre desenvolvimentos futuros e que já estão em andamento. Os Apêndices apresentam um tutorial para *download* e execução dos *scripts Python* desenvolvidos para essa análise, assim como uma galeria com miniaturas de todas as imagens das 200 pinturas usadas no estudo, além de visualizações alternativas da série temporal resultante e a descrição de uma exposição realizada no IFSC/USP com imagens geradas a partir de um algoritmo para pintura generativa desenvolvido nesse trabalho.

2 *Fundamentos*

Onde são descritos os fundamentos, algoritmos, métodos canônicos, sobre os quais se construiu os desenvolvimentos.

2.1 Uma breve exploração sobre o Barroco e Arte Moderna

É interessante levantar aqui algumas características sobre a história e estética presente nos movimentos Barroco e Moderno. Tais pontos são confrontados com observações obtidas pela análise das medidas quantitativas, discutidas no Capítulo 3. Da mesma forma, o resumo biográfico de cada artista considerado auxilia na avaliação de tais resultados.

2.1.1 Barroco

O Barroco é marcado pela tradição, pelo desejo de retratar a verdade (encontrado nas obras de Caravaggio, Frans Hals e Velázquez), a beleza (em Poussin, Vermeer), a natureza e o sagrado (Caravaggio, Rembrandt). Esteticamente, é notável o uso do contraste de luz (como na técnica do “*chiaroscuro*” de Caravaggio), a preferência por oposições complexas e desprezo pelo equilíbrio simplista na composição dos elementos em uma pintura. A transmissão dessas técnicas ou estéticas de um pintor para o outro é comum no Barroco. Espera-se, portanto, que pintores barrocos apresentem uma grande similaridade estética em suas obras. (5)

Para o presente estudo, os seguintes pintores foram escolhidos por representarem, reconhecida-

mente, características da era Barroca:

Miguel Ângelo da Caravaggio, Itália, 1573-

1610. Após a Renascença, foram Annibale Carracci e Miguel Ângelo de Caravaggio que, mesmo tendo métodos completamente opositos, amplificaram as ideias já apresentadas em Tintoretto e El Greco (ênfase sobre luz e cor, desprezo pelo simples equilíbrio, preferência por oposições complexas) no maneirismo mas que foram apresentadas de uma nova maneira e inauguraram o que viria a ser o movimento Barroco. Caravaggio, diferente de Carracci que se preocupava em retratar o belo, queria retratar a verdade, como a via, em detalhes. Essa busca pela verdade pode ser vista em *Judite e Holoferne* (Figura 2.1).



Figura 2.1 – Judite e Holoferne, c. 1599

O uso da luz contrastando rigidamente com o negro fundo e ajudando a ressaltar a joviedade de Judite, que demonstra ter convicção do que faz: cortar a cabeça de Holoferne, enquanto sua serva mostra nervosismo, esperando que o pedaço de carne morta encha o saco de pano que segura. É possível sentir o horror, surpresa e impotência de Holoferne enquanto é arrancado de seu sono por sua própria espada. Caravaggio fornece assim uma interpretação notável detalhismo da passagem bíblica: “Então Judite se aproximou da coluna da cama, que ficava junto à cabeça de Holofernes, e pegou a espada dele. Depois chegou perto da cama, agarrou a cabeleira de Holofernes, e pediu: Dá-me força agora, Senhor Deus de Israel. E com toda a força, deu dois golpes no pescoço de Holofernes e lhe cortou a cabeça. Rolou o corpo do leito e tirou o mosquiteiro das colunas. Depois saiu, entregou a cabeça de Holofernes para a serva, que a colocou na sacola de alimentos.” (Judit 13, 6)

Frans Hals, Holanda, 1580?-1666. Ao mesmo tempo que o Barroco era iniciado na Itália (Roma foi neste período o que a França foi mais a frente, o centro de discussões e atenções artísticas), na metade católica da Europa, em sua parte protestante não havia espaço para pintar o sagrado. Sobravam os retratos como fonte de renda e Frans Hals soube bem como pintá-los – embora recebendo pouco em retorno. Sua obra é constituída em grande maioria por retratos de burgueses e mercadores Holandeses, como o *Retrato de Isaak Abrahamsz Massa* (Figura 2.2),

mercador e amigo próximo de Hals. Embora na época a grande maioria dos pintores e estudantes estivessem influenciados pela técnica do “chiaroscuro” de Caravaggio, isso não se observa em Frans Hals: o fundo possui detalhes, complementa a composição e existem variações de sombra na face do modelo (o lado direito é iluminado por uma luz direta, enquanto o lado esquerdo apresenta uma sombra de luz natural). Em Caravaggio, a luz é outra, ela é direta, penetrante, artificial. Ao mesmo tempo, os retratos de Frans Hals diferiam dos retratos de até então. Sua pincelada rápida permitia capturar não o modelo, mas o momento, o instante. Outra diferença é a pose alternativa para a época. Diferente dos retratos com olhares perdidos, Frans Hals usa os olhos do modelo para expressar e compor o momento. Ao invés de um olhar perdido, Massa olha para algo que lhe chama atenção, a ponto de virar-se na cadeira.

Nicolas Poussin, França, 1594-1665. Carracci, Reni e seus seguidores retratavam uma versão “embelezada” da natureza, que imitava as estátuas clássicas. Este programa ficou conhecido como neoclássico ou “acadêmico”.



Figura 2.2 – Retrato de Isaak Abrahamsz Massa, c. 1626

Poussin foi um dos grandes mestres “acadêmicos” e, desta forma, influenciado pelo pintor que representa a oposição a Caravaggio: Carracci. Suas pinturas querem retratar a beleza, a inocência, a pureza de épocas antigas, seus mitos e histórias. É possível notar essa intenção na Figura 2.3 que retrata sua obra *Uma Dança para a Música do Tempo*. É interessante aqui apontar a diferença dessa composição enquanto comparada com as obras de Caravaggio e a proximidade com as pinturas de Carracci ou Reni.



Figura 2.3 – Uma Dança para a Música do Tempo, c. 1634-1635



Figura 2.4 – Velha Fritando Ovos, c. 1618

Velázquez, Espanha, 1599-1660. Mesmo ainda não tendo estado em Roma, havia conhecido e se impressionado pelos trabalhos de Caravaggio. Há grande semelhança entre seus trabalhos e as pinturas do mestre Italiano, como é possível observar na Figura 2.4 da obra *Velha Fritando Ovos*. Assim como Caravaggio, retrata a natureza como ela é, sua verdade é mais importante do que sua aparente beleza. Na pintura em destaque, há uma grande preocupação com os detalhes: os ovos, as mãos, as feições, os utensílios de cozinha, o vidro que o menino segura, todos representados com precisão fotográfica. A técnica do “chiaroscuro” de Caravaggio foi aplicada, onde uma luz intensa à esquerda da pintura ilumina com grande contraste os detalhes que Velázquez

Diego Velázquez, Espanha, 1599-1660. Mesmo ainda não tendo estado em Roma, havia conhecido e se impressionado pelos trabalhos de Caravaggio. Há grande semelhança entre seus trabalhos e as pinturas do mestre Italiano, como é possível observar na Figura 2.4 da obra *Velha Fritando Ovos*. Assim como Caravaggio, retrata a natureza como ela é, sua verdade é mais importante do que sua aparente beleza. Na pintura em destaque, há uma grande preocupação com os detalhes: os ovos, as mãos, as feições, os utensílios de cozinha, o vidro que o menino segura, todos representados com precisão fotográfica. A técnica do “chiaroscuro” de Caravaggio foi aplicada, onde uma luz intensa à esquerda da pintura ilumina com grande contraste os detalhes que Velázquez

queria propositalmente ressaltar, ao mesmo tempo, o fundo é tão negro que não se pode mais observar as paredes do ambiente.

Rembrandt van Rijn, Holanda, 1606-69. É reconhecido como o maior pintor da Holanda, dono de uma série de autorretratos que contam de forma biográfica toda a sua vida. Rembrandt usava a técnica do “chiaroscuro” porém de maneira diferente, como é possível ver na *A Tempestade no Mar da Galiléia* (Figura 2.5). Há grande uso de contraste, mas o fundo não está mergulhado em preto, ao contrário, o céu ajuda a complementar a composição, o mesmo pode se dizer do mar. Essa mesma abordagem está presente nos retratos e outras cenas bíblicas que pintou. De todos os pintores do Barroco, Rembrandt parece usar as técnicas de seus antepassados, mas ao mesmo tempo, se contrapor a eles adicionando nuances de seu próprio estilo.

Figura 2.5 – A Tempestade no Mar da Galiléia, c. 1633

Johannes Vermeer Uma das grandes realizações dos pintores holandeses é a retratação da natureza-morta com incrível detalhismo. Vermeer é considerado o grande mestre deste estilo, mas ao invés de objetos, incluía pessoas em sua natureza-morta. Vermeer parece procurar a melhor vestimenta, a melhor pose da modelo e posição do ponto de luz. Parece experimentar com os objetos da cena até encontrar o que deseja.

É interessante também perceber a diferença de sua pintura comparada a dos outros pintores aqui discutidos: todas são



Figura 2.6 – A Garota com Brinco de Pérola, c. 1665

feitas praticamente no mesmo local — sempre um cômodo doméstico — e com um número limitado de modelos, geralmente com a luz vindo de uma janela. Em suas pinturas há, a exemplo de Velázquez, uso extensivo do “chiaroscuro” de Caravaggio, como na *A Garota com Brinco de Pérola* (Figura 2.6).

2.1.2 Arte Moderna

Cada época de uma civilização cria uma arte que lhe é própria e que jamais se verá renascer. Tentar revivificar os princípios artísticos de séculos passados só pode levar à produção de obras natimortas. Assim como é impossível fazer reviver em nós o espírito e as maneiras de sentir dos antigos gregos, também os esforços tentados para aplicar seus princípios [...] só levarão à criação de formas semelhantes às formas gregas. A obra assim produzida será sem alma para sempre.

Wassily Kandinsky (9)

De Vermeer a van Gogh, passam-se por volta de 150 anos, toda a Renascença, o Impressionismo, chegando à Arte Moderna. Ao contrário do Barroco, a arte Moderna não está atrelada a regras. Cada pintor aplica ou cria novas formas de representar sua visão da natureza. Como bem dito por Gombrich (5): “[os pintores Modernos] ansiavam por uma arte que não consistisse de trucos que poderiam ser aprendidos, por um estilo que não é meramente um estilo, mas algo forte e poderoso como a paixão humana”. Van Gogh procurou por essa arte através do uso intenso de cores e aspecto caricato de suas pinturas. Paul Gauguin foi buscar no “primitivismo” encontrar as raízes da representação da natureza. Outros como Seurat (2) usaram da observação de propriedades físicas da visão cromática para pintar a natureza como uma coleção de pontos coloridos e dessa forma acabou criando o pontilhismo. Os pintores Modernos criam seu próprio estilo de maneira individualista, sem a influência de seus contemporâneos ou predecessores.

A Arte Moderna é representada nesse estudo pelos seguintes pintores:

Vincent van Gogh, Holanda, 1853-1890.

Junto com Cezánne e Gaugin, Van Gogh inaugura o que veio a ser conhecido como “arte moderna”. Cada pincelada de Van Gogh revela sua sensação ao estar pintando, sua emoção. Não estava interessado em respeitar regras de perspectiva, de composição, ou sombra. É possível perceber esse menosprezo pelo clássico no *Quarto em Arles* (Figura 2.7).

Os móveis não apresentam perspectiva correta, muito menos dimensões. Não

há sombra na pintura. Propunha usar as cores de maneira franca, sem se render às técnicas de sombreado. As pinceladas são todas aparentes, formam a própria textura. Nada tem de parecido com as obras Barrocas, ou mesmo do Impressionismo. Usava a distorção dos objetos para expressar o que sentia. Vale complementar tal imagem com as palavras do próprio Van Gogh em uma de suas inúmeras cartas: “Lamentavelmente, meu caríssimo amigo, o público apenas verá nesse exagero uma caricatura — mas o que nos importa isso?”. Mesmo sem perceber, acabara por desempenhar um papel revolucionário para as artes, e se opõe assim a todos os pintores conhecidos até então.

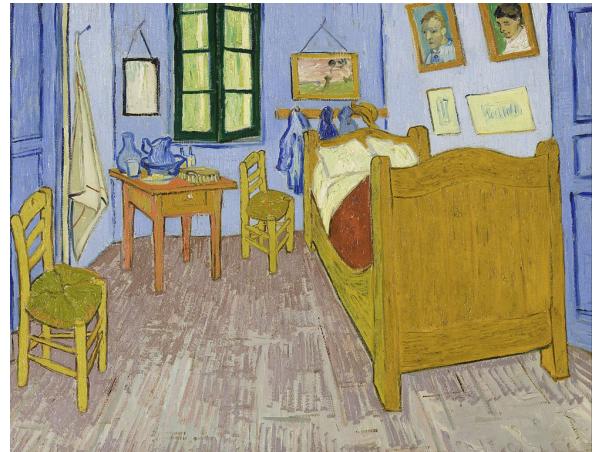


Figura 2.7 – Quarto em Arles, c. 1889

Wassily Kandinsky, Rússia, 1866-1944. Possivelmente inaugurou o que veio a ser conhecido como “arte abstrata” onde nenhum objeto é reconhecível na pintura. Suas pinturas encontram ressonância com a música cromática — encontrada já em Bach em seu “Cravo Bem Temperado”, tornando-se elemento expressivo no fim do período romântico, com Lizt, Mahler e Wagner, e acabando por impulsionar o atonalismo e ambas música dodecafônica e música serial, já

no século XX — no sentido do uso de toda a escala cromática em uma composição.

Kandinsky estava interessado no efeito perceptivo da cor pura, na interpretação psicológica das cores. Assim, formas que lembressem objetos da natureza não eram necessários, como visível na Figura 2.8. Esse uso das cores da maneira direta e franca já tinha sido anunciado por Van Gogh, que negava o uso de sombras para tornar as cores ainda mais aparentes e expressivas, algo visto também em Kandinsky e Matisse.

Henri Matisse, França, 1869-1954. Foi o mais famoso pintor do grupo parisiense conhecido como *Les Fauves*, ou “os selvagens”. Tal grupo foi assim chamado pelo desprezo às formas encontradas na natureza e pelo uso de cores violentas em suas pinturas. Dedicou-se à “simplificação decorativa” ao estudar os esquemas de cores de tapetes orientais e transpor tais esquemas para seus quadros.

Como visto na Figura 2.9 há harmonia entre todos os elementos da pintura, fazendo com que pareçam formar um único padrão, como em um tapete. Até mesmo a paisagem vista da janela parece integrar-se com a sala. Os desenhos do papel de parede são encontrados também na toalha da mesa. Os contornos simples desses desenhos são encontrados também na figura humana e em todos os utensílios da sala. Por esses motivos, o pintor a chamou de “harmonia em vermelho”, ressaltando



Figura 2.8 – Em Branco, c. 1923

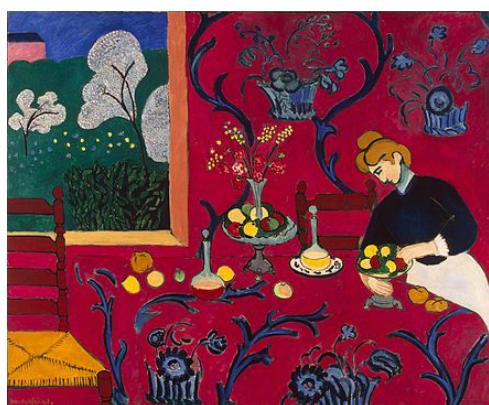


Figura 2.9 – A mesa de jantar: harmonia em vermelho (quarto vermelho), c. 1908

a importância da cor na obra.

Pablo Picasso, Espanha, 1881-1973. Estava interessado no problema de representar uma imagem através de objetos simples, mas sem perder sua característica de solidez e profundidade. Influenciado por Cézanne, emprega de forma literal seu conselho de observar a natureza como um conjunto de esferas, cones e cilindros. Procura então representar o que vê como um complexo de peças uniformes, cada uma representando uma faceta do que está sendo retratado, fundando assim o movimento Cubista. Essa colagem geométrica é vista em *Violino* (Figura 2.10). De certa forma, relembra os desenhos “primitivos” que representam o objeto a partir do ponto de vista que mais

lhe representa. Os traços dos símbolos encontrados no instrumento são repetidos, como as curvas da voluta, dos efes e do corpo. O mesmo grupo de 4 cortas aparece diversas vezes, como querendo representá-las de vários pontos de vista. Essa colagem de pontos de vista remete a como o objeto é lembrado: quando se imagina um violino, sua forma é exagerada, não se imagina apenas um, mas um conjunto de detalhes de todos os violinos que já foram experimentados pela memória. Embora seja uma colagem de formas desconexas, a pintura apresenta organização, como que seu todo desse sentido ao objeto conhecido previamente.



Figura 2.10 – Violino, c. 1911-12

Joan Miró, Espanha, 1893-1983. Inicialmente teve sua fase fauvista mas tornou-se reconhecidamente um surrealista. Miró foi um dos primeiros artistas a desenvolver a “escrita automática”, uma técnica onde o artista deixa sua mão mover-se livremente pelo papel, transferindo-a em seguida para a tela. Queria com isso se desfazer das técnicas de pintura já estabelecidas. Utilizou também conjuntos de símbolos abstratos para representar objetos reais (e.g. um triângulo para a cabeça, linhas curvas para um bigode) como é visto na Figura 2.11, onde sua obra acaba por se tornar uma colagem destes símbolos.



Figura 2.11 – O Campo Cultivado, c. 1923-24

Jackson Pollock, Estados Unidos, 1912-1956. Abandonou as imagens fantásticas do Surrealismo e os métodos convencionais de pintura. Pintava com as telas jogadas no chão, gotejando ou arremessando suas tintas em pé sobre as telas.



Figura 2.12 – Ritmo de Outono, c. 1950

O complexo de linhas (visto na Figura 2.12) reflete o desejo de simplificação dos artistas mo-

dernos assim como sua busca por uma “pintura pura” (5). Pollock trilhou essa busca através do que ficou conhecido como “pintura de ação”: uma pintura não premeditada, criada por impulso expontâneo.



2.2 Conceitos em Filosofia

Dialética, oposição e inovação são conceitos **excenciais** nas discussões filosóficas. A dialética é vista como método filosófico para argumentação, central na filosofia ocidental e oriental. O método envolve dois ou mais argumentos (ou ideias) contraditórios, a tese e a antítese. A solução dialética para esse conflito seria a síntese, uma nova ideia que busca pelo equilíbrio da tese e antítese. Como a tradução literal sugere, “o caminho entre as ideias” é o diálogo entre ideias que leva a outras ideias. Zenão de Eleia, Aristóteles, Platão e Sócrates foram pioneiros em seu uso, e também está presente no método dialético de Hegel e na dialética de Marx.

A oposição de ideias está intimamente relacionada à dialética. Há grande oposição entre a tese e a antítese, sendo ideias essencialmente contraditórias. A inovação, por sua vez, relaciona-se com a oposição: uma ideia não necessariamente estará destinada a opor uma outra ideia, não participa apenas de um “jogo de oposição” pois pode também buscar um movimento novo, alternativo. Desta forma, está inovando.

Uma proposta de quantificar tais conceitos foi iniciado em um estudo aplicado à Filosofia e Música (8). A partir de uma matriz de atributos que descrevia pesos (ou notas) dadas em conjunto pelos autores a certas características de filósofos e músicos, descrevia-se um espaço vetorial onde os conceitos eram quantificados. Esse estudo está sendo aqui expandido, onde as mesmas medidas são aplicadas, mas não mais a atributos com notas que poderiam ser julgadas como subjetivas, mas a partir da extração de tais atributos por processamento digital de imagens (discuto na Seção 2.3).

Havendo N atributos, define-se um espaço N -dimensional chamado de *espaço criativo*, pois a exemplo do espaço criativo sugerido por Deuze, tem como objetivo a representação de uma superfície onde artefatos (e.g. pinturas, peças musicais, poemas) criados por agentes (e.g. pintores, compositores, escritores) caracterizam uma região que foi explorada criativamente. É neste espaço criativo que as medidas de dialética, oposição e inovação são calculadas.

Para simplificar o cálculo, um protótipo \vec{p}_i é definido para cada classe C_p . Cada protótipo summariza uma classe de pinturas (ou um pintor), correspondendo ao seu *centróide*: $\vec{p}_i = \frac{1}{N_p} \sum_{j=1}^{N_p} \vec{f}_j$ calculados no espaço projetado. É importante notar que essa medida é independente de dimensão, porém métodos de redução de dimensionalidade são aplicados à matriz de atributos para possibilitar a visualização do *espaço criativo* em duas dimensões.

Uma sequência S de \vec{p}_i estados define uma série temporal. Um estado médio em um dado tempo i abrangendo os estados \vec{p}_1 até \vec{p}_j é definido como:

$$\vec{d}_i = \frac{1}{j} \sum_{j=1}^k \vec{p}_j \quad (2.1)$$

O estado de oposição define uma medida de oposição à \vec{p}_i como

$$\vec{r}_i = \vec{p}_i + 2(\vec{d}_i - \vec{p}_i) \quad (2.2)$$

e dessa forma, um vetor de oposição pode ser definido como:

$$\vec{D}_i = \vec{r}_i - \vec{p}_i. \quad (2.3)$$

que representa propriamente o deslocamento do estado \vec{r}_i em função de \vec{p}_i .

Sabendo que qualquer deslocamento a partir de um estado \vec{p}_i até um outro estado \vec{p}_j é definido

como

$$\vec{M}_{i,j} = \vec{p}_j - \vec{p}_i \quad (2.4)$$

é possível definir um *índice de oposição* para quantificar quanto um protótipo p_j se opõe a outro protótipo p_i (ou seja, um deslocamento na direção de \vec{r}_i) ou concorda com outro protótipo p_i (um deslocamento na direção de $-\vec{r}_i$):

$$W_{i,j} = \frac{\langle \vec{M}_{i,j}, \vec{D}_i \rangle}{\|\vec{D}_i\|^2} \quad (2.5)$$

sendo portanto a projeção de $\vec{M}_{i,j}$ em \vec{D}_i , ou seja, não importa onde o deslocamento tenha se dado, ele é considerado em relação ao vetor de oposição (ou deslocamento) \vec{D}_i . A Figura 2.13 ilustra \vec{D}_i dados dois estados consecutivos \vec{v}_i e \vec{v}_j .



Porém, movimentos nesse *espaço criativo* não estão restritos a confirmação ou contradição de “ideias”. Ideias alternativas podem existir fora desse deslocamento dualístico. Isso é modelado como um *índice de inovação* que quantifica quanto um protótipo p_j é inovador quando comparado com um outro protótipo p_i :

$$s_{i,j} = \sqrt{\frac{|\vec{p}_i - \vec{p}_j|^2 |\vec{d}_i - \vec{p}_i|^2 - [(\vec{p}_i - \vec{p}_j) \cdot (\vec{d}_i - \vec{p}_i)]^2}{|\vec{d}_i - \vec{p}_i|^2}} \quad (2.6)$$

ou seja, quanto p_j se afasta da linha L_i formada por p_i e r_i , a linha de “oposição”. A Figura 2.13 ilustra os cálculos dos índices de oposição e inovação para dois estados consecutivos \vec{v}_i e \vec{v}_j da série temporal.

Uma outra medida surge quando consideram-se três estados consecutivos nos tempos i, j e k . Sendo p_i a tese, p_j a antítese e p_k a síntese, um *índice de contra-dialética* pode ser definido como sendo

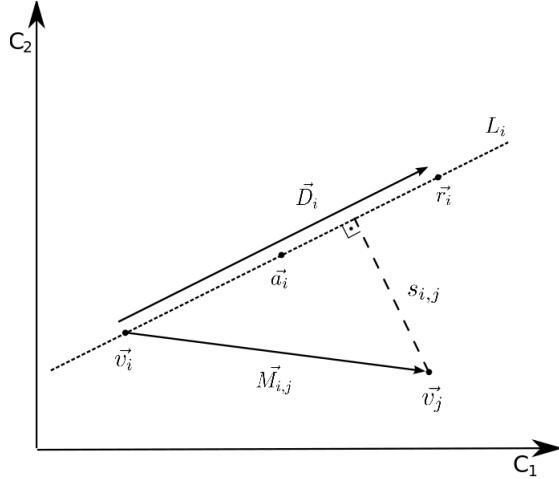


Figura 2.13 – Cálculo dos índices de oposição $W_{i,j}$ e inovação $s_{i,j}$ dados dois estados consecutivos \vec{v}_i e \vec{v}_j .



$$d_{i \rightarrow k} = \frac{|\langle \vec{v}_j - \vec{v}_i, \vec{v}_k \rangle + \frac{1}{2} \langle \vec{v}_i - \vec{v}_j, \vec{v}_i + \vec{v}_j \rangle|}{|\vec{v}_j - \vec{v}_i|} \quad (2.7)$$

ou, a distância entre p_k e a bissetriz $ML_{i,j}$ (ou um “hiperplano bissetriz” quando considerando espaços N -dimensionais) entre p_i e p_j . Em outras palavras, um estado p_k com grande distância $d_{i \rightarrow k}$ está afastado da síntese (possui baixa dialética) e vice-versa. A medida de contra-dialética $d_{i \rightarrow k}$ é ilustrada na Figura 2.14 para três estados consecutivos \vec{v}_i , \vec{v}_j e \vec{v}_k da série temporal.

2.3 Processamento e análise de imagens

Antes de analisar qualquer medida proveniente de atributos de artefatos do mundo físico, é preciso representá-los através de um modelo computacional. Como o domínio desse estudo é o das Artes Plásticas, mais precisamente, a Pintura, é necessário adquirir e processar imagens de obras de artistas.

O processamento e análise de imagens envolve operações para adquirir, manipular e representar imagens digitalmente em um sistema computacional. Envolve uma série de etapas canônicas,

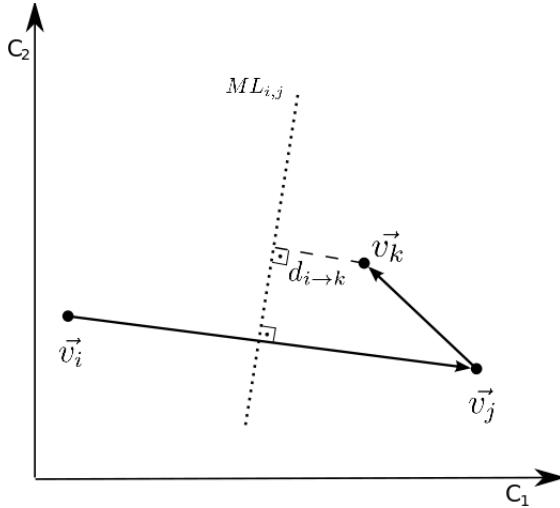


Figura 2.14 – Cálculo da contra-dialética $d_{i \rightarrow k}$ dados os estados consecutivos de tese \vec{v}_i , antítese \vec{v}_j e síntese \vec{v}_k . Quanto maior o valor da distância $d_{i \rightarrow k}$ de \vec{v}_j à síntese ideal formada pela bissetriz $ML_{i,j}$ entre \vec{v}_i e \vec{v}_j , menor a dialética.

sumarizadas na Figura 2.15. Na presente seção são discutidos cada uma dessas etapas que tornaram possíveis a realização desse estudo.

Cada imagem, após ser digitalizada, é representada como uma matriz de valores onde cada elemento armazena a intensidade de cor de uma região amostrada da imagem original. Uma imagem I representada no formato conhecido como RGB é definida como a matriz

$$I_{x,y,i} = [(p, q, r)], \quad 0 \leq p, q, r \leq 255 \quad (2.8)$$

cuja dimensão $N_x \times N_y \times N_i$ corresponde a quantidade de *pixels* N_x da linha e N_y da coluna, assim como a quantidade N_i de canais de cores — e.g. para uma imagem de 800x800 pixels, sua ordem é 800×800×3. Cada elemento da matriz possui um valor inteiro entre 0 e 255, onde 0 é o limite mais escuro e 255 o mais claro.

As imagens podem ainda serem representadas em escala de cinza, por uma matriz

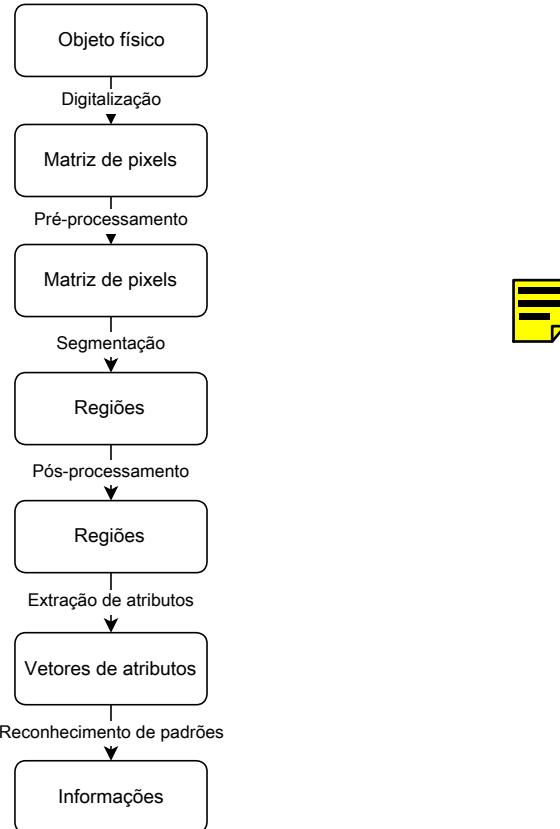


Figura 2.15 – Etapas canônicas para processamento e análise de imagens.



$$G_{x,y} = [n], \quad 0 \leq n \leq 255 \quad (2.9)$$

com dimensão $P \times Q$ e valor n representando o valor inteiro da intensidade de cinza de cada *pixel*. Alguns algoritmos de processamento, como os de segmentação, necessitam de imagens nesse formato.

Outros algoritmos necessitam representar a imagem com apenas dois valores: preto e branco. Por exemplo, elementos conexos em uma imagem segmentada são representados por imagens em preto e branco com o objetivo de facilitar a marcação de cada região conexa. A matriz é definida como

$$B_{x,y} = [n], \quad n \in 0, 255 \quad (2.10)$$

tendo dimensão $P \times Q$ e seu valor n podendo assumir apenas dois valores, 0 ou 255. Convencionase usar também, dado o aspecto binário da matriz, os valores 0 ou 1.

Uma imagem I , G ou B pode também ser definida como uma função $f(x,y)$ que mapeia as coordenadas (x,y) de um *pixel* em seu valor n . Sendo $S_x = 0, 1, \dots, N_x - 1$ e $S_y = 0, 1, \dots, N_y - 1$ o domínio espacial da imagem e $N = 0, 1, \dots, 255$ o domínio de n , tem-se a função

$$f : S_x \times S_y \rightarrow N \quad (2.11)$$

onde para B o domínio é $N = 0, 255$ ou $N = 0, 1$, e para I e G o domínio é $N = 0, 1, \dots, 255$, representando as graduações de cores em cinza e para cada canal de cor primária, respectivamente.

2.3.1 Conceitos úteis de Geometria Discreta e Morfologia Matemática

Enquanto trabalhando com imagens digitais o conceito de *vizinhança* é central. Algoritmos para pré-processamento (e.g. como a equalização por histograma, ou filtro de medianas) e até mesmo para extração de características como o algoritmo de curvatura ou cálculo de entropia local, são ambos baseados nesse conceito. Os vizinhos de um pixel p são os pixels V_i que o circundam, e costuma-se chamar este conjunto de *vizinhança- N* com $0 \leq i \leq N$. Duas vizinhanças são comuns, a vizinhança-4 e vizinhança-8. Se um pixel P possui coordenadas (i, j) , sua vizinhança-4 e vizinhança-8 seriam respectivamente os seguintes conjuntos:

$$V_0 = (i, j+1) \quad (2.12)$$

$$V_1 = (i-1, j) \quad (2.13)$$

$$V_2 = (i, j-1) \quad (2.14)$$

$$V_3 = (i+1, j) \quad (2.15)$$



$$V_0 = (i, j+1) \quad (2.16)$$

$$V_1 = (i-1, j+1) \quad (2.17)$$

$$V_2 = (i-1, j) \quad (2.18)$$

$$V_3 = (i-1, j-1) \quad (2.19)$$

$$V_4 = (i, j-1) \quad (2.20)$$

$$V_5 = (i+1, j-1) \quad (2.21)$$

$$V_6 = (i+1, j) \quad (2.22)$$

$$V_7 = (i+1, j+1) \quad (2.23)$$

onde é importante notar que as coordenadas (i, j) são relacionadas com as linhas e colunas da matriz que representa os pixels da imagem e não com as coordenadas Cartesianas (x, y) de um ponto qualquer na imagem. A Figura 2.16 ajuda a compreender tais vizinhanças.

Tendo uma vizinhança em torno de um pixel p qualquer com coordenadas (x, y) , pode-se definir uma função de processamento da imagem como

$$g(x, y) = T[f(x, y)] \quad (2.24)$$

	v_1	
v_2	p	v_0
	v_3	

vizinhança-4

v_3	v_2	v_1
v_4	p	v_0
v_5	v_6	v_7

vizinhança-8

Figura 2.16 – Coordenadas das vizinhanças-4 e 8 para um dado pixel p qualquer.

sendo $f(x,y)$ a imagem de entrada, $g(x,y)$ a imagem processada e T é um operador sobre f , definido sobre alguma vizinhança- N de (x,y) . Dessa forma, o centro (x,y) da subimagem que comprehende os pixels da vizinhança- N é movido de pixel em pixel, o que corresponde a alterar os valores $f(x,y)$ do centro pelo valor obtido por $g(x,y)$. É possível usar várias formas de subimagens (e.g. círculos ou elipses) mas subimagens quadradas são mais comuns para vizinhanças pois são de fácil implementação.

O operador T é **excencial** nesse tipo de processamento, pois é ele quem mapeia os valores de f em g . Uma operação de mapeamento muito comum para T é mapear o nível de cinza r em f para o nível de cinza s em g , ou:

$$s = T(r) \quad (2.25)$$

assim os níveis de cinza da imagem processada dependerá de alguma operação definida em T .

2.3.2 Pré-processamento

A etapa de pré-processamento tem como objetivo melhorar certos aspectos de uma imagem digital. É possível então corrigir defeitos ocorridos durante a aquisição da imagem ou realçar certos detalhes de interesse.

Costuma-se dividir o pré-processamento em operações no domínio real e das frequências. No

domínio real, os próprios elementos da matriz I são alterados diretamente. Já o domínio das frequências envolve a transformada de Fourier da matriz para manipular bandas de valores, necessitando da transformada inversa para levar a matriz ao espaço real novamente.

Uma operação recorrente de pré-processamento no domínio real, por ser computacionalmente barata e eficiente, é a *equalização por histograma*. O objetivo é ajustar o nível de contraste da imagem baseando-se em seu histograma de valores. O histograma de uma imagem G é dada pela função

$$\text{hist}(g) = p(r_k) = \frac{n_k}{n} \quad (2.26)$$

onde r_k é um nível de cinza k , n_k é a quantidade de pixels da imagem G que possuem nível de cinza k , n é quantidade de pixels da imagem G e $k \in \{0, 1, \dots, 255\}$. Ou seja, $p(r_k)$ corresponde à probabilidade de ocorrência de um nível de cinza r_k na imagem. O gráfico de $p(r_k)$ em função de r_k é denominado *histograma*. Essa informação é interessante quando se deseja realçar o contraste da imagem, visto que pode-se mensurar a quantidade de pixels em regiões mais claras, mais escuras e com níveis de cinza medianos. Assim, pode-se definir uma operação T que equalize os níveis de cinza r de f , gerando uma imagem equalizada g :

$$s = T(r_k) = \sum_{j=0}^k \frac{n_j}{n} = \sum_{j=0}^k p(r_j) \quad (2.27)$$

a essa operação T se dá o nome de *equalização de histograma* ou *linearização de histograma*. Ao se mapear os níveis de cinza r de f nos níveis s de g , tem-se a imagem equalizada em contraste.

Após equalizar os níveis de contraste da imagem, é comum suavisá-la e remover seus ruídos através de filtros como o de medianas. Esse efeito de suavização e remoção de ruídos ocorre pois cada pixel terá como seu valor a mediana de seus vizinhos. Assim, quanto maior a vizinhança,

maior a suavização. O filtro de médias também pode ser utilizado, porém o filtro de medianas preserva detalhes de bordas que são borrados pelo filtro de médias, portanto seu uso é mais interessante no caso da análise de pinturas. O que se quer é a eliminação de ruídos sem borrar detalhes de borda.

Para implementar o filtro por mediana, troca-se o valor do nível de cinza r em f pela mediana dos níveis de cinza na vizinhança- N desse pixel. Essa operação pode ser definida como

$$T[f(x,y)] = \text{med}(V_N(f(x,y))) \quad (2.28)$$

onde med é a mediana e $V_N(f(x,y))$ é o conjunto de pixels na vizinhança- N com centro em (x,y) na imagem f . A mediana é calculada ordenando-se os valores V_i em ordem crescente de seu nível de cinza e tomando o elemento central $V_{i/N}$ como seu valor. Da mesma forma que para a equalização por histograma, a imagem g com níveis s de cinza resultante da operação de T nos níveis r de cinza da imagem f

$$g(x,y) = s = T[f(x,y)] = T(r) \quad (2.29)$$

corresponde à imagem filtrada pela mediana.

2.3.3 Segmentação

Embora a visão humana seja capaz de distinguir formas (e dar-lhes significado, classificando-as) com relativa precisão, é preciso aplicar um procedimento conhecido como *segmentação* para identificar formas da imagem digitalizada. Assim, o processo de segmentação tem como objetivo particionar uma imagem em múltiplos segmentos que são na realidade grupos de pixels.

Há um grande número de algoritmos de segmentação, sendo uma área de pesquisa rica e em

constante desenvolvimento. Portanto, não há como esgotar todo o conjunto de algoritmos existentes em via de testá-los para a segmentação das pinturas selecionadas. Uma prática comum é selecionar um grupo de algoritmos e aplicá-los exaustivamente ao conjunto de imagens e, de maneira experimental, escolher o algoritmo que mais contribui para a segmentação pretendida. O algoritmo SLIC (*Simple Linear Iterative Clustering*) é baseado em superpixels e aplicado em matrizes coloridas de imagens. Portanto, para pinturas coloridas, seu uso é incentivado e demonstra segmentação esperada.

Algoritmos baseados em superpixels como o SLIC agrupam pixels em regiões que tenham maior significado do que a simples malha de pixels. Essas regiões mais significativas são chamadas superpixels. O algoritmo SLIC agrupa os pixels em superpixels através de uma adaptação do algoritmo de clusterização *k-means*. Apesar de ser uma ideia simples, se mostra comparável aos algoritmos de superpixel considerados “estado da arte” atualmente ??, chegando a superá-los para a segmentação.



O Algoritmo 1 lista os passos do procedimento SLIC. Primeiramente, uma imagem RGB I precisa ter seus elementos convertidos para CIELAB. Único parâmetro do algoritmo é k , sendo o número máximo de clusters. Em um passo inicial, k clusters são amostrados tendo seus centróides C_k distribuídos em uma malha regular de espaçamento $S = \sqrt{N/k}$, sendo N o número de pixels da imagem. No passo de atribuição, cada pixel p é associado a uma região limitada em torno de C_k . Isso é o que garante ganho na complexidade desse algoritmo, pois essa atribuição de cada pixel ao seu cluster não é feita considerando-se todos os N pixels da imagem, mas apenas aqueles pixels dentro dessa região. Como a região de um superpixel tem como tamanho aproximadamente $S \times S$, o tamanho da região de busca pelo novo centróide do cluster (i.e. $k - means$) é $2S \times 2S$ em torno do centróide C_k atual. Tendo todos os pixels p da região em torno do centróide, calcula-se a distância D de cada pixel p ao seu centróide C_k :



$$d_c = \sqrt{(l_j - l_i)^2 + (a_j - a_i)^2 + (b_j - b_i)^2} \quad (2.30)$$

$$d_s = \sqrt{(x_j - x_i)^2 + (y_j - y_i)^2} \quad (2.31)$$

$$D' = \sqrt{\left(\frac{d_c}{N_c}\right)^2 + \left(\frac{d_s}{N_s}\right)^2} \quad (2.32)$$

$$D = \sqrt{d_c^2 + \left(\frac{d_s}{S}\right)^2 m^2} \quad (2.33)$$

onde d_c e d_s são as distâncias do pixel p até um centróide C_k qualquer, considerando o espaço de cor — CIELAB — e o espaço geométrico, respectivamente. Em D' essas duas medidas são combinadas e também normalizadas segundo as distâncias máximas em cor e espaço, dadas por N_c e N_s . Como os centróides ficam espaçados a uma distância regular S , pode-se fazer $N_s = S$. E o máximo valor de cor é dado como parâmetro m do algoritmo. Com m posto dessa forma, esse parâmetro acaba por permitir o controle do peso das medidas de cor e espacial: quanto maior o valor de m , maior o peso da proximidade espacial e os superpixels serão mais compactos pois sua razão área por perímetro será menor. Quanto m é menor, os superpixels irão aderir mais às bordas (i.e. mais espalhados) de cada região e ao mesmo tempo terão tamanho e forma irregular. Como o algoritmo usa nativamente o formato CIELAB para cores, $m \in [1, 40]$. Cada pixel p tem sua distância e rótulo atualizados, caso **dua** distância atual seja menor que a distância antiga. Por fim, no passo de atualização do algoritmo, os novos centróides C_k são calculados como a média de todos os pixels pertencentes ao cluster e uma nova iteração se inicia. O algoritmo pára dado um máximo especificado de iterações ou se o erro residual da distância dos centróides atuais e anteriormente calculados em uma iteração forem menores ou iguais a um dado limiar.

Algoritmo 1: Algoritmo de segmentação SLIC

Entrada: Imagem colorida I em formato CIELAB

Entrada: Número máximo k de clusters

Entrada: Peso m para a distância no domínio espacial *versus* geométrico

Entrada: Número máximo t de iterações

Saída: Imagem rotulada R , cada rótulo identificando uma região segmentada

```

1 para cada centróide  $C_k = [l_k, a_k, b_k, x_k, y_k]^T$  faça
2   |    $C_k \leftarrow$  uma posição  $k$  de uma malha com espaçamento  $S$ 
3   fim
4 para cada pixel  $p$  faça
5   |   rótulo( $p$ )  $\leftarrow -1$ ;
6   |   distância( $p$ )  $\leftarrow \inf$ 
7   fim
8 enquanto não atingir a iteração máxima  $t$  faça
9   |   para cada centróide  $C_k$  faça
10  |   |   para cada para cada pixel  $p$  em uma região  $2S \times 2S$  em torno de  $C_k$  faça
11  |   |   |    $D \leftarrow$  distância entre  $p$  e  $C_k$ ;
12  |   |   |   se  $D \leq$  distância( $p$ ) então
13  |   |   |   |   distância( $p$ )  $\leftarrow D$  rótulo( $p$ )  $\leftarrow k$ ;
14  |   |   |   fim
15  |   |   fim
16  |   fim
17  |   para cada centróide  $C_k$  faça
18  |   |    $C_k \leftarrow$  ponto médio considerando os pixels da região
19  |   fim
20 fim
```

Após se ter todas as regiões rotuladas pelo algoritmo SLIC, é necessário um passo de rotulação por conectividade, visto que assim como a maioria dos algoritmos baseados em superpixels, não há a garantia do retorno de regiões conexas. Esse passo é feito então no pós-processamento.

2.3.4 Pós-processamento

Algoritmos como os de segmentação têm como saída principal uma versão da imagem original com rótulos. Esses rótulos identificam cada região segmentada, como ilustrado na Figura XX – essa etapa é comumente chamada de *rotulação*. Porém, esses rótulos identificam as regiões segmentadas, quando o que se quer é geralmente as regiões conexas. Regiões conexas são

aqueles cujas áreas formam uma ponte. Elas são especialmente interessantes quando se quer identificar as formas da imagem original. Um algoritmo simples de rotulação de componentes conexos pode ser definido através de um procedimento recursivo:

Algoritmo 2: Algoritmo de rotulação recursivo

Entrada: Imagem segmentada I com segmentos identificados por rótulo k

Saída: Imagem rotulada I com regiões **conexas** identificadas por rótulo k



É comum tais imagens apresentarem deformações e ruídos. Um exemplo de deformação é a presença de “buracos” ao longo de uma região segmentada. Esses espaços vazios provocam alterações em atributos que serão extraídos em um próximo passo, como a área da região. Ruídos são, por exemplo, regiões cujas áreas são ínfimas e em nada contribuem para um possível passo de extração de atributos, não sendo bons representantes das formas que compõem a imagem original. Esses erros devem ser eliminados e é esse o objetivo do passo de pós-processamento.

Para remover “buracos” de uma região R_i segmentada a partir de uma imagem original em escalas de cinza G onde a matriz binária R_i é construída a partir da segmentação de G calculada em S_G por

$$R_i = \begin{cases} 1 & \text{se } S_G(x, y) = i \\ 0 & \text{caso contrário} \end{cases} \quad (2.34)$$

aplica-se uma operação morfológica binária de dilatação.

Para remover as regiões com áreas não representativas de uma região R_i usa-se um limiar θ . Assim, regiões com áreas $\leq \theta$ são preenchidas com 0, eliminando-as de S_G . Essa operação pode ser definida através do **seguinte algoritmo**:

algoritmo 3

Algoritmo 3: Algoritmo de eliminação de áreas menores que um limiar θ

Entrada: Imagem rotulada I e limiar θ
Saída: Imagem rotulada I com regiões com áreas $\leq \theta$ filtradas

```

1 para cada região  $R_k$  rotulada com  $k$  em  $I$  faça
2   se  $area(R_k) \leq \theta$  então
3     para cada pixel  $p$  em  $R_k$  faça
4       |    $I(p) \leftarrow 0$ 
5     fim
6   fim
7 senão
8   para cada pixel  $p$  em  $R_k$  faça
9     |    $I(p) \leftarrow k$ 
10    fim
11  fim
12 fim

```



2.4 Extração de atributos

Após as etapas de preparação, segmentação e pós-processamento das imagens, estas estão prontas para a extração de atributos. Para caracterizar adequadamente uma imagem, certos aspectos devem ser considerados e são dependentes da natureza da imagem. No caso das pinturas, Penousal (10) sugere o uso de complexidade de imagens para estimar características estéticas. Lev Manovich (11) utiliza a análise de saturação de luz, contraste, brilho e demais atributos relacionados com a intensidade de cinza nas imagens. Essas abordagens encontram fundamento na teoria Gestalt que enumera um conjunto de “regras” de agrupamento **que estaria a visão humana propensa.**



Desta forma, um conjunto de descritores de imagens (ou atributos) é selecionado e aplicado experimentalmente ao conjunto de imagens já processadas. Embora os algoritmos de extração sejam eficientes em suas funções, não há a garantia de que sejam suficientes para a correta caracterização de uma imagem. Assim, o procedimento canônico é considerar um amplo conjunto de atributos e em seguida partir para a seleção daqueles que melhor atendam os objetivos

da análise (discutido na Seção 2.5). Esse conjunto deve portanto incluir atributos que irão, inicialmente, descrever uma larga gama de características como complexidade, textura e detalhes sobre a forma dos segmentos — e.g. área, perímetro, curvatura.

2.4.1 Atributos de complexidade

Para descrever a complexidade, medidas de entropia e energia para diferentes combinações de elementos da imagem são considerados. A noção de entropia é emprestada da teoria da informação. Nela, a premissa fundamental é que a geração de informação pode ser modelada como um processo probabilístico, sendo medido de forma que concorde com a intuição humana (12). Desta forma, um evento qualquer E pode ocorrer com probabilidade $P(E)$, contendo

$$I(E) = \log \frac{1}{P(E)} = -\log P(E) \quad (2.35)$$



sendo $I(E)$ a *unidade de informação* de E , denominada *auto-informação* de E . Isso equivale a dizer que a quantidade de informação atribuída ao evento E é inversamente proporcional à probabilidade de E ocorrer. Se $P(E) = 1$, ou seja, se E ocorre sempre, $I(E) = 0$ e nenhuma informação é atribuída. Caso E não ocorrer, ou $P(E) = 0$, tem-se $I(E) = \infty$. Quanto maior a probabilidade de E ocorrer, menor informação estará incorporada, pois esse é um resultado que espera-se ocorrer com grande frequência. Por outro lado, quanto menor a probabilidade de E ocorrer, mais informação estará incorporada, pois é um resultado menos provável de ocorrer. Se houverem J símbolos a_j associados a um evento E , a probabilidade da ocorrência de a_j é $P(a_j)$ e

$$\sum_{j=1}^J P(a_j) = 1 \quad (2.36)$$

e a auto-informação associada à ocorrência de um único símbolo a_j é $I(a_j) = -\log P(a_j)$. Para a

ocorrência de todos os símbolos, tem-se portanto:

$$-kP(a_1)\log P(a_1) - kP(a_2)\log P(a_2) - \dots - kP(a_J)\log P(a_J) \quad (2.37)$$

ou ainda:

$$-k \sum_{j=1}^J P(a_j)\log P(a_j). \quad (2.38)$$

Portanto, a informação média associada à ocorrência do evento E dados todos os a_j símbolos é:

$$H(E) = - \sum_{j=1}^J P(a_j)\log P(a_j) \quad (2.39)$$

onde $H(E)$ é denominada *incerteza* ou *entropia* de E .

Considerando a imagem em escala de cinza G (i.e. portanto um atributo da família de *medidas de campo*) onde cada pixel de coordenadas linha i e coluna j é representado por $f(i, j)$, é possível calcular sua entropia aplicando a Equação 2.39 à G :

$$H = \text{hist}(G) \quad (2.40)$$

$$P = \left\{ p_i = \frac{H_i}{\sum_i H} \right\} \quad (2.41)$$

$$S = - \sum_i p_i \log p_i, p_i \neq 0 \quad (2.42)$$

$$\mathcal{A}_0 = S \quad (2.43)$$

sendo *hist* o histograma dos valores dos níveis de cinza em G , P as probabilidades p_i de cada amostra i e S a entropia da imagem G . Esse portanto é o primeiro atributo \mathcal{A}_0 do conjunto de atributos \mathcal{A}_i .

A densidade espectral da imagem total, por sua vez, é dada pelo cálculo da *transformada de Fourier*. Vale aqui introduzir tal conceito para se chegar à definição de densidade espectral. Seja $f(x)$ uma função contínua de uma variável real x , a transformada de Fourier $\mathcal{F}\{f(x)\}$ é definida pela equação

$$\mathcal{F}\{f(x)\} = F(u) = \int_{-\infty}^{+\infty} f(x) \exp[-2i\pi ux] dx \quad (2.44)$$

com $i = \sqrt{-1}$. A partir de $F(u)$ pode-se obter a função original $f(x)$ através da *transformada inversa de Fourier*:

$$\mathcal{F}^{-1}\{F(u)\} = f(x) = \int_{-\infty}^{+\infty} F(u) \exp[2i\pi ux] du. \quad (2.45)$$

A transformada de Fourier de uma função real é geralmente complexa, e pode ser expressa por

$$F(u) = \Re(u) + \Im(u)i \quad (2.46)$$

onde $\Re(u)$ e $\Im(u)$ são os componentes real e imaginário de $F(u)$, respectivamente. É conveniente expressar a Equação 2.46 em sua forma exponencial:

$$F(u) = |F(u)| e^{\phi(u)i} \quad (2.47)$$

onde $|F(u)| = [\Re^2(u) + \Im^2(u)]^{\frac{1}{2}}$ é o *espectro de Fourier* e $\phi(u) = \tan^{-1} \left[\frac{\Im(u)}{\Re(u)} \right]$ o *ângulo de fase*.

Tomando-se o quadrado do espectro tem-se a *densidade espectral*, também chamada de *espectro de potência* de $f(x)$:

$$P(u) = |F(u)|^2 = \Re^2(u) + \Im^2(u). \quad (2.48)$$

Assim, densidade espectral da imagem G pode ser calculada com base na Equação 2.48:

$$E = |\Re(X(G))|^2 + |\Im(X(G))|^2 \quad (2.49)$$

onde X é a transformada de Fourier de G e a soma dos quadrados dos módulos da parte real e imaginária da de X corresponde à energia espectral procurada. Com base nessa medida, pode-se derivar as medidas de média e desvio padrão das energias nas linhas, colunas, centróides e da imagem total:



$$\mathcal{A}_1 = \mu = \frac{\sum E_{(i,*)}}{N} \text{ média das energias nas linhas } i \quad (2.50)$$

$$\mathcal{A}_2 = \sigma = \sqrt{\frac{\sum(E_{(i,*)} - \mu)^2}{N}} \text{ desvio padrão das energias nas linhas } i \quad (2.51)$$

$$\mathcal{A}_3 = \mu = \frac{\sum E_{(*,j)}}{N} \text{ média das energias nas colunas } j \quad (2.52)$$

$$\mathcal{A}_4 = \sigma = \sqrt{\frac{\sum(E_{(*,j)} - \mu)^2}{N}} \text{ desvio padrão das energias nas colunas } j \quad (2.53)$$

$$\mathcal{A}_5 = \frac{\sum iE_{(i,*)}}{N} \text{ centróide das energias nas linhas } i \quad (2.54)$$

$$\mathcal{A}_6 = \frac{\sum iE_{(*,j)}}{N} \text{ centróide das energias nas colunas } j \quad (2.55)$$

$$\mathcal{A}_7 = \mu = \frac{\sum E_{(i,j)}}{N} \text{ média das energias nas linhas } i \text{ e colunas } j \quad (2.56)$$

$$\mathcal{A}_8 = \sigma = \sqrt{\frac{\sum(E_{(i,j)} - \mu)^2}{N}} \text{ desvio padrão das energias nas linhas } i \text{ e colunas } j \quad (2.57)$$

Essas mesmas medidas (\mathcal{A}_{0-8}) podem ser aplicadas para cada um dos 3 canais de cor RGB da imagem I , obtendo assim o conjunto \mathcal{A}_{9-17} de atributos para o canal vermelho, conjunto de atributos \mathcal{A}_{18-26} para canal verde e \mathcal{A}_{27-35} para o canal azul.



2.4.2 Atributos de textura

Com o objetivo de analisar a textura das imagens, as 14 medidas propostas por Haralick (13) são de interesse. Elas são medidas ditas *estatísticas de segunda ordem* pois são calculadas a partir da matriz de co-ocorrência de níveis de cinza de uma dada imagem G . Uma das vantagens dessa abordagem é levar em conta a posição relativa de cada pixel da imagem. Cada uma das 14 medidas propostas procura caracterizar um aspecto de textura como contraste, homogeneidade e complexidade.

Dada uma imagem G com N_g níveis de cinza, sua matriz de co-ocorrência será uma matriz quadrada de dimensões $N_g \times N_g$ onde cada elemento $P_d(i, j)$ representa a quantidade de pixels da imagem G que possuem os níveis de cinza i e j , separados por uma distância numa certa direção e sentido, determinado por \vec{d} . Para uma imagem, considera-se apenas o posicionamento relativo entre cada pixel e seus vizinhos (i.e. pixels adjacentes) e portanto, \vec{d} poderá assumir apenas 8 direções possíveis considerando os possíveis ângulos $\alpha \in \{0^\circ, 45^\circ, 90^\circ, 135^\circ, 180^\circ, 225^\circ, 270^\circ, 315^\circ\}$ que tal vetor pode assumir dado que encontra-se “aprisionado” em uma malha (i.e. possui vizinhança-8). Como trata-se de uma matriz de co-ocorrência, esta é simétrica, e portanto esse conjunto possíveis α torna-se ainda menor. Por fim, dados os possíveis ângulos $\alpha \in \{0^\circ, 45^\circ, 90^\circ, 135^\circ\}$ e considerando os valores $\{-1, 0, 1\}$ como componentes x, y possíveis de \vec{d} , tem-se o cálculo dos 14 atributos de Haralick para cada uma das seguintes direções:

$$\alpha = 0^\circ \rightarrow \vec{d} = (1, 0) \quad (2.58)$$

$$\alpha = 45^\circ \rightarrow \vec{d} = (1, 1) \quad (2.59)$$

$$\alpha = 90^\circ \rightarrow \vec{d} = (0, 1) \quad (2.60)$$

$$\alpha = 135^\circ \rightarrow \vec{d} = (-1, 1) \quad (2.61)$$

a Tabela 2.17 lista os 14 atributos de Haralick, lembrando que estes são calculados para cada uma das 4 direções possíveis de \vec{d} . Assim, essas medidas definem os $14 \cdot 4 = 56$ atributos seguintes considerados nesse estudo, o conjunto \mathcal{A}_{36-56} .



2.4.3 Atributos de contorno e forma

Por fim, a forma de segmentos componentes de cada imagem são descritos. Tendo a matriz C resultante do processo de identificação de componentes conexos e por conseguinte as matrizes binárias C_i para cada componente conexo i , pode-se calcular o perímetro e área de cada componente:

A razão entre o perímetro e a área indica quanto uma forma se aproxima de um círculo, sendo assim outro atributo interessante:

Ainda, o número i de componentes conexos de cada matriz C também é um atributo importante, pois indica o quanto uma imagem é complexa em relação ao número de elementos que a compõe (e.g. as pinturas de Pollock possuem um número muito maior de componentes do que a maioria dos demais pintores).

A área da região convexa de uma forma fornece outro atributo. É calculado através do algoritmo *convex-hull*.



A razão entre a área da região convexa e da região original do componente indicam outra medida de circularidade, ou o quanto o componente possui uma forma rica em curvas acentuadas.

A curvatura é um atributo que mensura a mudança de direção “relativa” entre dois pontos conectados. Esse descritor tem uma motivação biológica interessante relacionada com o sistema de visão humano — e.g. o reconhecimento de objetos é relacionado à identificação de cantos e pontos de alta curvatura. Esses pontos possuem mais informação sobre a forma do objeto do que linhas retas ou curvas suaves. Dessa forma, a curvatura é um atributo interessante para uso

Tabela 2.17 – Os 14 atributos de textura de Haralick, considerando:

$$p(i, j) = P_d(i, j),$$

$$p_x(i) = \sum_{j=1}^{N_g} p(i, j),$$

$$p_y(j) = \sum_{i=1}^{N_g} p(i, j),$$

$$p_{x+y}(k = i + j) = \sum_{i=1}^{N_g} \sum_{j=1}^{N_g} p(i, j),$$



$$p_{x-y}(k = |i - j|) = \sum_{i=1}^{N_g} \sum_{j=1}^{N_g} p(i, j).$$

Ainda, $H(X)$ é a entropia de X e $\text{autoval}_2(X)$ é o segundo maior autovalor de X .

Uniformidade	$f_1 = \sum_{i=1}^{N_g} \sum_{j=1}^{N_g} p(i, j)^2$
Contraste	$f_2 = \sum_{i=1}^{N_g} \sum_{j=1}^{N_g} (i - j)^2 p(i, j)$
Correlação	$f_3 = \frac{\sum_{i=1}^{N_g} \sum_{j=1}^{N_g} i j p(i, j) - \mu_x \mu_y}{\sigma_x \sigma_y}$
Variância	$f_4 = \sum_{i=1}^{N_g} \sum_{j=1}^{N_g} (i - \mu)^2 p(i, j)$
Momento inverso da diferença	$f_5 = \sum_{i=1}^{N_g} \sum_{j=1}^{N_g} \frac{1}{1+(i-j)^2} p(i, j)$
Média da soma	$f_6 = \sum_{k=2}^{2N_g} k p_{x+y}(k)$
Variância da soma	$f_7 = \sum_{k=2}^{2N_g} (k - f_6)^2 p_{x+y}(k)$
Entropia da soma	$f_8 = - \sum_{k=2}^{2N_g} p_{x+y}(k) \log(p_{x+y}(k))$
Entropia	$f_9 = - \sum_{i=1}^{N_g} \sum_{j=1}^{N_g} p(i, j) \log(p(i, j))$
Variância da diferença	$f_{10} = \text{var}(p_{x-y})$
Entropia da diferença	$f_{11} = - \sum_{k=0}^{N_g-1} p_{x-y}(k) \log(p_{x-y}(k))$
Medida de correlação (1)	$f_{12} = \frac{f_9 + \sum_{i=1}^{N_g} \sum_{j=1}^{N_g} p(i, j) \log[p_x(i)p_y(j)]}{\max\{H(p_x(i)), H(p_y(j))\}}$
Medida de correlação (2)	$f_{13} = \sqrt{1 - \exp\left[-2\left(\left(-\sum_{i=1}^{N_g} \sum_{j=1}^{N_g} p_x(i)p_y(j) \log(p_x(i)p_y(j))\right) - f_9\right)\right]}$
Coeficiente de correlação máxima	$f_{14} = \sqrt{\text{autoval}_2\left(-\sum_{k=1}^{N_g} \frac{p(i,k)p(j,k)}{p_x(i)p_y(j)}\right)}$

na caracterização das pinturas consideradas nesse estudo. A curvatura de uma forma é calculada usando os seguintes descritores de Fourier and esquematizada na Figura 2.18. (??) A curvatura $k(t)$ de uma curva paramétrica $c(t) = (x(t), y(t))$ é definida como:

$$k(t) = \frac{\dot{x}(t)\ddot{y}(t) - \dot{y}(t)\ddot{x}(t)}{(\dot{x}(t)^2 + \dot{y}(t)^2)^{\frac{3}{2}}} \quad (2.62)$$

onde $\dot{x}(t)$, $\dot{y}(t)$, $\ddot{x}(t)$ e $\ddot{y}(t)$ são respectivamente as derivadas primeira e segunda de $x(t)$ e $y(t)$. Essas derivadas são obtidas através da transformada de Fourier e do teorema da convolução:

$$\dot{x} = \mathfrak{I}^{-1}(2\pi i\omega X(\omega)) \quad (2.63)$$

$$\dot{y} = \mathfrak{I}^{-1}(2\pi i\omega Y(\omega)) \quad (2.64)$$

$$\ddot{x} = \mathfrak{I}^{-1}(-(2\pi\omega)^2 X(\omega)) \quad (2.65)$$

$$\ddot{y} = \mathfrak{I}^{-1}(-(2\pi\omega)^2 Y(\omega)) \quad (2.66)$$

onde \mathfrak{I}^{-1} é a transformada inversa de Fourier, X e Y a transformada de Fourier de x e y respectivamente, ω é o domínio de frequência e i a unidade imaginária.

Os seguintes atributos são calculados a partir dos dados fornecidos pela curvatura: *média* e *desvio padrão* dos dados, o *número de picos* de curvatura e a *distância* (geométrica e em pixels) entre os picos. É importante notar que um *pico* é definido como um ponto de alta curvatura. Um ponto a é considerado um pico se sua curvatura $k(a)$ satisfazer os seguintes critérios:

$$k(a) > k(a-1) \quad (2.67)$$

$$k(a) > k(a+1) \quad (2.68)$$

$$k(a) > Limiar \quad (2.69)$$

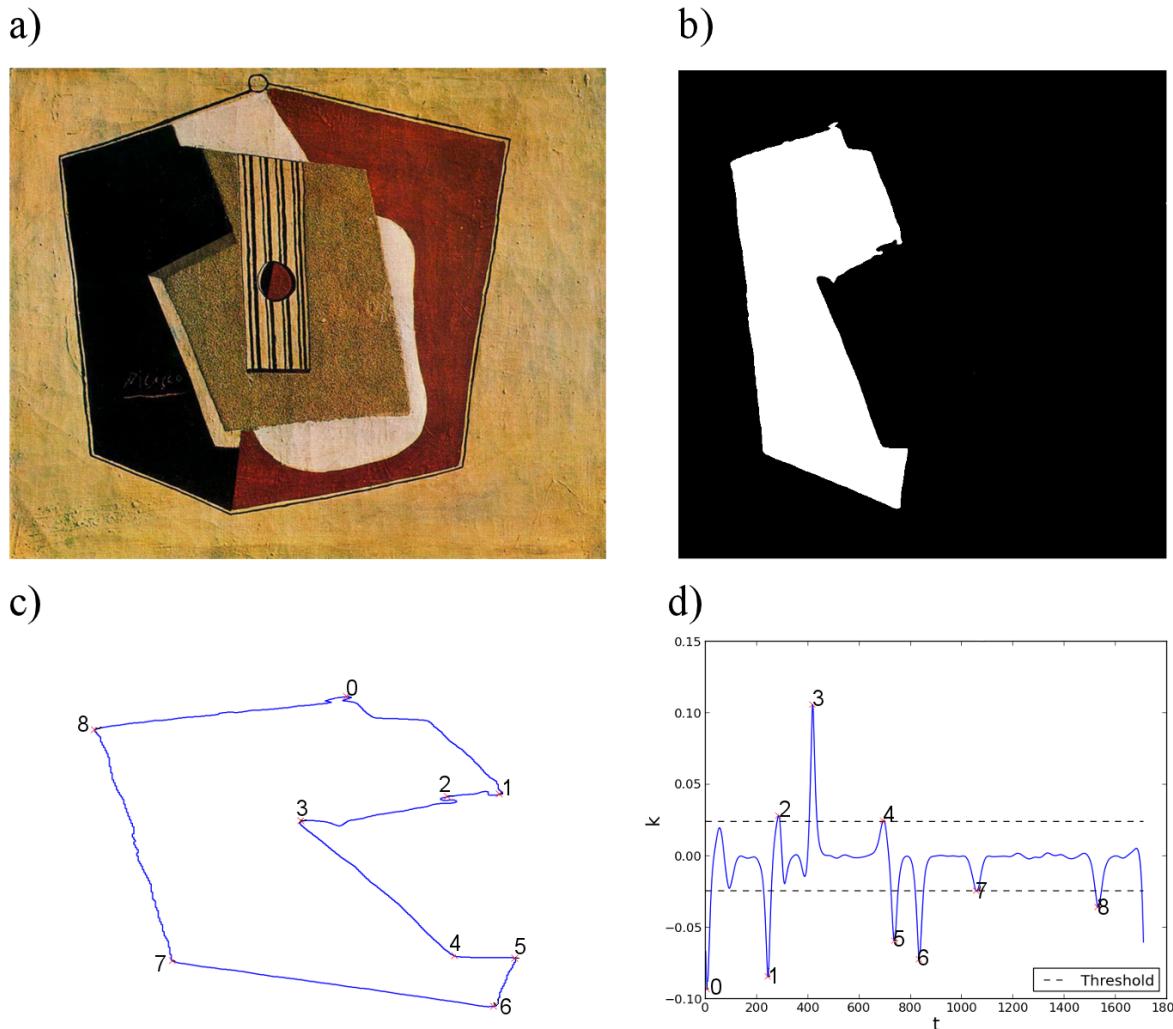


Figura 2.18 – a) Imagina da pintura original. b) Uma região segmentada da pintura. c) A curvatura extraída a partir da região segmentada. d) A curva paramétrica $k(t)$ dado um limiar em particular, com os picos em destaque.

A simples contagem de componentes conexos da imagem fornece um outro atributo, também considerado.

2.5 Redução de dimensionalidade e classificação

Na maioria das rotinas de análises de dados, a quantidade de atributos leva à necessidade de selecionar quais atributos são mais relevantes ao objetivo previsto (e.g. garantir máximo agru-

pamento das amostras em certas classes) e reduzir a dimensionalidade das amostras a um ponto que se consiga visualizá-las. Essas necessidades estão presentes também neste estudo e alguns métodos foram selecionados para supri-las.

Existe um grande número de métodos para a identificação dos melhores atributos, aqui dois deles são descritos: matriz de espalhamento e LDA (Linear Discriminant Analysis). Esse último também pode ser utilizado para a redução da dimensão da matriz de entrada, e é portanto descrito juntamente com outro método para redução de dimensionalidade, o PCA (Principal Components Analysis). Ainda, o LDA quando usado em conjunto com distribuição Gaussiana e regra de Bayes, torna-se um classificador. Detalhes sobre esse algoritmo também são apresentados.

O método conhecido como matrizes de espalhamento procura encontrar a melhor razão de Fisher, que é um indicador quantitativo de quanto duas ou mais classes estão apresentando menor covariância interna (agrupamento) e maior covariância entre as classes (dispersão). Ou seja, busca-se a projeção que mais separa as classes umas das outras. (14)

Para todas as N amostras (no caso, pinturas), considerando todas as possíveis combinações de pares de atributos $F_{N,a}$ e $F_{N,b}$, as matrizes de espalhamento S_{inter} e S_{intra} são calculadas com K classes (no caso, $K = 12$ para 12 pintores), uma classe C_i para cada pintor:

$$S_{intra} = \sum_{i=1}^K S_i \quad (2.70)$$

$$S_{inter} = \sum_{i=1}^K N_i (\vec{\mu}_i - \vec{M})(\vec{\mu}_i - \vec{M})^T \quad (2.71)$$

sendo N_p o número de amostras para a classe C_p e a matriz de espalhamento para a classe C_i definida como

$$S_i = \sum_{i \in C_i} (\vec{f}_i - \vec{\mu}_i)(\vec{f}_i - \vec{\mu}_i)^T \quad (2.72)$$

onde \vec{f}_i é uma amostra da matriz de atributos F cujas linhas e colunas correspondem às amostras e seus atributos $F = [\leftarrow f_i^T \rightarrow]$ e $\vec{\mu}_p$ e \vec{M} são os vetores de média dos atributos para as amostras da classe C_p e para todas as amostras, respectivamente:

$$\vec{\mu}_p = \frac{1}{N_p} \sum_{i \in C_p} \vec{f}_i \quad (2.73)$$

$$\vec{M} = \frac{1}{N} \sum_{i=1}^N \vec{f}_i \quad (2.74)$$

O traço da razão entre as matrizes intra- e inter-classe resulta na razão de Fisher, a constante:

$$\alpha = \text{tr}(S_{inter} S_{intra}^{-1}) \quad (2.75)$$

Se ao invés de calcular o traço for calculado os autovalores e autovetores da razão das matrizes, tem-se a projeção que melhor separa as classes, ou seja, o LDA.



$$\alpha = \text{eig}(S_{inter} S_{intra}^{-1}) \quad (2.76)$$

Ao tomar os autovetores dos maiores autovalores, em módulo, tem-se tal projeção. É por isso que o LDA pode ser concebido como um método de redução de dimensão, reduzindo os N atributos a um número de atributos $r < N$ (geralmente $r \leq 3$ para possibilitar a projeção em 2 ou 3 dimensões visíveis) que melhor separam as classes.

Convém aqui abordar um outro método de redução de dimensionalidade, o PCA, que lembra o LDA. No PCA, se está interessado em calcular os autovalores e autovetores que mais correla-

cionam os dados em questão. Para isso, toma-se a matriz de atributos F e calcula-se sua matriz de covariância ([equivalente também à correlação de Pearson](#)), que nada mais é que a operação de covariância aplicada a cada dimensão i de uma matriz X qualquer. Dadas as relações

$$\text{média}(X) = m_x = \mu_x = \bar{x} = \frac{\sum_{i=1}^n X_i}{n} \quad (2.77)$$

$$\text{variância}(X) = var_x = \sigma_x^2 = s_x^2 = \frac{\sum_{i=1}^n (X_i - \text{mean})^2}{n} \quad (2.78)$$



$$\text{desvio padrão}(X) = std(X) = \sigma_x = s_x = \sqrt{\frac{\sum_{i=1}^n (X_i - \text{mean})^2}{n}} \quad (2.79)$$

$$\text{covariância}(X, Y) = cov(X, Y) = c_{X,Y} = \frac{\sum_{i=1}^n (X_i - \mu_x)(Y_i - \mu_y)}{n} \quad (2.80)$$

a matriz de covariância $C^{n \times n}(X)$ dadas n dimensões de X é dada por

$$C^{n \times n}(X) = \begin{pmatrix} cov(x_1, x_1) & cov(x_1, x_2) & \dots & cov(x_1, x_n) \\ cov(x_2, x_1) & cov(x_2, x_2) & \dots & cov(x_2, x_n) \\ \vdots & \vdots & \vdots & \vdots \\ cov(x_n, x_1) & cov(x_n, x_2) & \dots & cov(x_n, x_n) \end{pmatrix} \quad (2.81)$$

onde x_i é a i -ésima dimensão da matriz X .

Novamente, calculando os autovalores (e seus respectivos autovetores) da matriz de covariância $C^{n \times n}(F)$ e tomando os autovetores dos maiores autovalores, em módulo, tem-se os *componentes principais*

$$V = \begin{pmatrix} \text{autovetor}_0 & \text{autovetor}_1 & \dots & \text{autovetor}_n \end{pmatrix} \quad (2.82)$$

que formarão uma base para a projeção dos dados com maior correlação possível através da multiplicação da matriz original F com os componentes principais V , ambos transpostos:

$$D = V^T \times F^T \quad (2.83)$$

ou seja, D é a base que mais “reúne características” dos demais atributos. Tomando-se apenas estes $r < N$ atributos, tem-se portanto uma redução na dimensão. É importante notar que os autovalores indicam o quanto cada atributo contribui para a correlação. Portanto, é sempre interessante notar se os r autovalores em módulo somam cerca de **70% do total**, indicando assim serem suficientes para representar os N atributos originais.



3 *Desenvolvimentos e Resultados*

3.1 Pintores escolhidos

Para a análise foram selecionados 12 pintores de grande relevância histórica. Esse grupo abrange os estilos ou movimentos artísticos que vão do Barroco ao Moderno, onde 6 dos pintores representam um dos movimentos, enquanto os 6 restantes, representam o outro. O grupo é mostrado na Tabela 3.1 juntamente com seu estilo artístico mais representativo. Aqui vale uma nota. É de conhecimento que pintores como Picasso demonstraram mais de um estilo durante a vida. Porém, para tal análise, apenas o estilo mais marcante (e pelo qual melhor se conhece e define o artista) foi escolhido. No caso de Picasso, apenas pinturas de seu período Cubista foram escolhidas, com o objetivo de representar tal movimento.

3.2 Corpus de pinturas

Para cada pintor, foram consideradas 20 imagens de suas pinturas, obtidas de arquivos em domínio público, organizados pela Wikipedia. Uma amostra dessas pinturas e seu respectivo ano de criação está listada na Tabela 3.2. Todas as 240 pinturas são apresentadas em forma de galeria no Apêndice B. Os arquivos de imagem das pinturas assim como o código-fonte que implementa esta análise encontra-se disponível online em <http://github.com/automata/analise-pintores> e no Apêndice A.

Tabela 3.1 – Pintores escolhidos para a análise, exibidos em ordem cronológica, juntamente com o estilo artístico que melhor representa. Divididos em dois grupos: 6 pintores Barrocos e 6 pintores Modernos.

Artistas	Estilos/Movimentos mais marcantes
Caravaggio	Barroco, Renassença
Frans Hals	Barroco, Idade de ouro Holandesa
Nicolas Poussin	Barroco, Classicismo
Diego Velázquez	Barroco
Rembrandt	Barroco, Idade de ouro Holandesa, Realismo
Johannes Vermeer	Barroco, Idade de ouro Holandesa
Vincent van Gogh	Pós-Impressionismo
Wassily Kandinsky	Expressionismo, Arte abstrata
Henri Matisse	Modernismo, Impressionismo
Pablo Picasso	Cubismo
Joan Miró	Surrealismo, Dada
Jackson Pollock	Expressionismo abstrato

3.3 Análise de imagens para extração de atributos



Todas as 240 imagens foram redimensionadas e cortadas em janelas de 800x800 pixels, considerando esta janela posicionada nas mesmas coordenadas em ambas imagens, preservando o mesmo aspecto em todas as pinturas. Em seguida, as imagens foram pré-processadas aplicando-se equalização por histograma e filtro de médias com janelamento de raio 3.

Algoritmos de extração de características foram aplicados a versões coloridas, em escala de cinza e preto-e-branco das imagens, conforme necessário (e.g. para o algoritmo convex-hull, uma imagem binária (preto-e-branco) foi utilizada, enquanto para o algoritmo de textura de Haralick, uma imagem em escala de cinza foi utilizada, já a segmentação SLIC utilizou a versão RGB de cada imagem).

Com o objetivo de mensurar características de regiões das pinturas, métodos de segmentação foram utilizados, a saber: Watershed, SLIC e Felzenswald. Após experimentos (Figura 3.3), preferiu-se o método de segmentação SLIC, por apresentar melhor separação das regiões de

Tabela 3.2 – Algumas das 240 pinturas juntamente com a data de sua criação.

Pintores	Título da obra	Ano de criação
Caravaggio	Músicos	1595
	Judite decapitando Holofernes	1598
	Davi com a cabeça de Golias	1610
Frans Hals	Retrato de uma mulher desconhecida	1618/20
	Retrato de Paulus van Beresteyn	1620s
	Retrato de Stephanus Geeraerdt	1648/50
Nicolas Poussin	Vênus e Adônis	1624
	Céfalo e Aurora	1627
	Ácis e Galateia	1629
Diego Velázquez	Três músicos	1617/18
	O almoço	1618
	La mulatto	1620
Rembrandt	O vendedor de óculos (visão)	1624/25
	Os três cantores (audição)	1624/25
	Balaão e o burro	1626
Johannes Vermeer	A leiteira	1658
	O astrônomo	1668
	Garota com brincos de pérola	1665
Vincent van Gogh	Noite estrelada sobre o Ródano	1888
	A noite estrelada	1889
	Auto-retrato com chapéu de palha	1887/88
Wassily Kandinsky	Em branco II	1923
	Composição X	1939
	Pontos	1920
Henri Matisse	Auto-retrato em uma camiseta listrada	1906
	Retrato de Madame Matisse	1905
	A dança (primeira versão)	1909
Pablo Picasso	Les Demoiselles d'Avignon	1907
	Guernica	1937
	Dora Maar au Chat	1941
Joan Miró	O fazendeiro	1921/22
	O campo lavrado	1923/24
	Bleu II	1961
Jackson Pollock	No. 5	1948
	Ritmo de outono	1950
	Pólos azuis	1952

cada pintura. Parâmetros da segmentação SLIC foram ajustados de forma a melhor segmentar as regiões: como é possível notar no detalhe *e*) da Figura 3.3, outros valores que os escolhidos para parametrização do método revelaram resultados que não contribuiriam para uma boa segmentação.

Tendo-se as regiões separadas, estas foram agrupadas em componentes conexos, ou seja, em regiões conectadas e independentes umas das outras. Com tais regiões agrupadas, partiu-se para o cálculo de curvatura de cada região.

Todo o processo está representado esquematicamente na Figura 3.4 e abrange todos os passos, do processamento das imagens das pinturas até o cálculo de medidas de dialética, oposição e inovação, discutidas em detalhes nos próximos capítulos.

3.4 Seleção de atributos

Para selecionar os atributos mais relevantes, neste caso, os atributos que separassem melhor os grupos de pinturas – em outras palavras, que garantissem menor covariância interna em cada classe e maior covariância entre as classes – uma medida de dispersão é aplicada usando as matrizes esparsas discutidas na Seção 2.5.

Calculando α através da Eq. 2.76 para todos os possíveis pares de atributos $F_{N,a}$ e $F_{N,b}$ **doss** $N = 93$ atributos e ordenando os resultados por α , é possível selecionar todos os atributos mais relevantes para a classificação: pares com maiores valores de α apresentam melhor dispersão inter-classe e agrupamento intra-classe do que pares com menores valores. Como visto na Tabela 3.5 (e nas Figuras 3.6 e 3.7), os atributos μ *dos picos de curvatura* e μ *do número de segmentos* possuem maior valor de α e foram selecionados para a análise das medidas de oposição, inovação e dialética — ambos atributos se mostraram predominantes mesmo na projeção por LDA, discutida na Seção 3.5.1. É interessante notar a natureza dos atributos selecionados: o

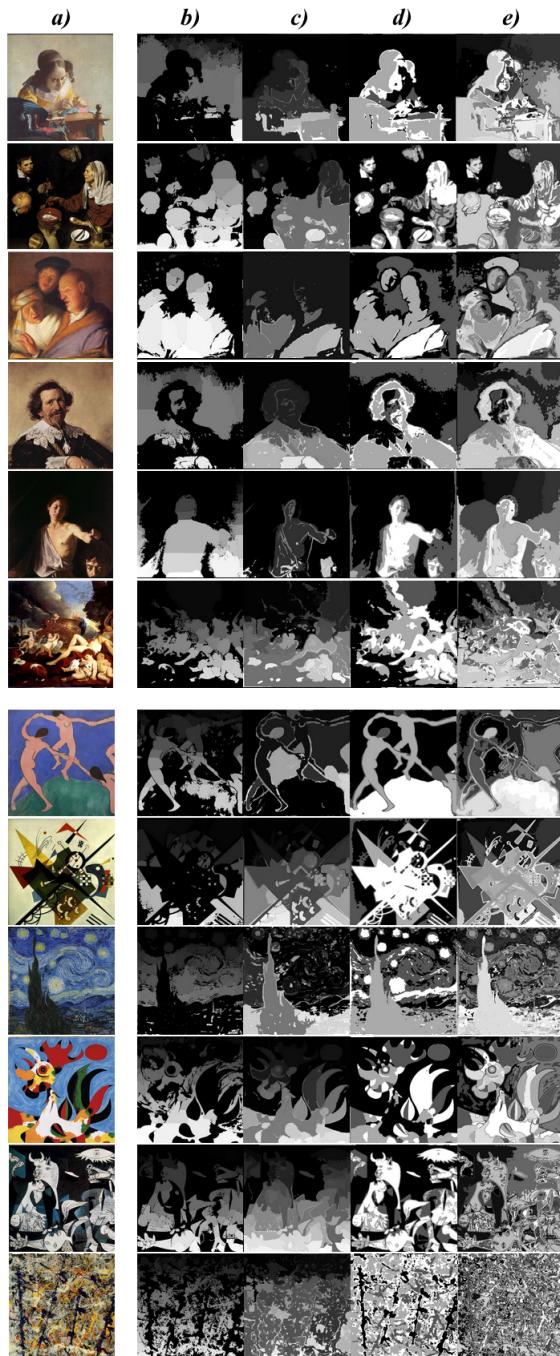


Figura 3.3 – Experimentos realizados para segmentação de pinturas. a) a imagem original, b) segmentação por Watershed, c) Felzenswald, d) SLIC e e) SLIC com parâmetros X. O método SLIC foi escolhido por apresentar, visualmente, melhor separação dos segmentos, e os parâmetros escolhidos contribuíram para a segmentação apresentada.

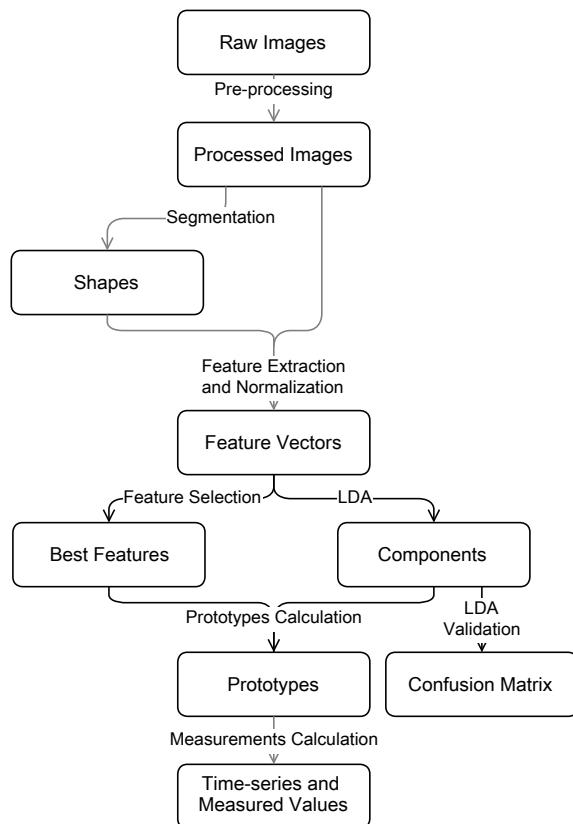


Figura 3.4 – Um sumário com todos os passos tomados, desde o processamento das imagens das pinturas até a extração de características, assim como a obtenção da série temporal onde foram calculadas as medidas de oposição, inovação e dialética.

número de segmentos em cada pintura e os picos de curvatura são características proeminentes para a classificação das pinturas, melhores até mesmo que os atributos de textura de Haralick e de complexidade de imagens (entropia). Outros atributos que apresentaram também valores altos de α — como μ da área de *convex-hull*, do perímetro dos segmento e da área do segmento, e circularidade — também são relacionadas com características de forma. Ambos atributos apresentaram projeções e propriedades de agrupamento similares às da Figura 3.6 como mostrado na Figura 3.8.

Tabela 3.5 – Pares de atributos $F_{N,a}$ e $F_{N,b}$ ordenados por α . Pares com valores maiores de α mostram maior dispersão inter-classe enquanto menor dispersão intra-classe (maior agrupamento). O melhor par de atributos: μ dos picos de curvatura e μ do número de segmentos são selecionados para a análise e cálculo das medidas.

Par	Atributo a	Atributo b	α
1	μ do número de picos	μ do número de segmentos	42.445
2	μ do número de segmentos	μ da área de convex-hull	37.406
3	μ do perímetro do segmento	μ do número de segmentos	36.703
4	μ da área do segmento	μ do número de segmentos	36.214
5	μ do número de segmentos	μ área convexa / área total	34.885
6	μ de circularidade (Per. ² /Area)	μ do número de segmentos	33.540
7	μ da energia das linhas (canal verde)	μ do número de segmentos	32.954
8	μ da energia das linhas e colunas (canal verde)	μ do número de segmentos	32.954
9	σ da energia das linhas (canal verde)	μ do número de segmentos	32.932
10	σ da energia das linhas e colunas (canal verde)	μ do número de segmentos	32.906
11	μ de entropia local (janela de dimensão 5)	μ do número de segmentos	32.898
12	Entropia (Haralick adj. 4)	μ do número de segmentos	32.898
13	Entropia (Haralick adj. 3)	μ do número de segmentos	32.883
14	Entropia (Haralick adj. 1)	μ do número de segmentos	32.874
15	Entropia (Haralick adj. 2)	μ do número de segmentos	32.869
16	μ da energia das linhas (canal vermelho)	μ do número de segmentos	32.865

3.5 Classificação e medidas de dialética, oposição e inovação

O espaço criativo projetado considerando todas as pinturas “representadas” por \vec{p}_i é apresentado na Figura 3.6. É possível notar grupos bem definidos com menor sobreposição, principalmente quando considerando as pinturas Modernas. A série temporal formada pelos protótipos \vec{p}_i para cada pintor no espaço projetado é visto na Figura 3.7, facilitando a visualização da evolução da série.

Detalhes interessantes surgem dessa projeção. A mais impressionante é a grande distância entre Pollock e os demais pintores: isso se deve ao grande número de segmentos presentes nas pinturas de Pollock quando comparado aos demais artistas (o eixo-y corresponde à projeção desse atributo: μ do número de segmentos). De qualquer forma, ambos eixos x (número de picos da curvatura) e y são relevantes para separar os movimentos Barroco e Moderno. É possível notar uma separação entre os pintores Barrocos e Modernos onde as pinturas Barrocas

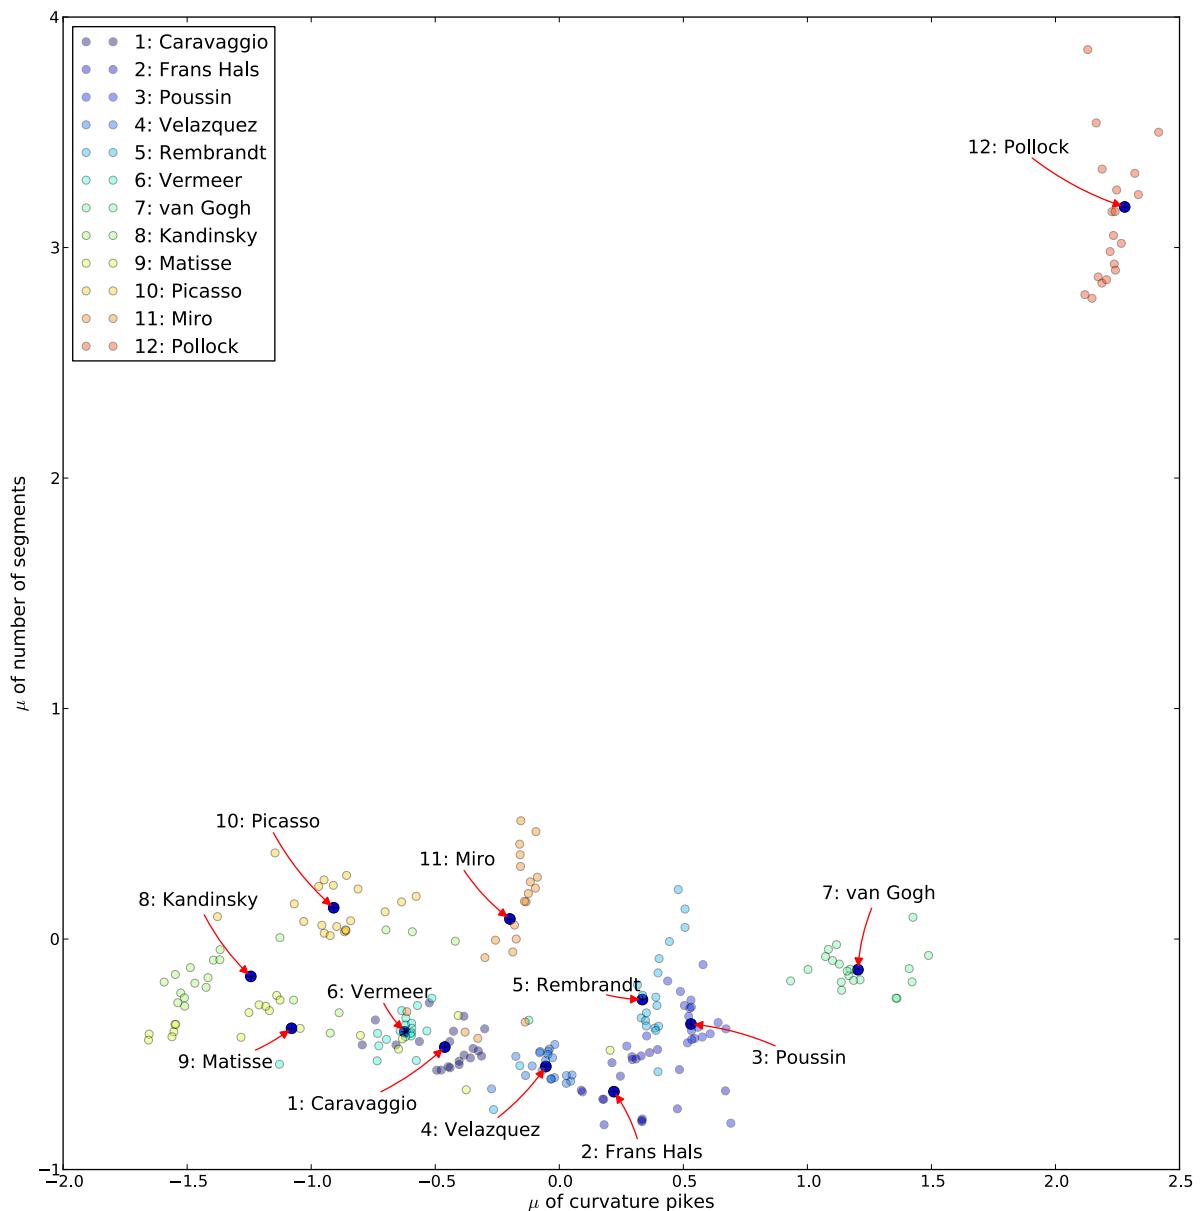


Figura 3.6 – Projeção do espaço criativo considerando o melhor par de atributos μ de picos da curvatura e μ do número de segmentos.

mostram-se arranjadas em um grupo com grande sobreposição enquanto as amostras Modernas estão agrupadas e separadas uma das outras, ao mesmo tempo que cobrem uma região maior do espaço criativo do que as Barrocas. Esse fato é confirmado pela história da Arte onde os pintores Modernos tentando experimentar novos materiais e técnicas (como revisado na Seção X)

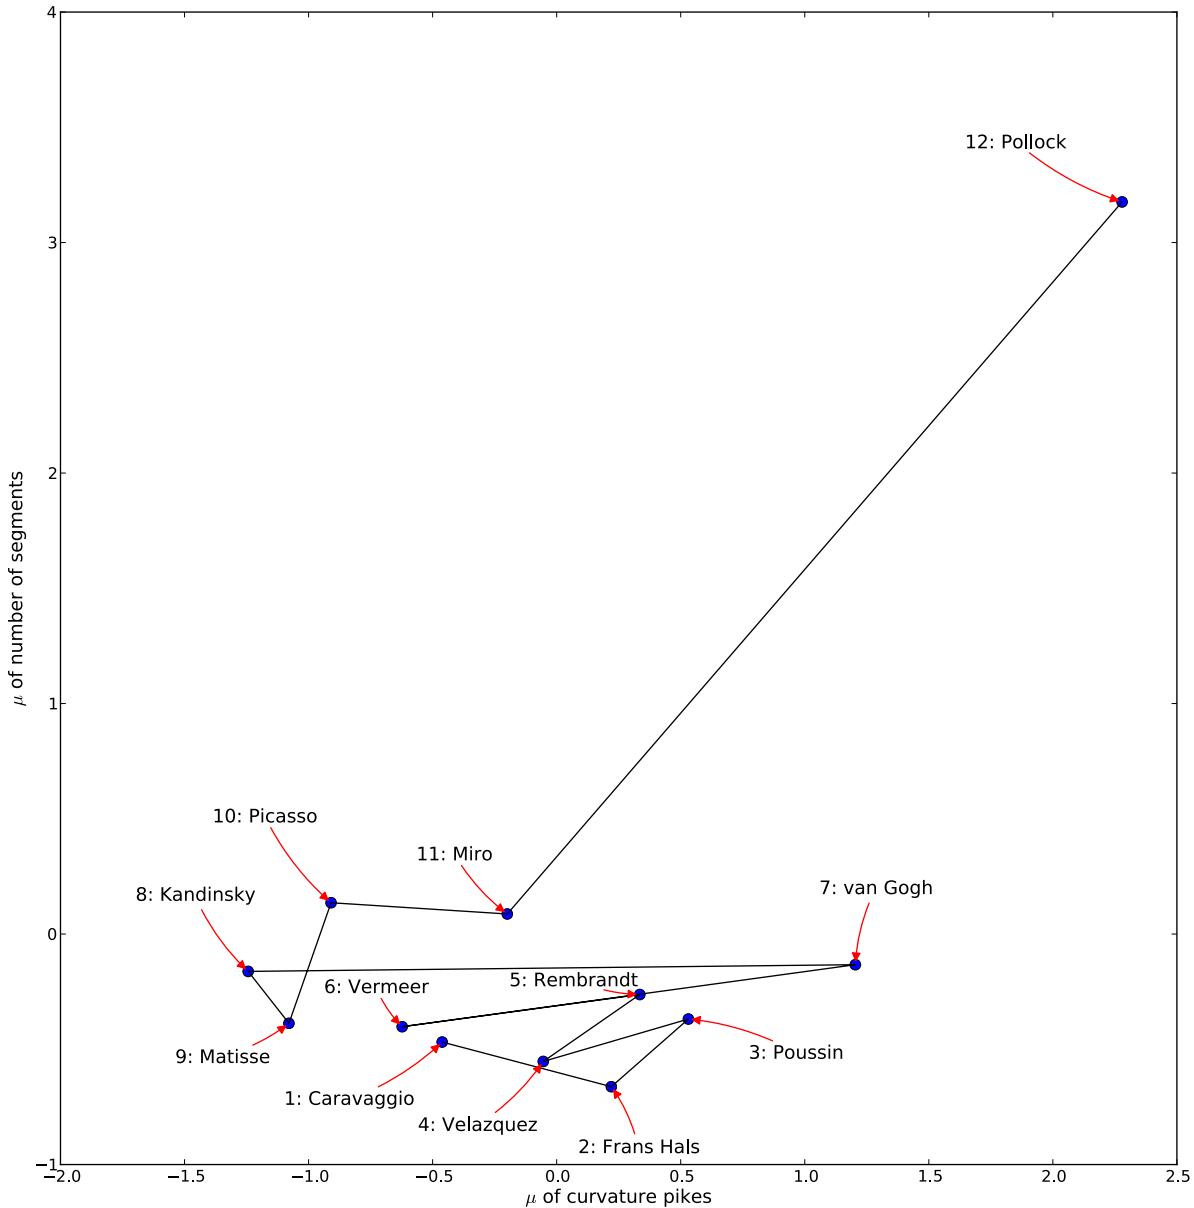


Figura 3.7 – Série temporal considerando o melhor par de atributos μ de picos da curvatura e μ do número de segmentos.

para representar suas percepções da natureza enquanto os Barrocos tendem a utilizar métodos tradicionais de suas respectivas escolas. O mesmo fato pode ser observado quando se analisa a série temporal, onde a diferença entre os movimentos artísticos é clara: enquanto os Barrocos preferem retornar uns aos outros em um padrão cíclico, há um deslocamento abrupto em Van

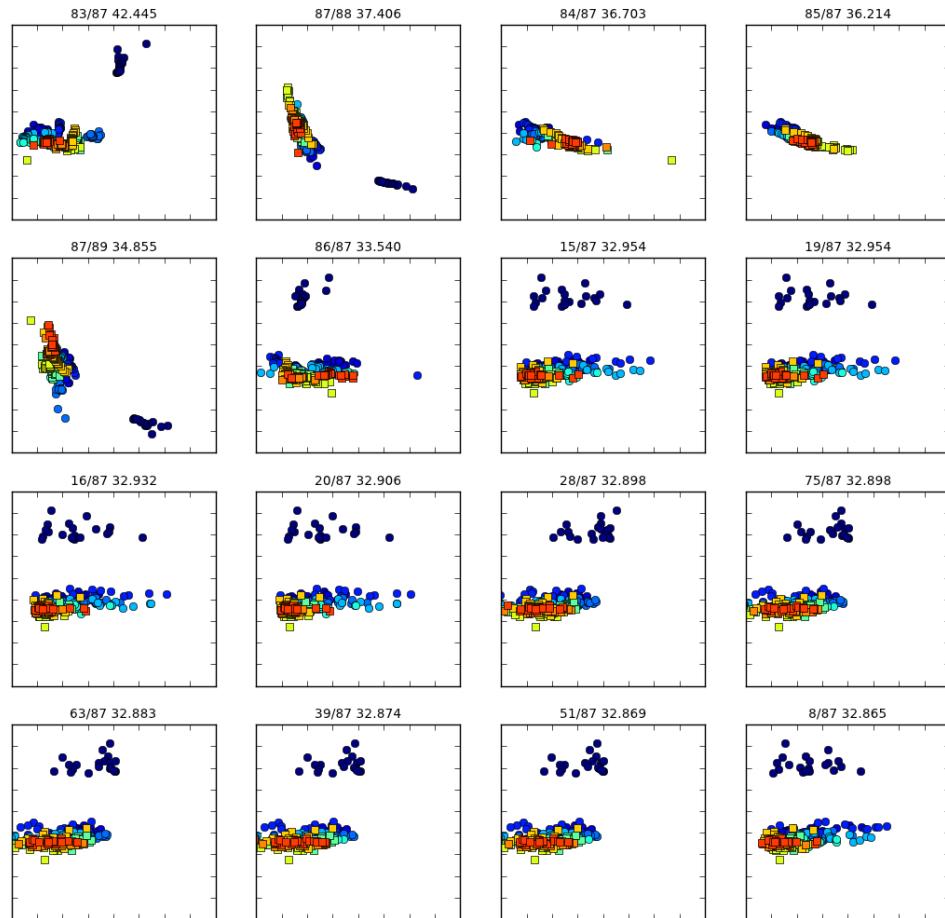


Figura 3.8 – Matrizes esparsas para cada i-ézimo par de atributos listado na Tabela 3.5 com os maiores valores para α . A primeira projeção (par 1) foi utilizado nesse estudo.

Gogh — o primeiro pintor Moderno considerado nesse estudo — que o separa dos primeiros pintores e “quebra” o padrão antes cíclico. Van Gogh, embora localizado próximo aos pintores Barrocos e no extremo oposto da maioria dos pintores Modernos, estabelece o período Moderno e depois dele os deslocamentos de um vetor a outro continuam a evoluir até alcançar seu ápice, em Pollock, não mostrando mais padrões cílicos.

Quando ambos grupos (Barroco e Moderno) são analisados individualmente, é possível notar

outros detalhes de interesse. Primeiramente no Barroco, a trajetória desenhada de Caravaggio e Frans Hals até Poussin estabelece um caminho que termina com um movimento de oposição (e de retorno) de Velázquez, que retorna a Caravaggio. Isso também é notado no movimento de retorno à Cavaraggio apresentado por Vermeer — alguns críticos (15) afirmam que pintores como Vermeer nem teriam existido se não fosse a influência de Caravaggio: os agrupamentos de pinturas de Vermeer e Caravaggio apresentam a maior sobreposição dentre todos os agrupamentos presentes no *espaço criativo*. Isso pode ser atribuído à influência do mestre do “chiaroscuro” em ambos pintores, principalmente em Velázquez que foi reconhecidamente um estudioso das pinturas de Caravaggio (5). Ambos fatos são confirmados pelos histogramas do nível médio de cinza das pinturas mostrado na Figura 3.9. Os histogramas de Velázquez e Vermeer são os que mais se aproximam do histograma de Caravaggio quando comparados aos outros pintores barrocos.



Em sumário, o grupo barroco é fortemente inter-relacionado quando comparado com os modernos onde há **auxênciâ** de sobreposições. Novamente, isso sugere uma distinção centrada no estilo de cada artista da era moderna enquanto os pintores barrocos tendem a compartilhar técnicas e características estéticas. Isso é também confirmado quando se comparam os histogramas dos pintores modernos na Figura 3.10: há baixa similaridade entre os pintores modernos considerados, contrastando diretamente com o que foi observado para os pintores **modernos** na barrocos

Figura 3.9.

Quando são consideradas as medidas de oposição e inovação, outros resultados interessantes apresentam-se, como mostrado na Tabela 3.11 e Figura 3.12.

Claramente, o maior valor de oposição é atribuído a Rembrandt. Esse fato é curioso por **sí**, considerando que o mestre Holandês é reconhecido como um “contraponto” ao movimento Barroco, mesmo tendo sido parte desse movimento (5). Vermeer também apresenta forte oposição e a natureza de suas pinturas (e.g. interiores domésticos, uso de cores claras) pode explicar

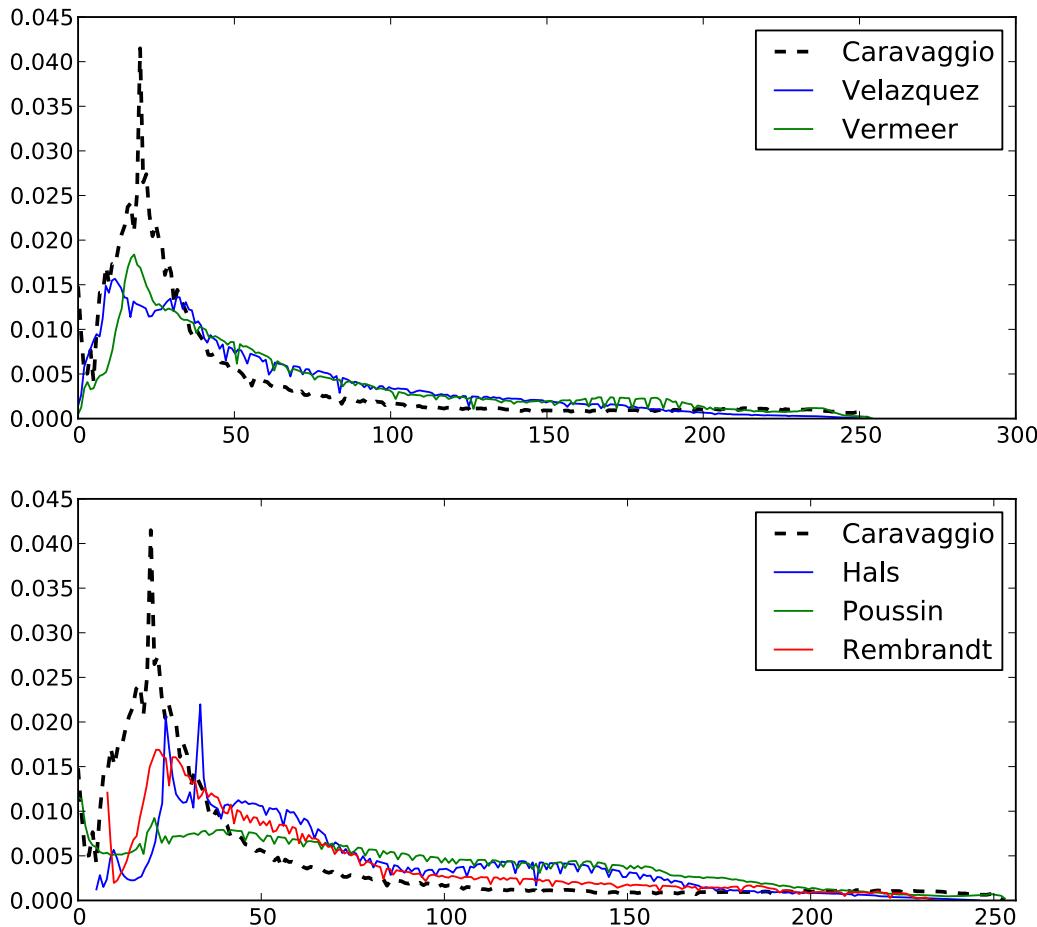


Figura 3.9 – Histogramas dos níveis médios de cinza para todos os pintores barrocos. Vermeer e Velázquez mostram maior similaridade com Caravaggio do que os outros pintores barrocos: a proximidade em contraste encontra fundamento na história, tendo sido ambos pintores influenciados por Caravaggio.

esse fenômeno. Um padrão torna-se visível no começo de ambos movimentos Barroco e Moderno: decremento contínuo nos valores de oposição, seguido de incremento. Da mesma forma, um platô com alta oposição é observado nos pintores Barrocos. Esse platô ocorre exatamente na transição de um movimento artístico ao outro, diminuindo gradualmente enquanto os artistas modernos começam a se estabelecer na história. Esse decremento nos valores de oposição reflete

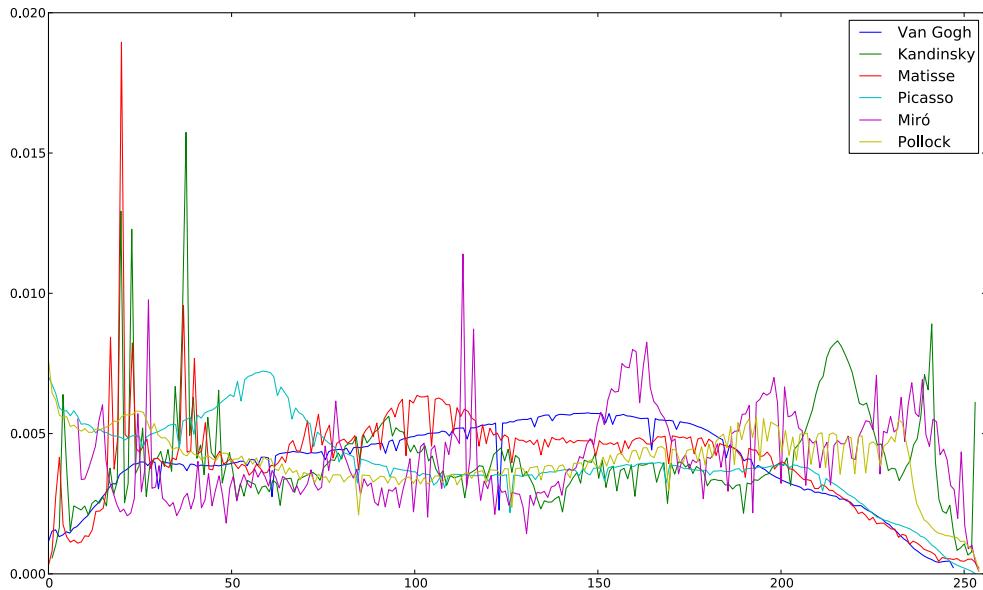


Figura 3.10 – Histogramas nos níveis médios de cinza para os pintores modernos. Há baixa similaridade entre os pintores modernos, diferente do que ocorre para os pintores barrocos.

um aspecto de baixa oposição entre os primeiros artistas Barrocos enquanto há o incremento da oposição presente nos deslocamentos que precedem o movimento Moderno, embora os valores de inovação se mantém oscilando mas sempre aumentando durante toda a série temporal. Isso caracteriza novamente uma cena comum nas Artes, principalmente nos Modernistas, onde cada um tente definir seu próprio estilo enquanto a história se prepara para ingressar em um novo movimento. Em resumo, no que se pode falar dos índices de **oposico** e inovação, o *espaço criativo* é marcado por aumento constante de inovação, grande oposição em momentos específicos de sua evolução (a transição entre o Barroco e Moderno) e menor oposição entre artistas de um mesmo movimento, principalmente no Barroco.

No que tange a contra-dialética, mostrada na Tabela 3.13 e Figura 3.14, há um paralelo com as curvas de oposição e inovação. A contra-dialética reforça fatos já observados: pintores do mesmo movimento mostram inicialmente um decremento em seus valores, seguido por incre-

Tabela 3.11 – Índice de oposição $W_{i,j}$ e inovação $s_{i,j}$ para cada um dos 11 deslocamentos de um pintor a outro.

Deslocamento	$W_{i,j}$	$s_{i,j}$
Caravaggio → Frans Hals	1.	0.
Frans Hals → Poussin	0.111	0.425
Poussin → Velázquez	0.621	0.004
Velázquez → Rembrandt	1.258	0.072
Rembrandt → Vermeer	1.152	0.341
Vermeer → Van Gogh	1.158	0.280
Van Gogh → Kandinsky	0.970	0.452
Kandinsky → Matisse	0.089	0.189
Matisse → Picasso	0.117	0.509
Picasso → Miró	0.385	0.325
Miró → Pollock	2.376	3.823

mento contínuo, refletindo a concordância de membros do mesmo movimento e a sua preparação nas vésperas de inaugurar um novo movimento. O pico de contra-dialética acontece em Van Gogh e Kandinsky: de novo, exatamente o ponto onde o Barroco termina e o Moderno começa, considerando os pintores selecionados para esse estudo.

Tabela 3.13 – Índices de contra-dialética para cada um dos 10 deslocamentos entre tese, antítese e síntese, considerando os dois melhores atributos.

Tese, antítese e síntese	$d_{i \rightarrow k}$
Caravaggio → Frans Hals → Poussin	0.572
Frans Hals → Poussin → Velázquez	0.337
Poussin → Velázquez → Rembrandt	0.151
Velázquez → Rembrandt → Vermeer	0.608
Rembrandt → Vermeer → Van Gogh	1.362
Vermeer → Van Gogh → Kandinsky	1.502
Van Gogh → Kandinsky → Matisse	1.062
Kandinsky → Matisse → Picasso	0.183
Matisse → Picasso → Miró	0.447
Picasso → Miró → Pollock	2.616

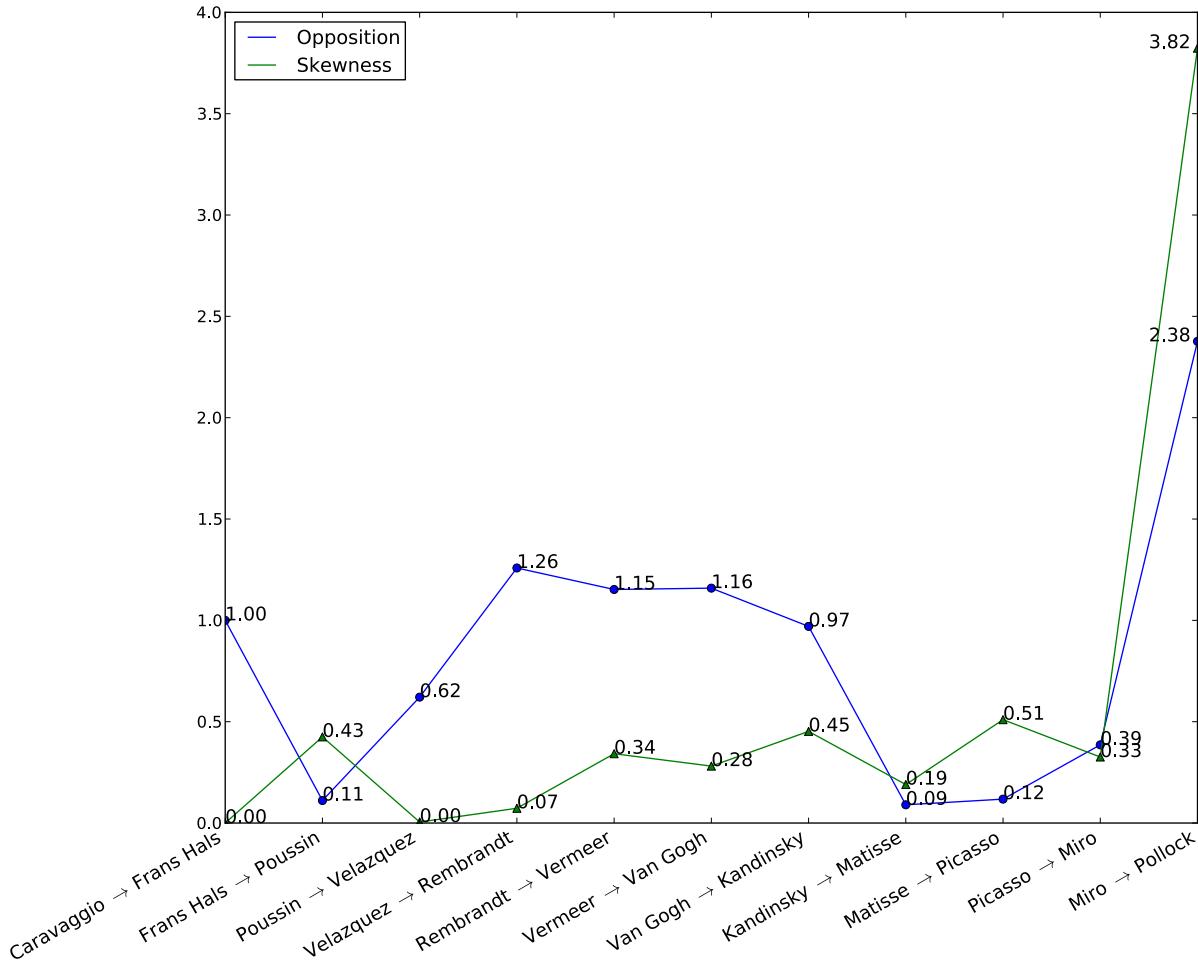


Figura 3.12 – Valores de oposição $W_{i,j}$ e inovação $s_{i,j}$ considerando os dois melhores atributos.

3.5.1 Análise por LDA de todos os atributos

Embora os atributos $F_{N,83}$ (μ de picos de curvatura) e $F_{N,87}$ (μ do número de segmentos) apresentaram-se como opções interessantes para a classificação, o método LDA foi aplicado considerando todos os $N = 93$ atributos com o objetivo de testar a relevância dos atributos originalmente selecionados e a estabilidade dos resultados. O método LDA projeta os atributos em um espaço de $n < N$ dimensões que melhor separa as pinturas e que acaba por resultar em uma nova série temporal como feito para o caso dos melhores atributos. Nesse caso, para permitir a visualização das medidas, considerou-se a projeção com $n = 2$ componentes que resultou em

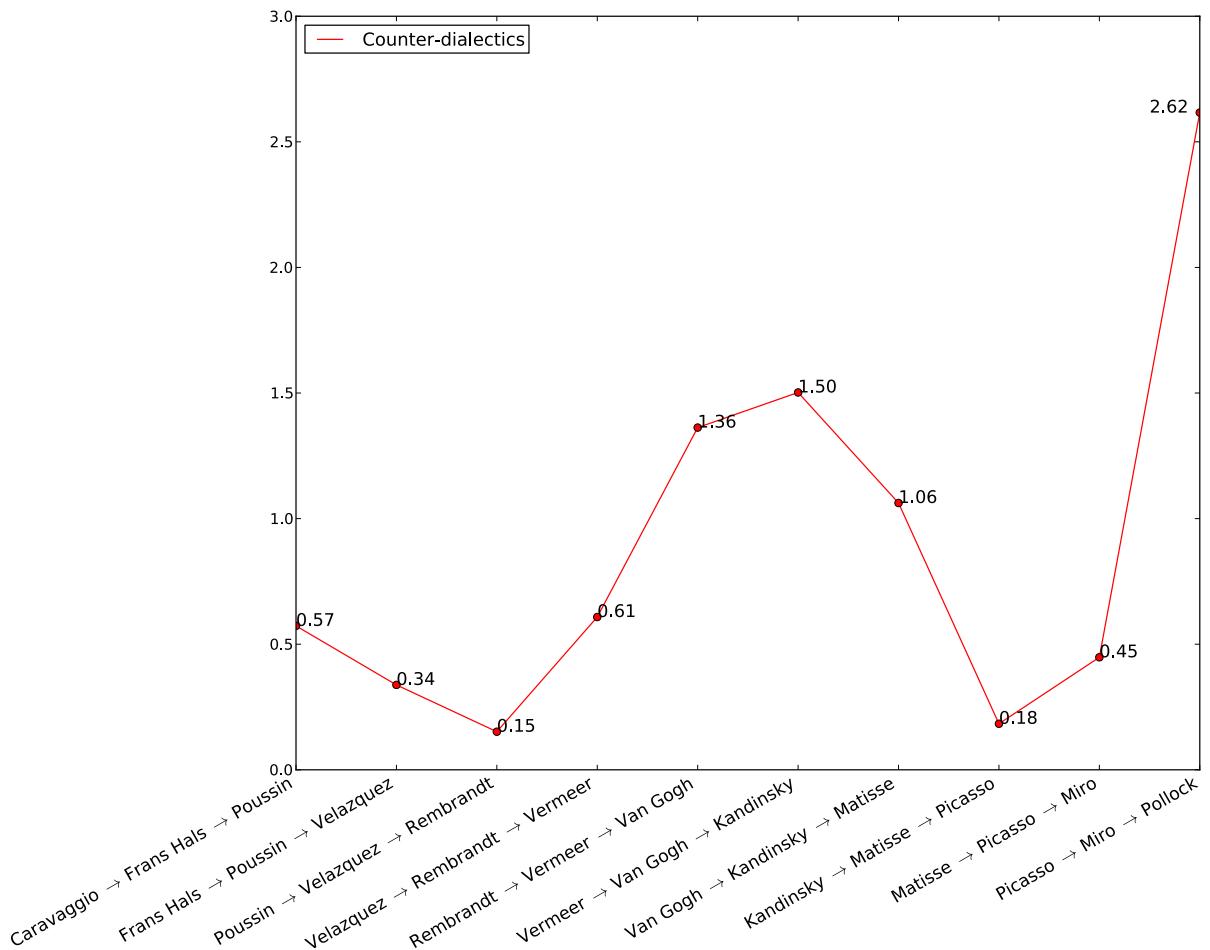


Figura 3.14 – Valores de contra-dialética considerando os dois melhores atributos.

um espaço de 2 dimensões, mostrado na Figura 3.15. É possível notar, como esperado, uma similaridade com os resultados da Subseção ???. Os índices de inovação (Figura 3.17) apresentam uma curva ascendente ainda mais bem definida durante toda a evolução da série. Os padrões notados na evolução de ambos índices de oposição e contra-dialética continuam visíveis nessa nova projeção por LDA, como é possível notar na Figuras 3.17 e 3.19, respectivamente.

Para validação do LDA o grupo de 240 pinturas foi dividido em dois: um conjunto de treinamento contendo 10 pinturas selecionadas aleatoriamente para cada artista, e um conjunto de teste contendo as 10 pinturas restantes para cada artista, ambos sem repetição. A matriz de confusão (Figura 3.20) indica o quanto satisfatória é a classificação. Os elementos da diagonal

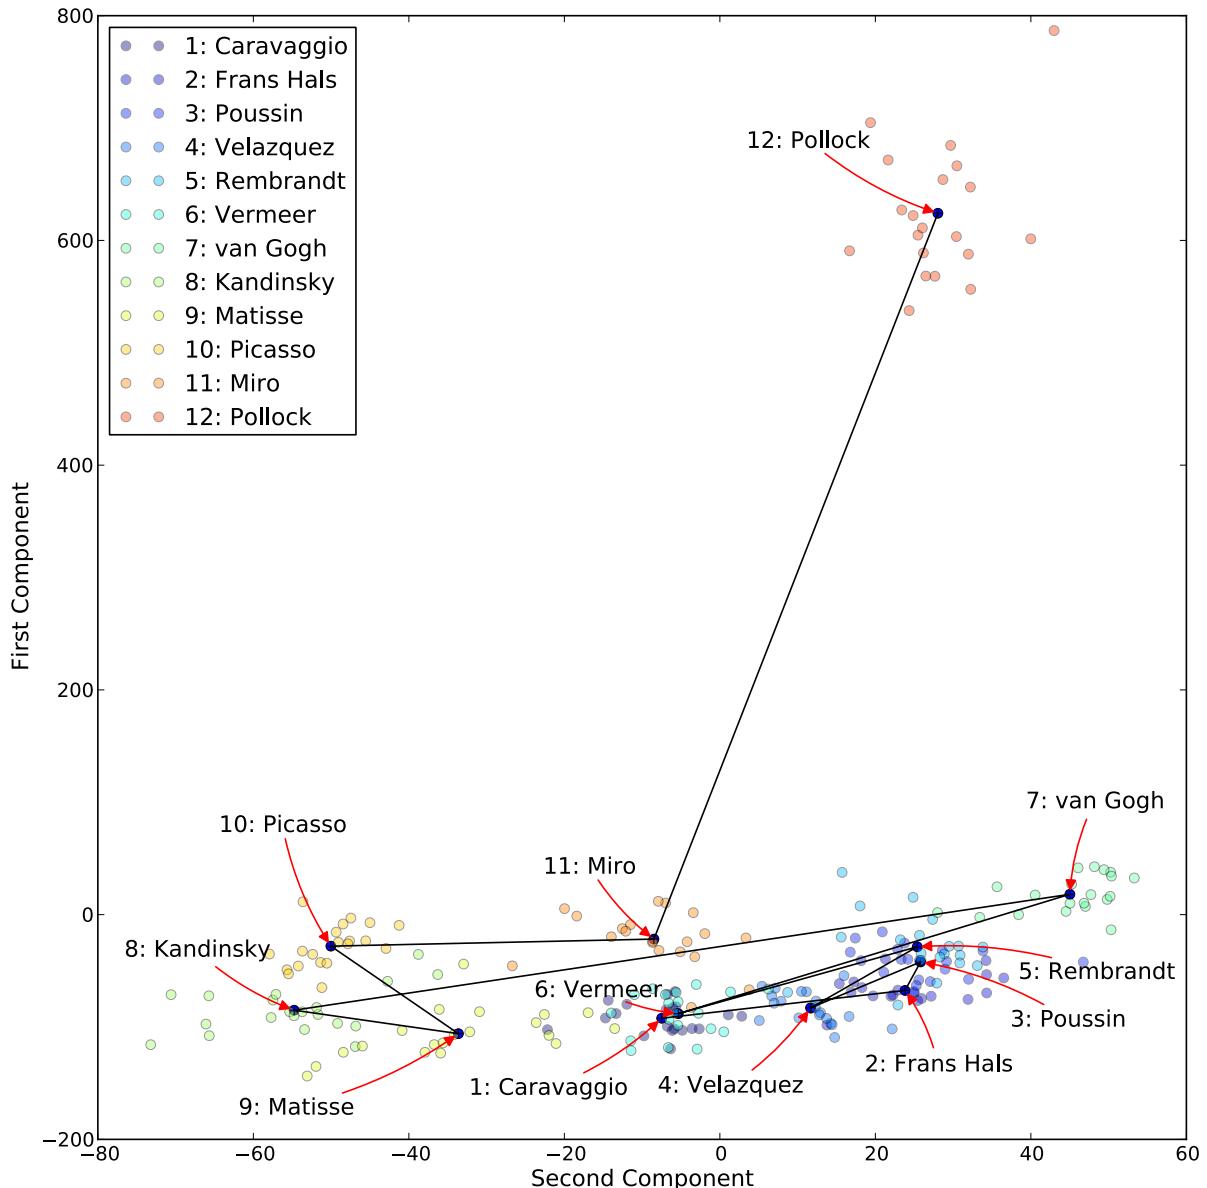


Figura 3.15 – Série temporal resultante da projeção em 2 dimensões do espaço criativo considerando os dois primeiros componentes com maiores autovalores obtidos a partir da transformação LDA na matriz de $N = 93$ atributos.

principal representam o número de amostras (pinturas) para as quais a classe obtida no conjunto de teste coincide com a classe esperada (obtida na fase de treinamento). Elementos localizados fora da diagonal principal indicam aqueles que não foram classificados corretamente pelo método LDA. Quanto maiores os **valoers** da diagonal principal, melhor a predição de classes.

Tabela 3.16 – Índices de oposição e inovação para cada um dos 11 deslocamentos de um pintor ao outro.

Deslocamento	$W_{i,j}$	$s_{i,j}$
Caravaggio → Frans Hals	1.	0.
Frans Hals → Poussin	-0.101	0.132
Poussin → Velázquez	0.588	0.037
Velázquez → Rembrandt	1.526	0.050
Rembrandt → Vermeer	1.101	0.143
Vermeer → Van Gogh	1.153	0.157
Van Gogh → Kandinsky	1.279	0.512
Kandinsky → Matisse	0.179	0.149
Matisse → Picasso	-0.201	0.516
Picasso → Miró	0.432	0.163
Miró → Pollock	4.031	2.662

Como é possível observar, o método LDA demonstra predição esperada para o grupo de pinturas considerado. As amostras com melhor classificação são as pinturas de Pollock, o que é esperado, pois é o pintor que mais se distancia dos outros no *espaço de pinturas*. Em geral, a matriz de confusão reflete os resultados previamente discutidos: há similaridade entre pintores barrocos, principalmente Velázquez, Caravaggio e Rembrandt e é possível notar claramente a separação entre pintores **antes de depois** de Van Gogh, que define a fronteira entre os movimentos Barroco e Moderno.

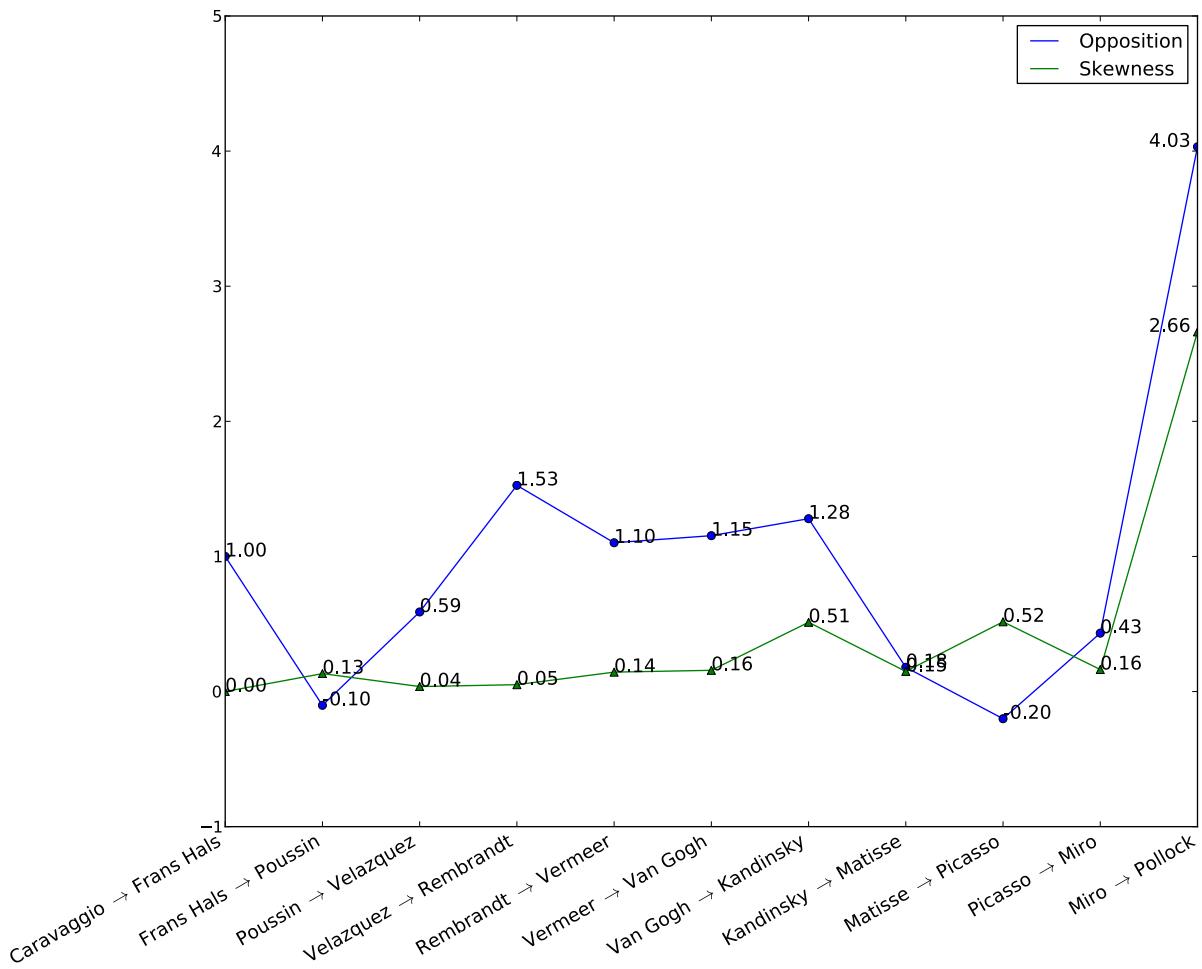


Figura 3.17 – Valores de oposição e inovação considerando a série temporal para todos os $N = 93$ atributos refletidos nos dois primeiros componentes obtidos pelo método LDA. Os mesmos padrões observados quando considerando os dois melhores atributos ainda permanecem nessa observação, como esperado.

Tabela 3.18 – Índices de contra-dialética para cada um dos deslocamentos para os dois melhores componentes do LDA.

Deslocamento	Contra-dialética ($d_{i \rightarrow k}$)
Caravaggio → Frans Hals → Poussin	0.587
Frans Hals → Poussin → Vel'azquez	0.317
Poussin → Vel'azquez → Rembrandt	0.268
Vel'azquez → Rembrandt → Vermeer	0.736
Rembrandt → Vermeer → Van Gogh	1.192
Vermeer → Van Gogh → Kandinsky	2.352
Van Gogh → Kandinsky → Matisse	0.974
Kandinsky → Matisse → Picasso	0.241
Matisse → Picasso → Mir'o	0.704
Picasso → Mir'o → Pollock	1.924

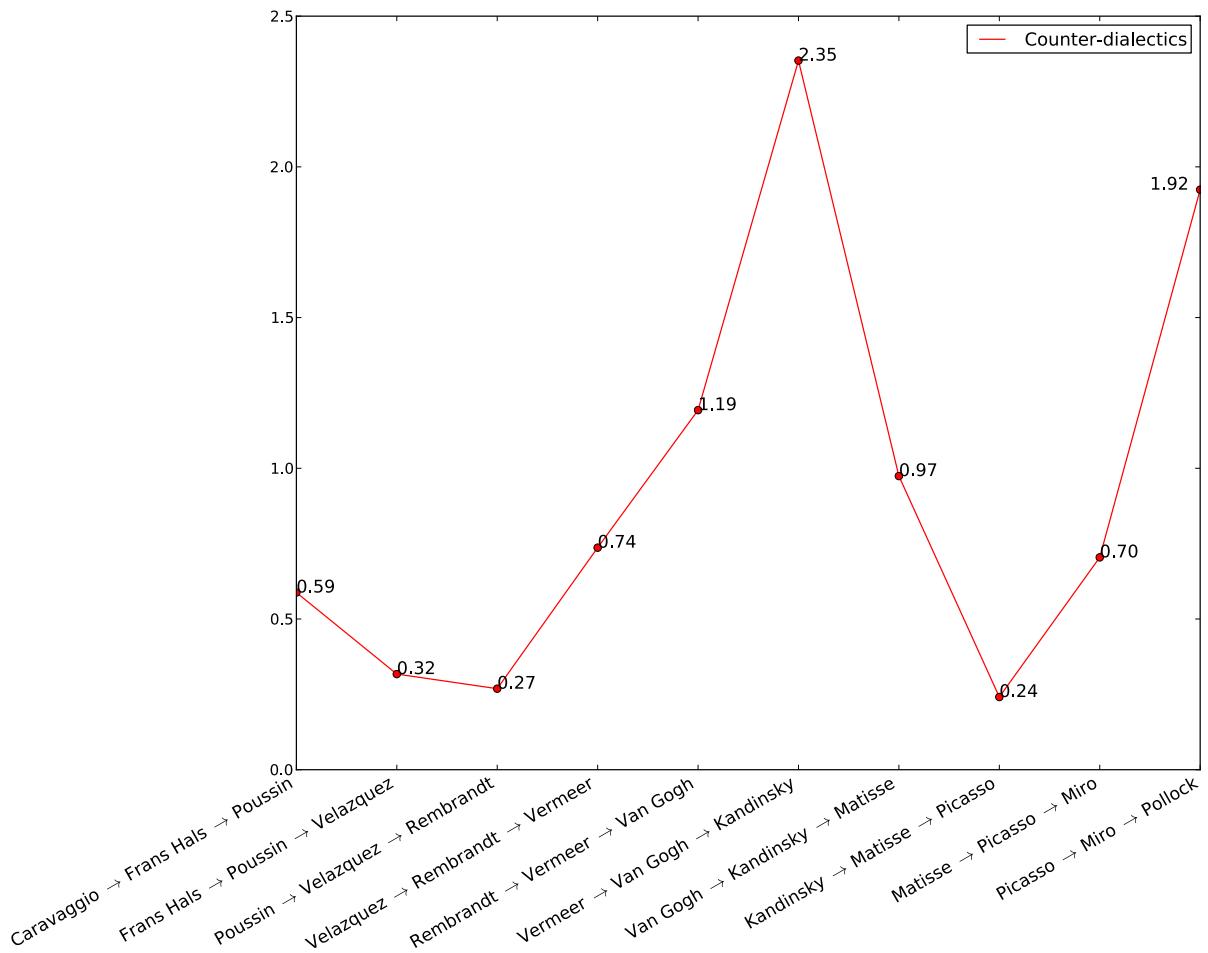


Figura 3.19 – Contra-dialética (valores altos indicam baixa incidência de dialética) calculada para os componentes principais obtidos por LDA. O padrão observado anteriormente para o melhor par de atributos apresenta-se ainda mais visível aqui: é possível observar claramente que o maior valor está no ponto de transição dos movimentos artísticos (Van Gogh e Kandinsky).

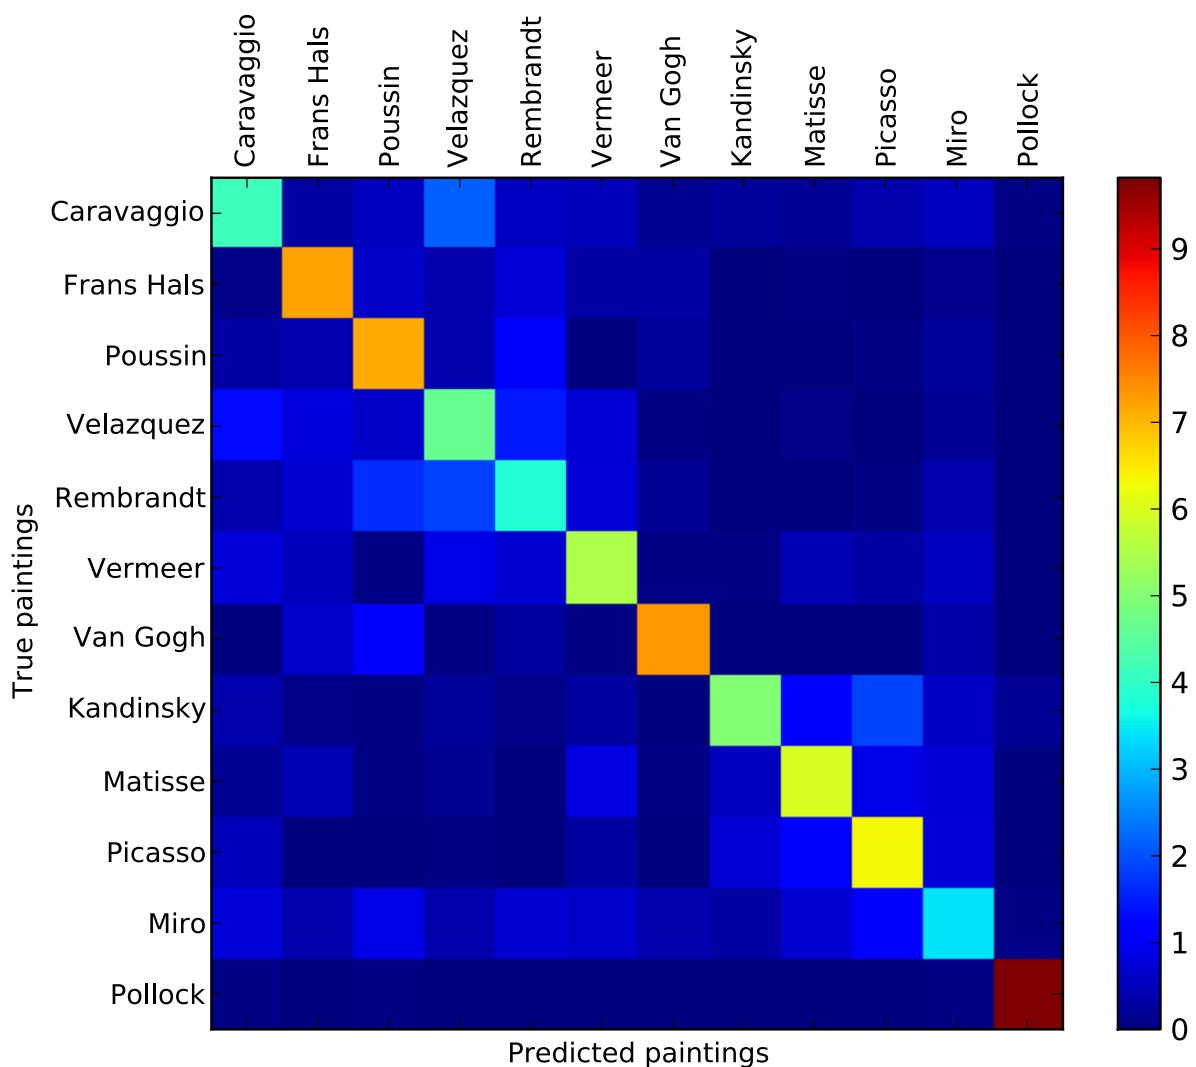


Figura 3.20 – Matriz de confusão para o método LDA. *Metade das pinturas de cada artista é usado como conjunto de treino e a metade restante como conjunto de teste. Os elementos da diagonal principal mostram o número de amostras da classe esperada que correspondem com a classe obtida pelo método. Dada a grande quantidade de valores na diagonal principal, a validação sugere que o método LDA foi suficiente para a classificação das pinturas. Além disso, detalhes já observados nos resultados desse estudo são novamente observados na matriz: deslocamento de Van Gogh e similaridade entre pintores do mesmo movimento, principalmente Barroco.*

4 Conclusões

Apontamentos futuros: uso integrado a um algoritmo de otimização (AG) para geração de material, colaboração para uso do mesmo framework para geração de estruturas musicais e demais artefatos. Aplicação do método em mais pinturas e artistas. Novas medidas quantitativas para conceitos humanos.



Os atributos que melhor classificaram as pinturas foram *a)* número de picos de curvatura e *b)* número de segmentos por imagem, ambos relacionados com a forma do segmento. Outros atributos que apresentaram altos valores para α também estavam, em geral, relacionados com a forma. Esses atributos podem ser usados satisfatoriamente para a classificação de pintores, apresentando resultados ainda melhores que atributos canônicos em processamento de imagens como as medidas de textura de Haralick ou medidas baseadas na complexidade de figuras (entropia). A relevância de tais medidas foi atestada pela análise do índice de dispersão α calculado para cada par possível de atributos e validada através da aplicação do método LDA. Esse, por sua vez, também teve sua validação efetuada e acabou por reforçar as observações e padrões obtidos para as medidas com base filosófica.

A caracterização das pinturas pelo uso destes atributos tornou possível a análise de medidas quantitativas (geométricas). Embora de importância central para o entendimento da evolução da humanidade, conceitos filosóficos como a dialética não são abordados **comunmente belas** ciências exatas. Enquanto tratadas como medidas geométricas, **ambas** medidas de oposição,

inovação e dialética revelaram conceitos importantes que puderam ser comparados com resultados já obtidos para a música e filosofia (8). Compositores mostram altos valores de dialética, o que sugere a tradição mestre-aprendiz — reconhecida nas escolas musicais. Filósofos, por sua vez, mostram grandes valores de oposição, o que também encontra base em como a evolução da Filosofia se dá: geralmente, através do conflito de ideias. Pintores, como mostrado nesse estudo, exibem declínio nos valores de oposição e dialética no início de cada movimento artístico considerado. Esse declínio é seguido por um aumento constante até encontrar seu ápice, exatamente no momento onde há a transição de um movimento (Barroco) para o outro (Moderno). Ainda, diferente dos filósofos e músicos, na pintura a inovação apresenta valores aumentando constantemente, durante toda a série temporal. Isso pode refletir a influência de cada movimento artístico em seus representantes, juntamente com um constante desejo de inovar, presente principalmente nos pintores modernos. Dessa forma, fatos já fundamentados na história das artes são confirmados por tais medidas quantitativas. Nesse sentido, uma das observações mais sumárias é a sobreposição de pinturas barrocas **enquanto nos pintores isso não acontece.** Pelo contrário, os grupos de pintores modernos apresentam pouca sobreposição e, ao mesmo tempo, cobrem uma região maior do espaço geométrico quando comparados aos barrocos. Essas observações encontram paralelo na história, com os barrocos compartilhando as características estéticas de suas obras uns com os outros, enquanto os modernos procuram definir cada um seu próprio estilo, individualmente.

Embora insuficiente para esgotar todas as características encontradas em um artista e sua obra, esse método sugere um *framework* para o estudo das ciências humanas através de medidas geométricas em um espaço de atributos. Como trabalhos futuros, o número de pintores pode ser expandido e um conjunto de pintores pode ser escolhido especificamente para investigar suas influências (**e.g.** pinturas dos filhos de Frans Hals podem ser incluídas para verificar a influência de seu pai e mestre, ou ainda, pinturas de Rafael, Poussin e Guido Reni (5) or Carracci podem ser comparadas com o objetivo de verificar a já reconhecida similaridade entre ambos pintores,

ou a influência de Cézanne em Matisse e Picasso, que declarou “meu primeiro e único mestre (...) Cézanne é o pai de todos nós” (16). Ainda, um número maior de pinturas para cada artista pode ser considerado para análise. O mesmo *framework* pode ser aplicado (como já demonstrado para a Música, Filosofia e Pintura) a outros campos de interesse humano como Cinema e Literatura.

Mais uma vez reforça-se que, ao invés de suplantar as discussões humanas, que tanto trazem de valor para o entendimento da sociedade, esse *framework* pretende somar, fornecendo mais um ponto de vista.



REFERÊNCIAS

- 1 ANDERSEN, K. *The geometry of an art.* [S.l.]: Springer, 2007.
- 2 KEMP, M. et al. *The Science of Art: Optical themes in western art from Brunelleschi to Seurat.* [S.l.]: Yale University Press New Haven, CT, 1990.
- 3 PEGUS, L. Leonardo da vinci-anatomical drawings. *Journal of Visual Communication in Medicine*, Informa UK Ltd UK, v. 1, n. 2, p. 63–69, 1978.
- 4 HALL, M. B.; GILL, M. J. et al. Color and meaning: Practice and theory in renaissance painting. *Renaissance and Reformation/Renaissance et Réforme*, v. 16, n. 4, p. 83–85, 2009.
- 5 GOMBRICH, E. *The story of art.* Phaidon Press, Ltd., 1995.
(STORY OF ART). ISBN 9780714832470. Disponível em:
<<http://books.google.com.br/books?id=CECSU2MRH4QC>>.
- 6 WISNIK, J. M. *O som eo sentido: uma outra história das músicas.* [S.l.]: Círculo do Livro, Companhia das Letras, 1989.
- 7 GUIGUE, D. Estética da sonoridade: teoria e prática de um método analítico—uma introdução. *Claves*, n. 4, 2007.
- 8 VIEIRA, V. et al. A quantitative approach to evolution of music and philosophy. *Journal of Statistical Mechanics: Theory and Experiment*, v. 2012, n. 08, p. P08010, 2012. Disponível em: <<http://stacks.iop.org/1742-5468/2012/i=08/a=P08010>>.
- 9 KANDINSKY, W.; CABRAL, Á.; DANESI, A. d. P. *Do espiritual na arte e na pintura em particular.* [S.l.]: Martins Fontes, 2000.
- 10 ROMERO, J. et al. Using complexity estimates in aesthetic image classification. *Journal of Mathematics and the Arts*, v. 6, n. 2-3, p. 125–136, 2012. Disponível em: <<http://www.tandfonline.com/doi/abs/10.1080/17513472.2012.679514>>.
- 11 MANOVICH, L. *Style Space: How to compare image sets and follow their evolution (draft text).* ago. 2011. <http://lab.softwarestudies.com/2011/08/style-space-how-to-compare-image-sets.html>.
- 12 GONZALEZ, R. C.; WOODS, R. E. *Processamento de imagens digitais.* [S.l.]: Edgard Blucher, 2000.

- 13 HARALICK, R. M.; DINSTEIN, I.; SHANMUGAM, K. Textural features for image classification. *Ieee Transactions On Systems Man And Cybernetics*, IEEE, v. 3, n. 6, p. 610–621, 1973. Disponível em: <<http://ieeexplore.ieee.org/lpdocs/epic03/wrapper.htm?arnumber=4309314>>.
- 14 COSTA, L. d. F. D.; CESAR JR., R. M. *Shape Analysis and Classification: Theory and Practice*. 1st. ed. Boca Raton, FL, USA: CRC Press, Inc., 2000. ISBN 0849334934.
- 15 LAMBERT, G.; NÉRET, G. *Caravaggio. Ediz. tedesca*: Taschen Deutschland GmbH, 2000. (Basic Art Series). ISBN 9783822808184. Disponível em: <<http://books.google.com.br/books?id=eMWrHAAACAAJ>>.
- 16 RISHEL, J. J.; SACHS, K.; BERNSTEIN, R. *Cézanne and beyond*. [S.l.]: Yale University Press, 2009.



APÊNDICE A – Tutorial para execução dos scripts Python desenvolvidos para análise

1. Certifique-se de ter instalado as dependências:

```
sudo apt-get install python python-numpy python-matplotlib
                           python-setuptools git
git clone https://github.com/scikit-image/scikit-image.git
cd scikit-image
sudo python setup.py install
```

2. Clone o repositório Git da dissertação e *scripts* (o repositório inclui os arquivos de imagens das pinturas, portanto o tempo de *download* pode ser longo):

```
git clone https://github.com/automata/ana-pintores.git
cd ana-pintores/
```

3. Para analisar as pinturas por processamento de imagens, execute:

```
python analyse_pinturas.py
python analyse_segs.py
```

4. Para gerar a matriz de atributos extraídos a partir da análise anterior:

```
python feature_matrix_gen.py
```

5. Para calcular as medidas de inovação, oposição e dialética, assim como plotar a série temporal considerando os dois melhores atributos e LDA, assim como uma versão alternativa que substitui os marcadores por miniaturas das pinturas:

```
python metrics_caso1.py
```

```
python metrics_caso3b.py
```

```
python metrics_caso1_alternativo.py
```

6. Para validar os resultados através do LDA:

```
python valida3_r.py
```

7. Para calcular as matrizes esparsas e o índice α de separação, listando e plotando os pares de atributos que apresentaram melhor separação:

```
python scatter_matrix_pintores.py
```

8. Para plotar o comparativo dos histogramas de níveis de cinza médio das pinturas:

```
python chiaroscuro.py
```

```
python chiaroscuro_modernos.py
```

Cada script produz arquivos de imagens e resultados de saída diversos. Seus respectivos códigos devem ser consultados para se compreender quais as saídas geradas.

***APÊNDICE B – Galeria de imagens das 240
pinturas analisadas***

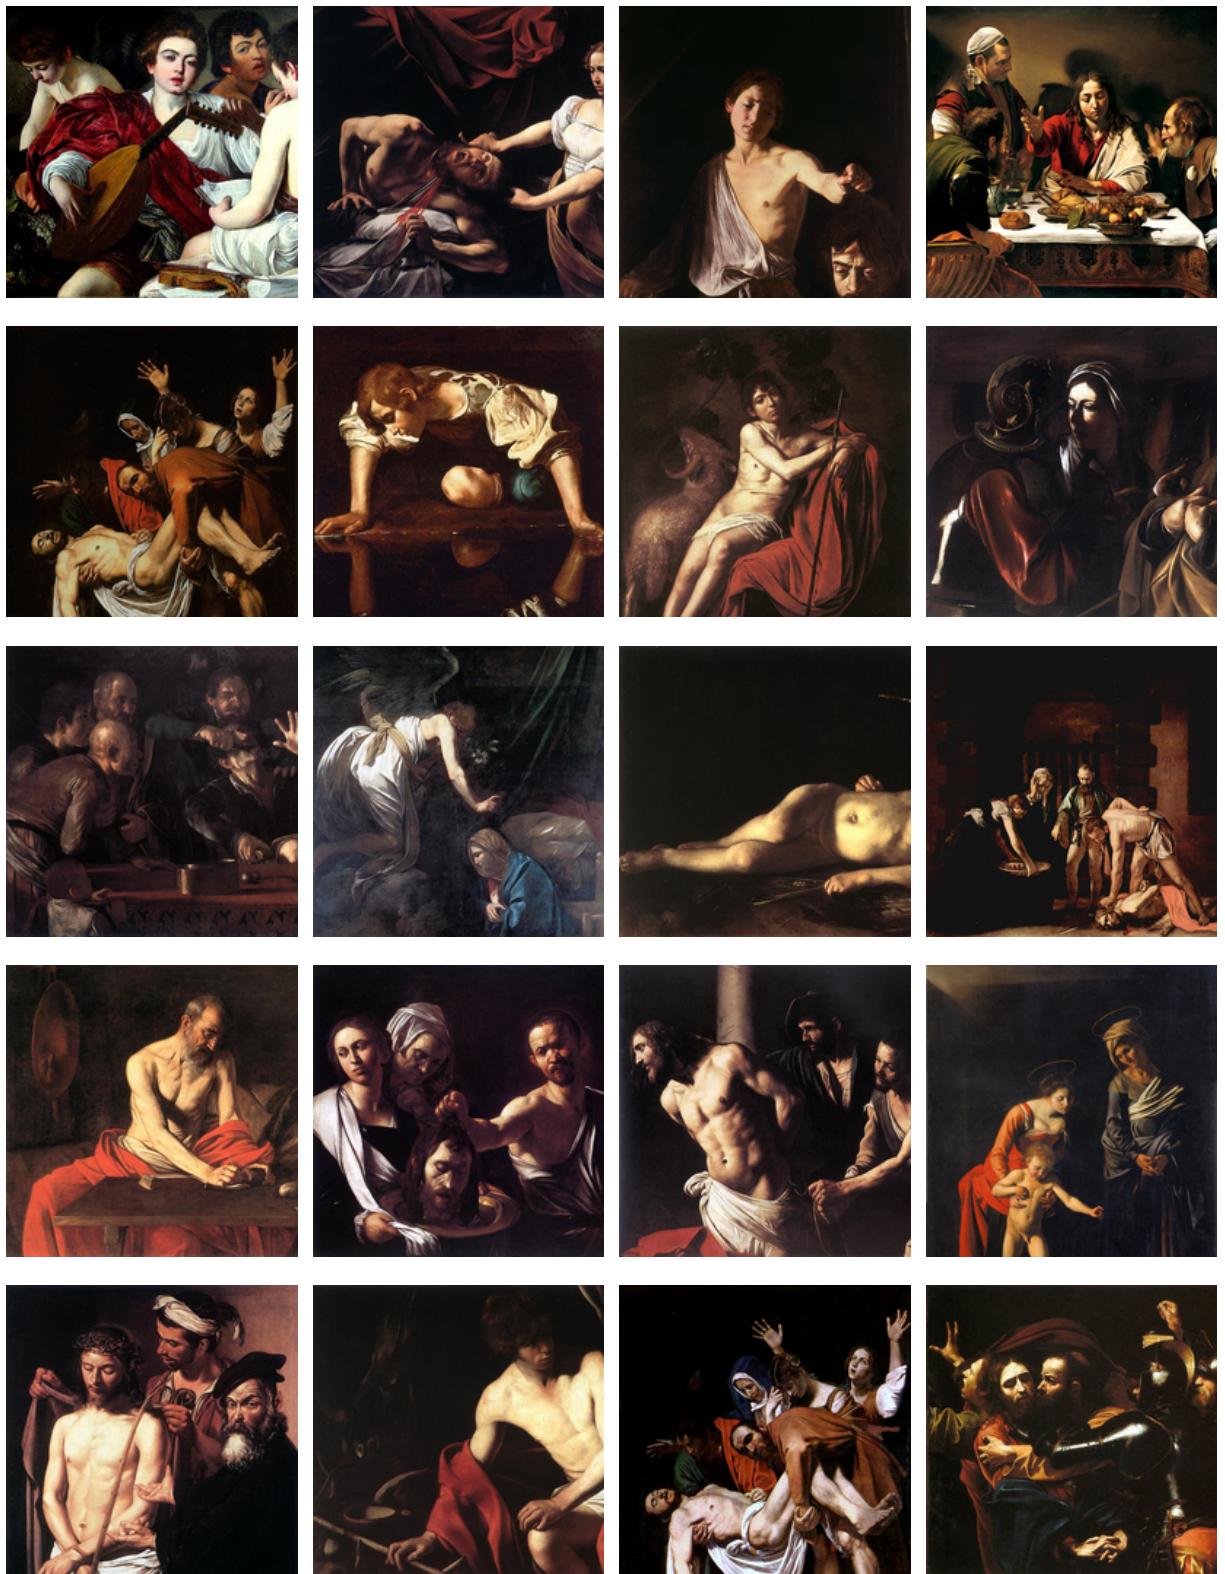


Figura B.1 – Caravaggio

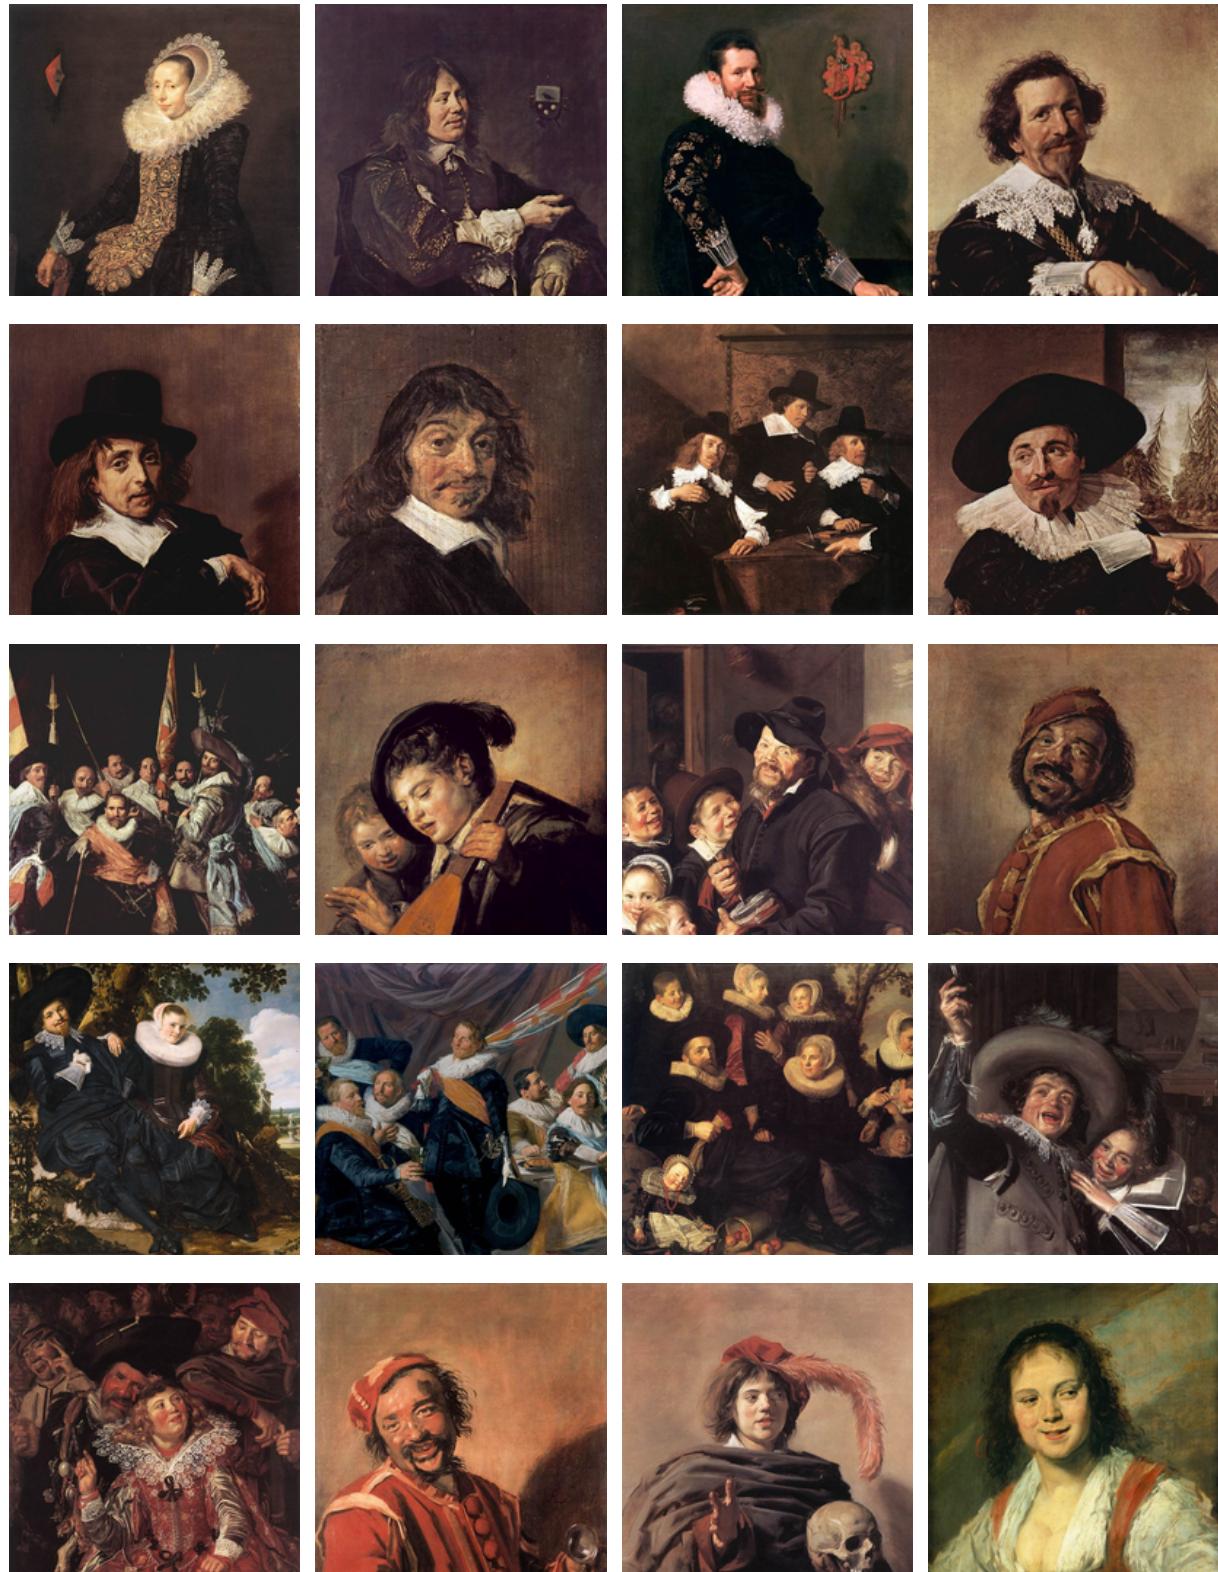


Figura B.2 – Frans Hals

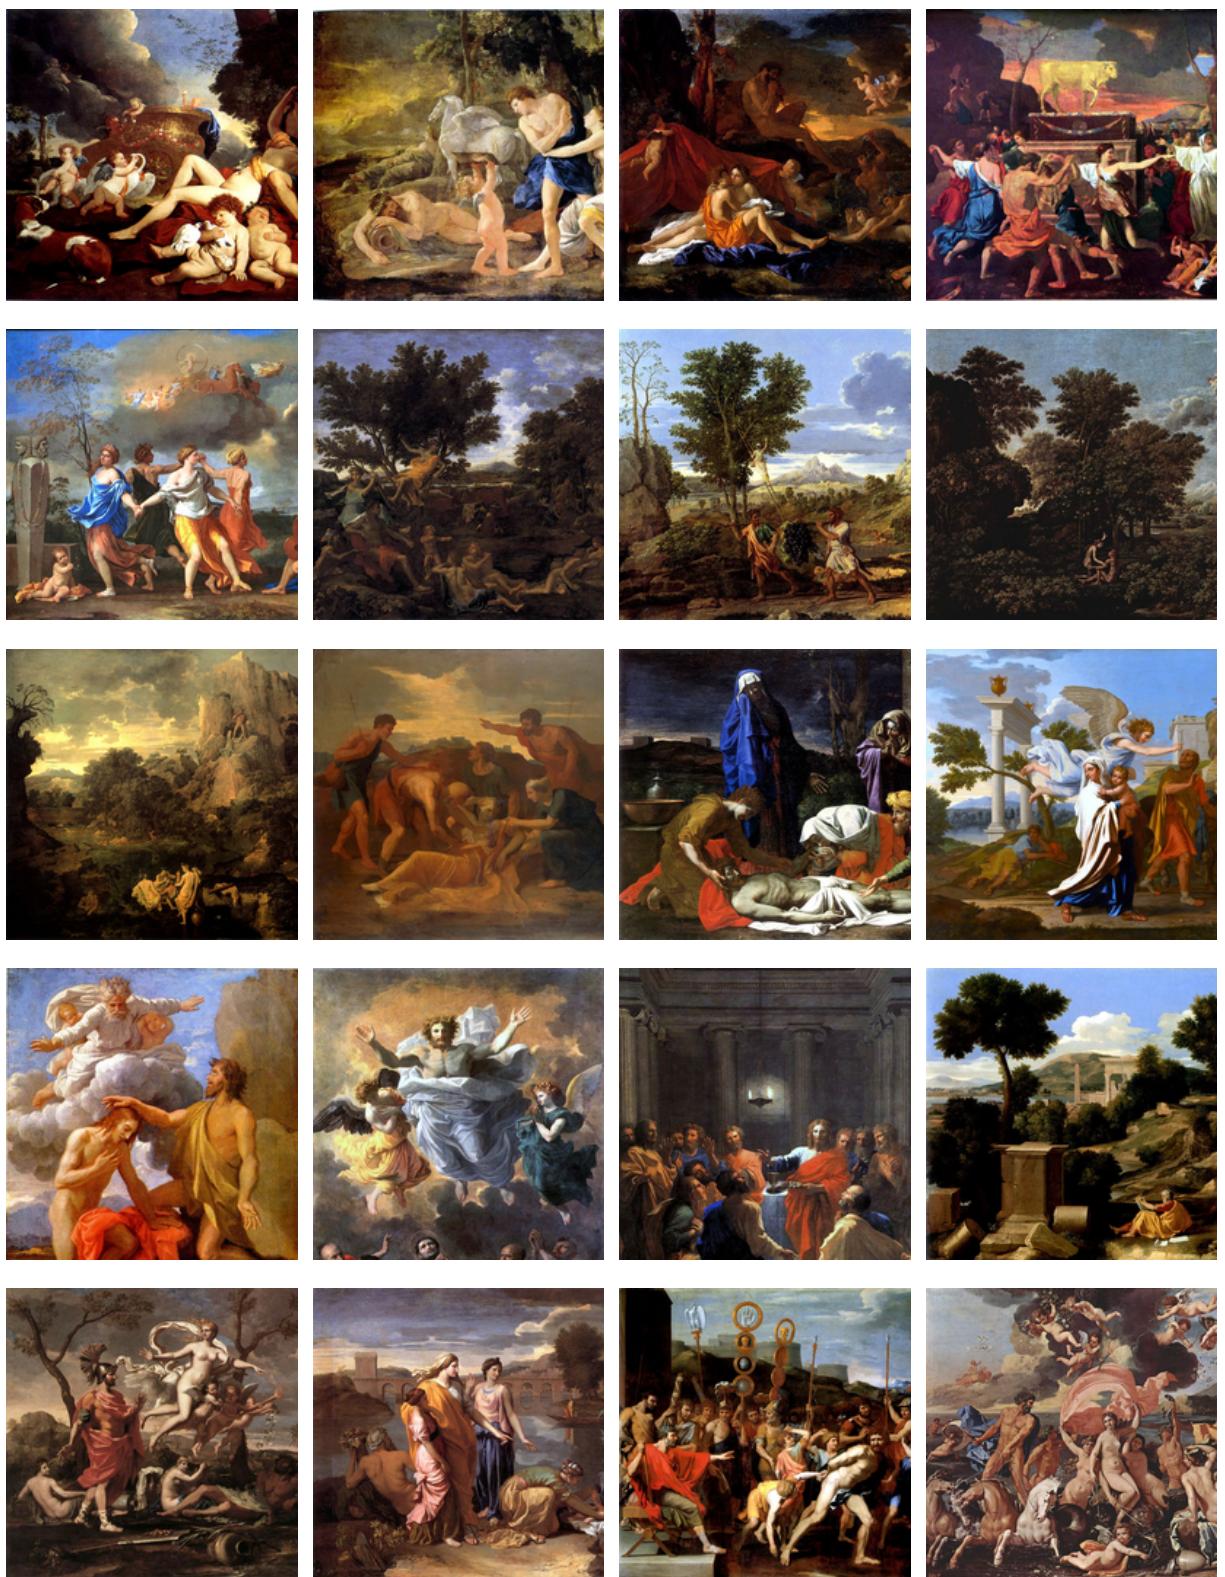


Figura B.3 – Nicolas Poussin



Figura B.4 – Diego Velázquez

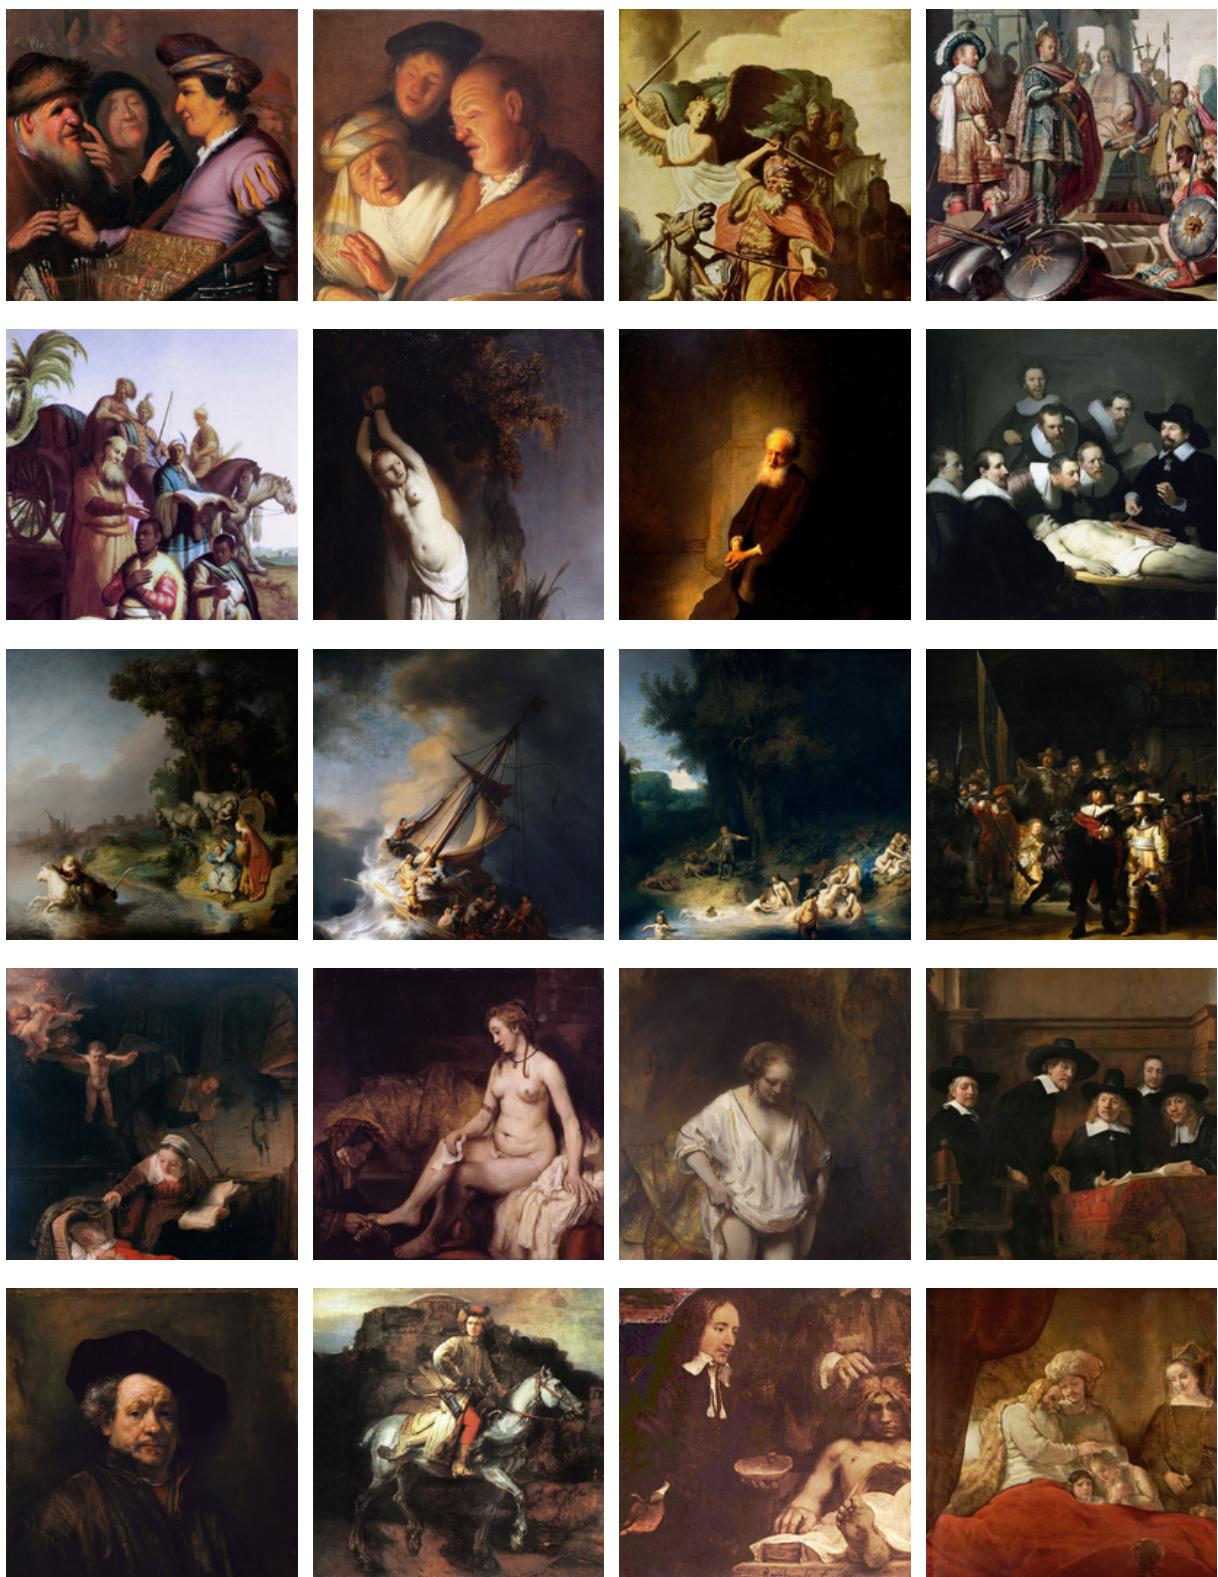


Figura B.5 – Rembrandt Harmenszoon van Rijn



Figura B.6 – Johannes Vermeer

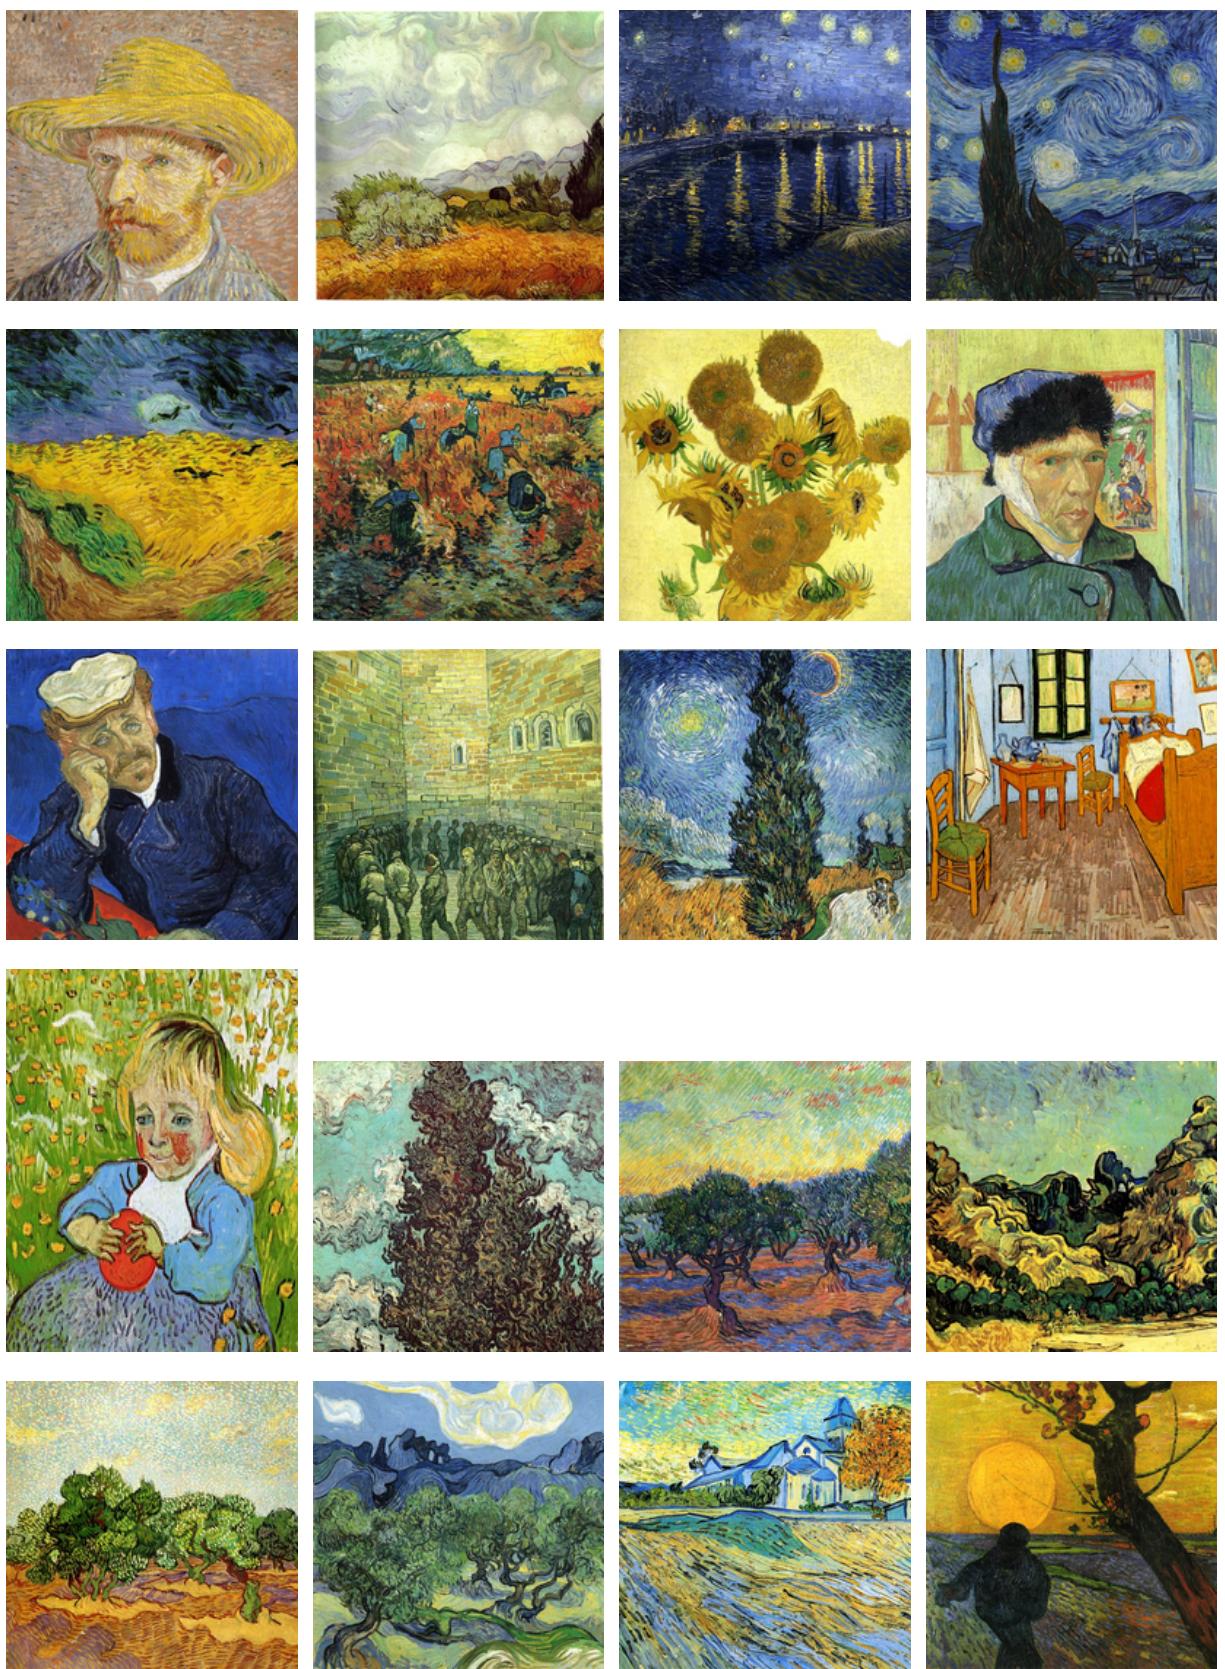


Figura B.7 – Vincent van Gogh

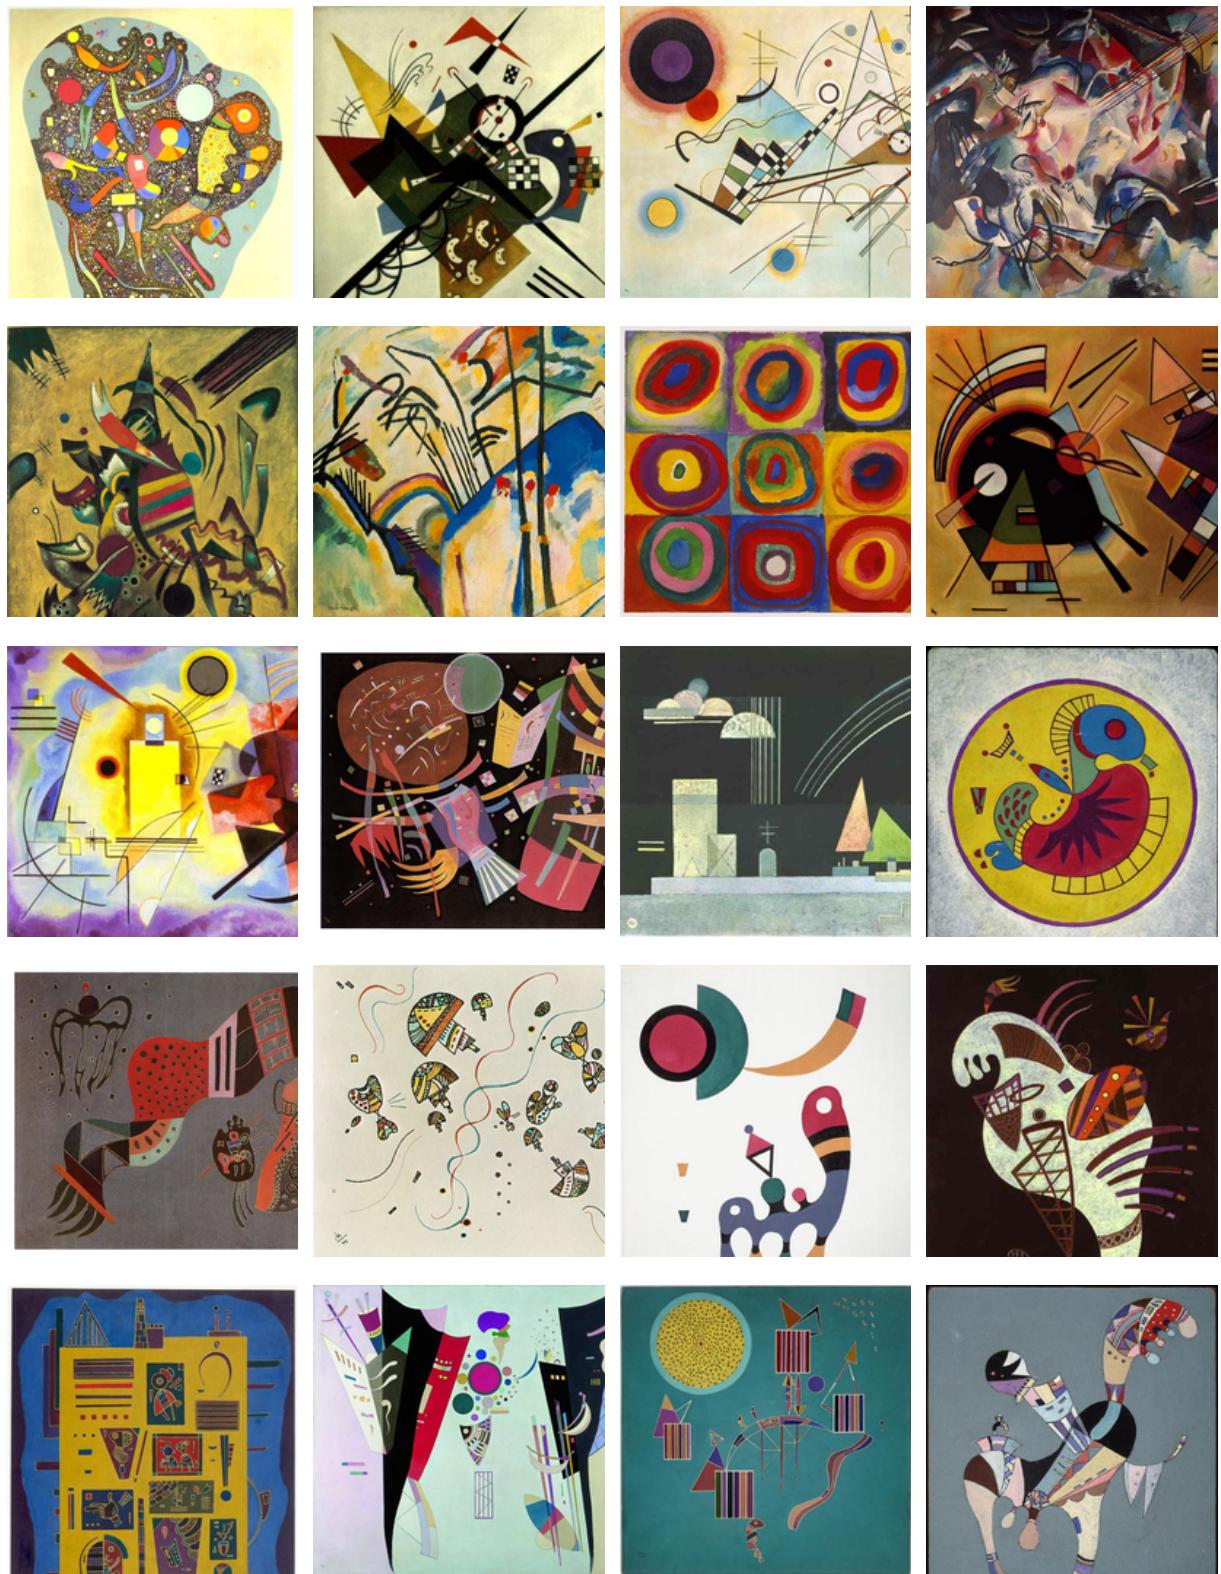


Figura B.8 – Wassilly Kandinsky

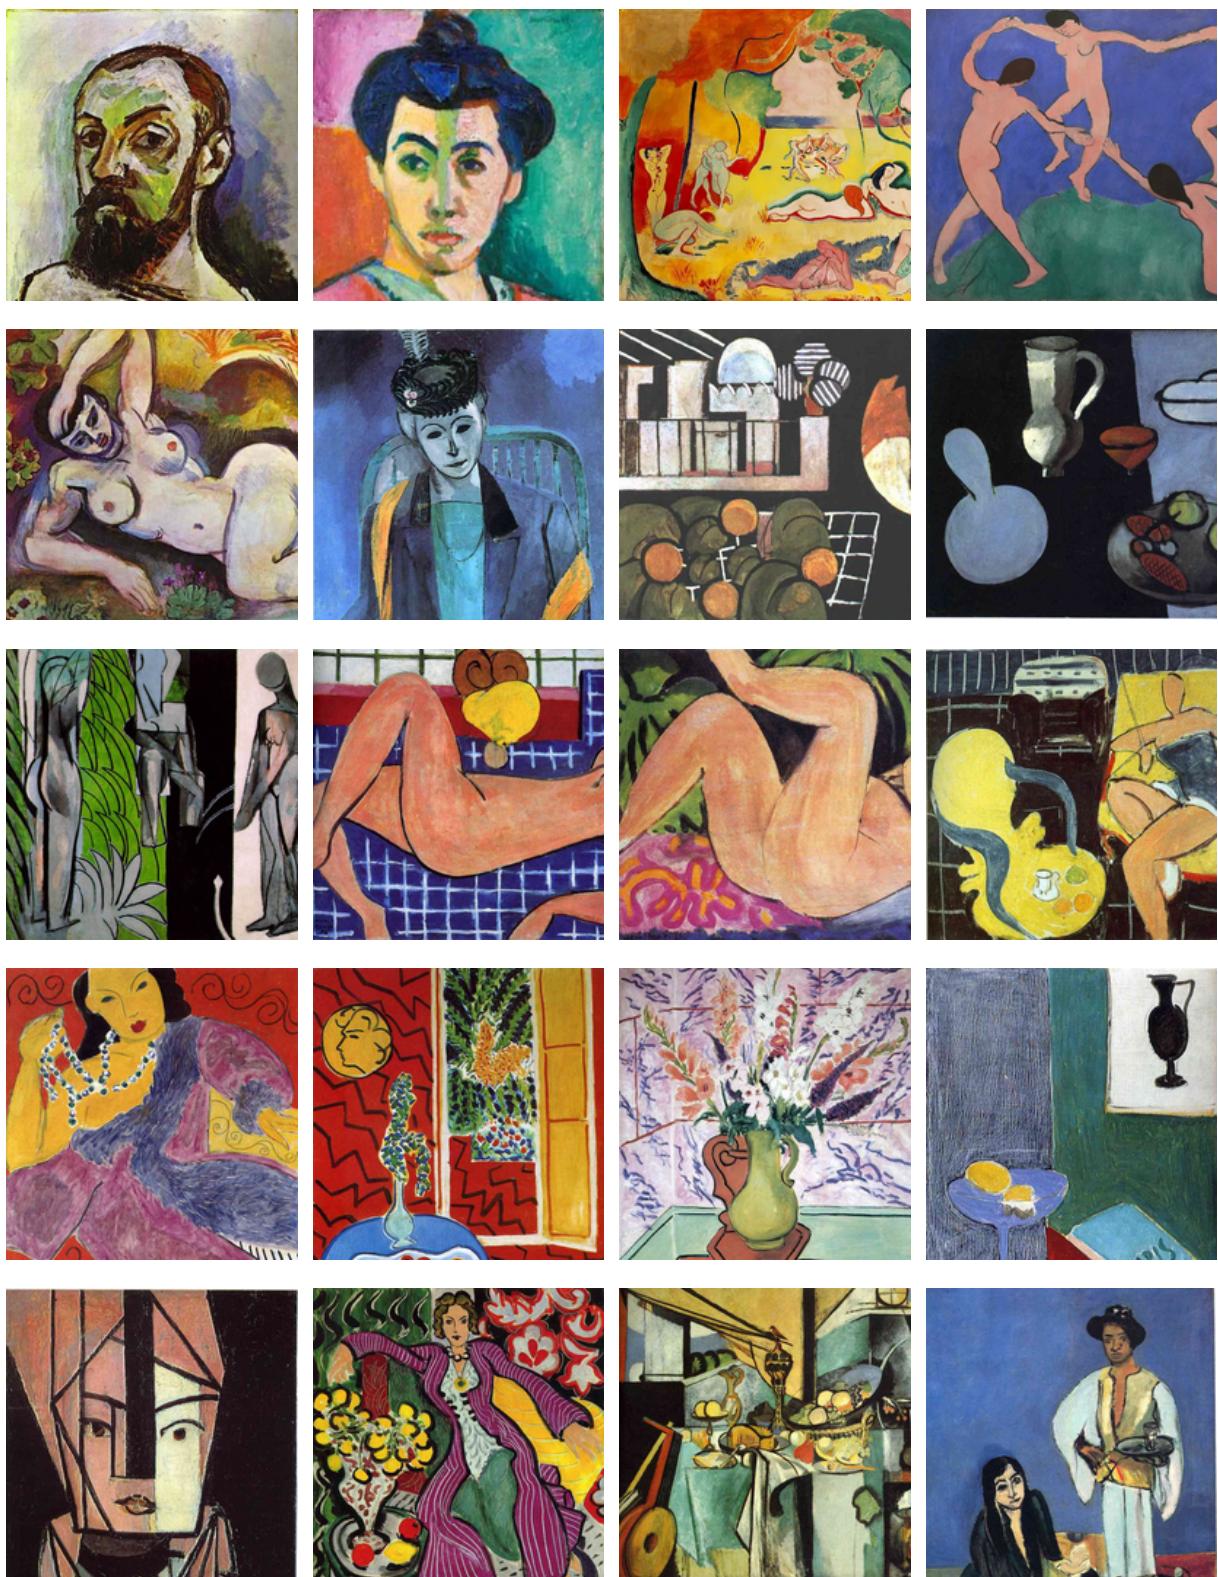


Figura B.9 – Henri Matisse

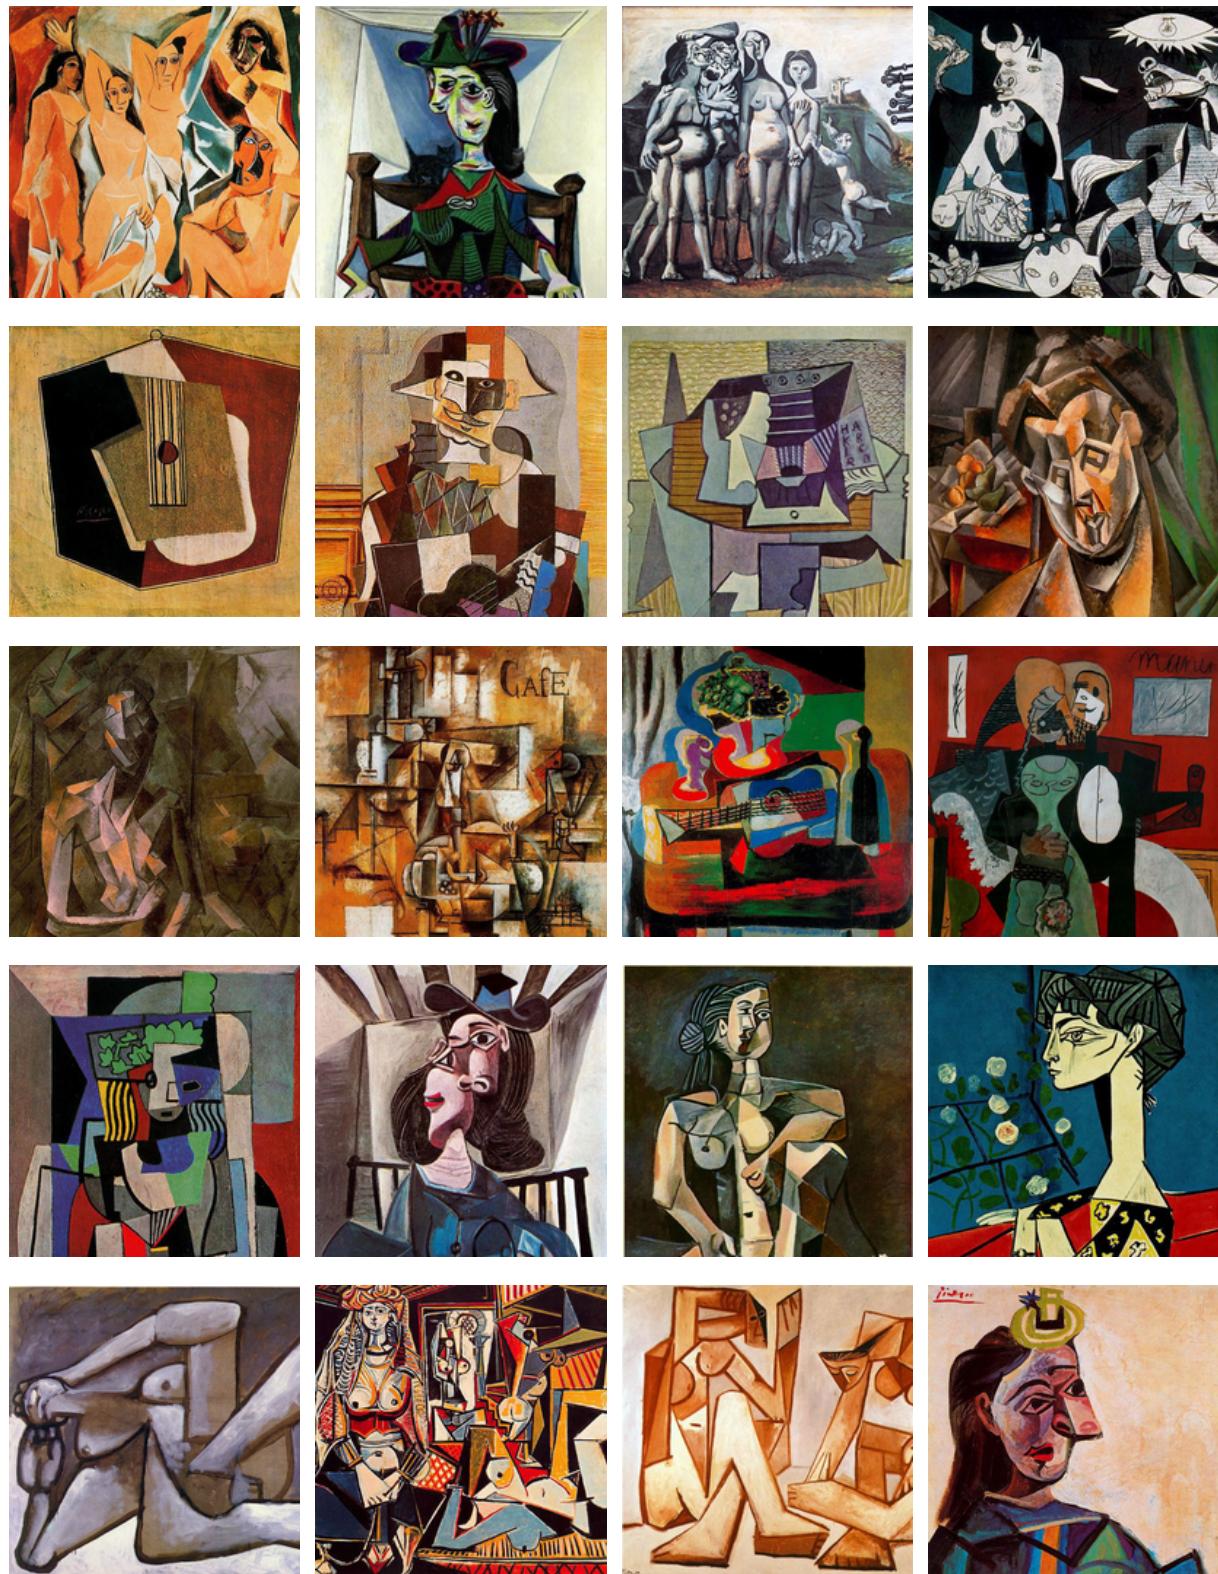


Figura B.10 – Pablo Picasso



Figura B.11 – Joan Miró

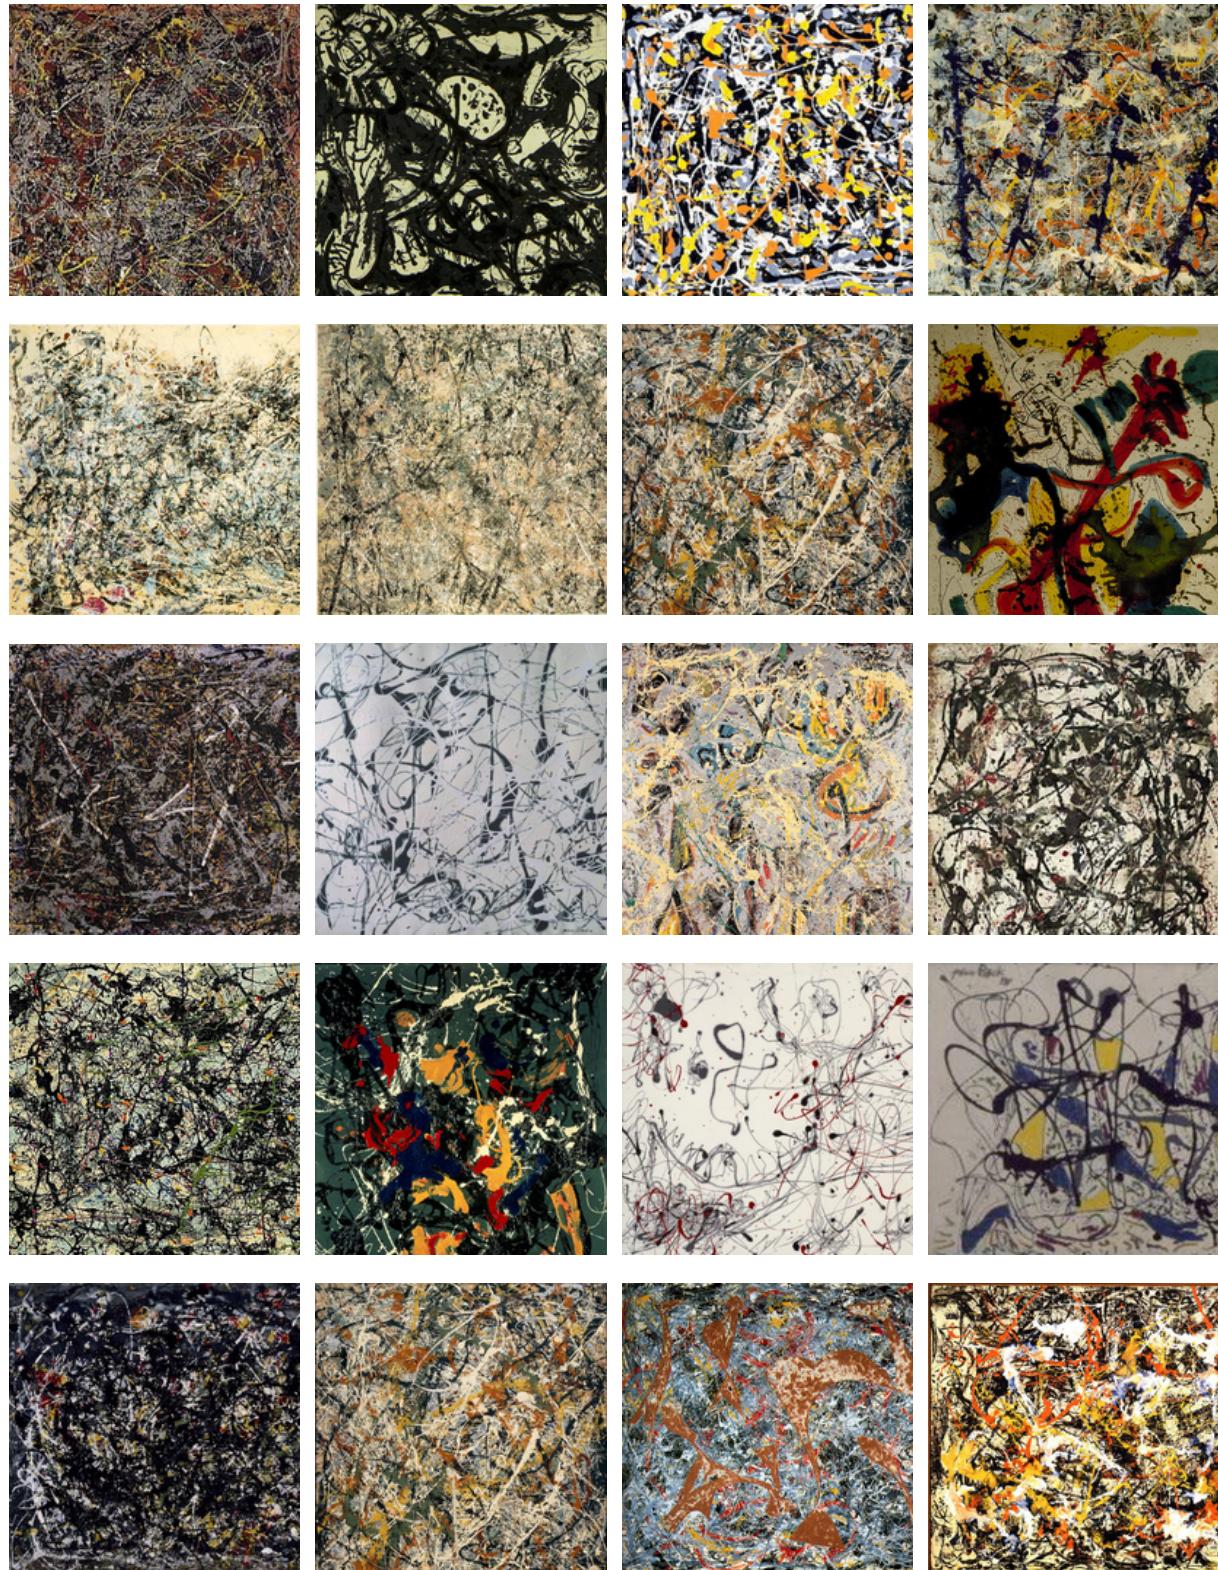


Figura B.12 – Jackson Pollock

APÊNDICE C – Visualizações complementares

Ao se representar as projeções das Figuras 3.6 e 3.7 usando miniaturas das pinturas ao invés de simples marcadores, tem-se uma visualização interessante onde detalhes variação de contraste e cor podem ser observados (Figura ??).

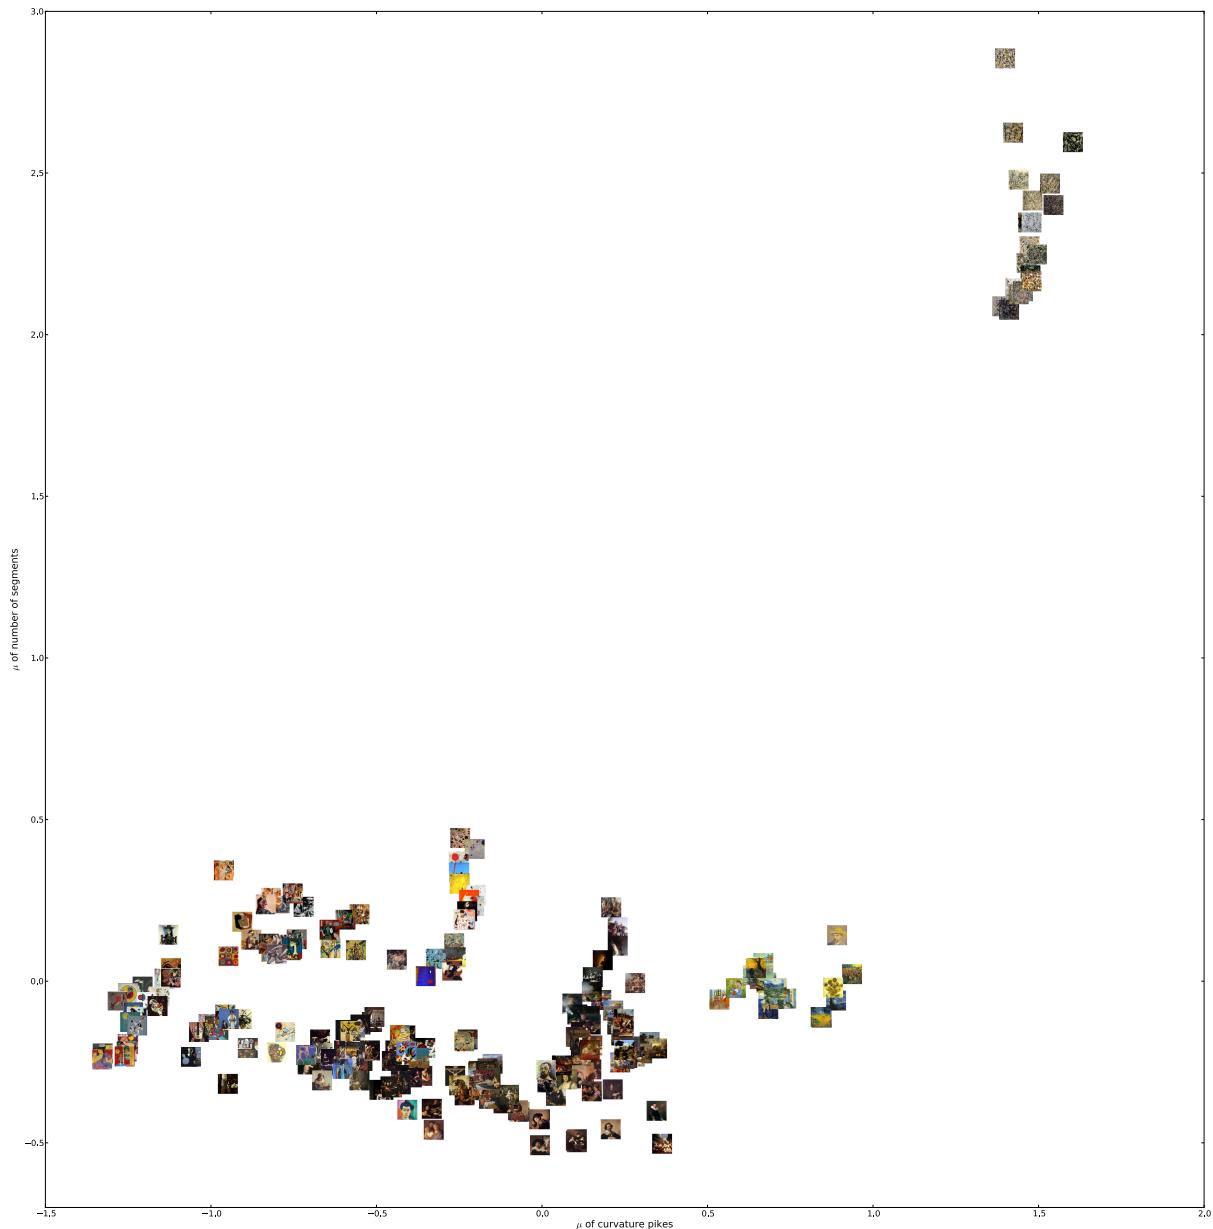


Figura C.1 – Visualização alternativa das projeções das Figuras 3.6 e 3.7. É possível perceber detalhes de contraste e cor e sua influência no agrupamento e separação dos grupos de pintores.

APÊNDICE D – Pinturas generativas por tesselação de Delaunay. Estudo 4

Tendo como base o processamento de imagens (pré-processamento e segmentação) realizado para as 240 pinturas usadas nesse estudo, foram geradas 240 novas “pinturas”. Todas as 240 pinturas generativas estão disponíveis em http://www.flickr.com/photos/auto_mata/sets/72157634660390040/.

Nos dias 30 de Setembro a 4 de Outubro de 2013, um conjunto de quadros foi aceito e exposto no espaço “Obra Artística” da 3^a Semana Integrada do Instituto de Física de São Carlos (SIFISC 3). Seguem os detalhes da obra:

Título Pinturas generativas por tesselação de Delaunay. Estudo 4

Tipo de obra Quadro

Altura 120cm

Profundidade 5cm

Largura 240cm

Descrição Imagens de pinturas originais dos movimentos Barroco e Moderno foram segmentadas. Coordenadas de pontos pertencentes a esses segmentos foram dadas como entrada

para o algoritmo de tesselação de Delaunay. O algoritmo cria uma malha a partir da triangulação das coordenadas dadas, sem cruzamentos de arestas. A cor de cada triângulo da malha equivale à cor média do segmento da pintura original.

Todo o código-fonte assim como as “pinturas” geradas, e suas versões para impressão, encontram-se em <http://github.com/automata/tri-delaunay>.

As Figuras D.1 mostram fotos da exposição. O objetivo foi desmistificar o processo de geração das imagens, mostrando junto com a imagem final, cada passo do algoritmo, ilustrado com imagens explicativas. Ainda, as instruções para o visitante acessar e executar o código-fonte para gerar suas próximas versões “remixadas” com bases em novas imagens acompanhavam cada “pintura”. As pinturas expostas foram escolhidas através da consulta à preferência de pessoas em um *thread* da lista de emails do *labMacambira.sf.net*¹ e dos próprios autores deste estudo²

¹ <http://labmacambira.sf.net>

² Em <https://etherpad.mozilla.org/genpaintings> encontra-se o *pad* com as sugestões levantadas, assim como um esboço de uma matéria sobre as pinturas que pretende-se publicar na revista aberta e independente *Quiosque*.

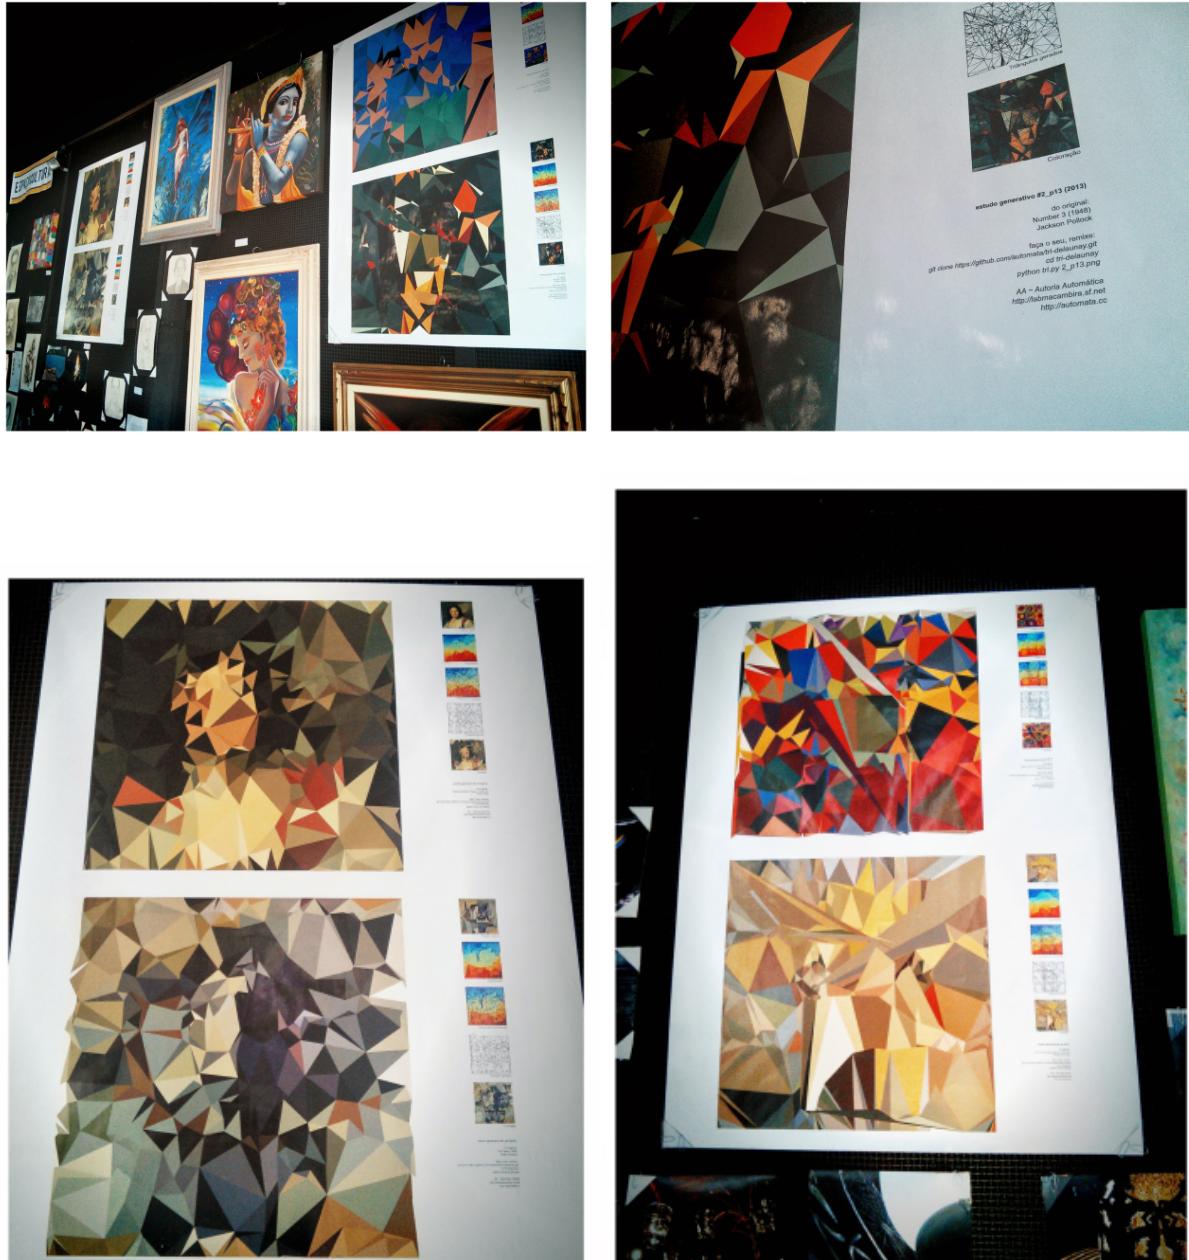


Figura D.1 – Fotos da exposição realizada no SIFISC 2013 com imagens geradas por algoritmo desenvolvido em paralelo a este estudo.