

**Universidade de São Paulo
Instituto de Física de São Carlos
Departamento de Física e Ciências dos Materiais
Grupo de Computação Interdisciplinar**

VILSON VIEIRA

**Um Estudo Quantitativo sobre a Evolução de
Movimentos Artísticos**

São Carlos

2014

VILSON VIEIRA

Um Estudo Quantitativo sobre a Evolução de Movimentos Artísticos

Dissertação apresentada ao Programa de Pós-graduação em Física do Instituto de Física de São Carlos da Universidade de São Paulo, para a obtenção do título de Mestre em Ciências.

Área de Concentração: Física Aplicada

Orientador: Prof. Dr. Gonzalo Travieso

Colaborador: Prof. Dr. Luciano da Fontoura Costa

Versão Corrigida

(versão original disponível na Unidade que aloja o Programa)

São Carlos

2014

AUTORIZO A REPRODUÇÃO E DIVULGAÇÃO TOTAL OU PARCIAL DESTE
TRABALHO, POR QUALQUER MEIO CONVENCIONAL OU ELETRÔNICO,
PARA FINS DE ESTUDO E PESQUISA, DESDE QUE CITADA A FONTE.

AGRADECIMENTOS

Sinceros agradecimentos ao Prof. Gonzalo Travieso e ao Prof. Luciano da Fontoura Costa. Tenham certeza que foi com vocês que aprendi o que é fazer pesquisa. Foram ensinamentos que guardarei para toda a vida. Além da orientação de excelência, ficará para sempre a amizade.

Aos meus queridos pais, Vilson e Salete, sabem que devo tudo o que sou a vocês. Encontro sempre suas palavras de conforto e sabedoria em cada esquina que cruzo, em cada caminho que percorro. Amo muito vocês.

À minha amada, Gabriela, que esteve ao meu lado em cada momento, bom ou ruim, por seu amparo, carinho e cumplicidade. Te amo.

À Paulo e Lourdes pelas conversas sempre animadas, e à Isabela pelas risadas sempre prontas às minhas piadas :-D

Aos meus irmãos Renato e Ricardo Fabbri, que me acolhem com tanto carinho e com quem espero viver ainda ótimas passagens. Renato, obrigado por ser um verdadeiro mentor.

Ao bom amigo e conselheiro Pedro Kroeger, continuas sendo a quem sigo os passos.

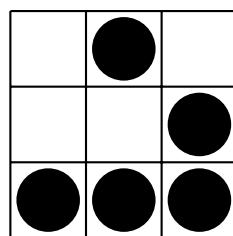
A todos do labMacambira.sf.net, por todas as colaborações e aprendizados, seja artisticamente, cientificamente, socialmente, em *software*, em *tinta*, em *notas* ou em *espírito*.

À Mozilla Foundation e seus colaboradores, em especial ao bom amigo Forrest Olliphant, que me mentorou enquanto participante do Googler Summer of Code 2012 e com quem continuo compartilhando ótimas conversas e desenvolvimentos. Thank you Fo!

A todos os amigos que fiz no IFSC/USP, em especial Carlos Doro Neto (valeu pelo *Doro's method!*), David Sbrissa (*bit*****!*), prof. Osvaldo “Chu”, prof. Rodrigo Guido, profa. Yvonne Mascarenhas, Débora Correa, Mauro Miazaki, Diego, César, Thomás, Filipi. Aos parceiros do *hacklab do velho*, tenho grande carinho por todos vocês.

Não sei se conseguirei lembrar de todos, mas meu especial agradecimento e grande carinho a Daniel Penalva, Caleb Luporini, Guilherme Lunhani, Geraldo Magela Rocha, Glerm Soares, Chico e Fábio Simões, Daniel Marostegan, prof. Rogério “Zeco” Silva, Gilson Beck, Marcos Mendonça, Danilo Shiga, Edson Corrêa, Vanessa Ferreira, prof. Luis Castelões, Luis Fernando Muniz Cirne, Marília Pisani, prof. Massimo Canevacci. À Teia Casa de Criação e Pontão Nós Digitais, ao MuSA, aos amigos da Udesc, à galera do AVAV, do Crânio Sonante, a todos que tive contato real e virtualmente, nas listas de email, AA, IRC e outras redes e canais.

Agradeço às comunidades de cultura e software livre e aberto por todos os conhecimentos e tecnologias repassados e que compõem esta contribuição.



“Art is made to disturb. Science reassures. There is only one valuable thing in art: the thing you cannot explain.”

— GEORGES BRAQUE

“Science is what we understand well enough to explain to a computer, art is everything else.”

— DONALD KNUTH

“Todos querem entender de arte. Por que não tentam entender o canto de um pássaro?”

— PABLO PICASSO

RESUMO

VIEIRA, V. **Um Estudo Quantitativo sobre a Evolução de Movimentos Artísticos.** 2014. 253p. Dissertação (Mestrado) - Instituto de Física de São Carlos, Universidade de São Paulo, São Carlos, 2014.

Enquanto muitos estudos são feitos para a análise e classificação de pinturas e outros ramos das Artes, este estudo não se detém somente à classificação. Extende-se aqui um método de análise já aplicado à Música e Filosofia (1), representando a evolução da Pintura como uma série temporal onde relações como *oposição*, *inovação* e *dialética* são medidas quantitativamente. Para isso, um *corpus* de pinturas de 12 artistas reconhecidos do período Barroco e de movimentos da Arte Moderna foram analisadas. Um conjunto de 99 atributos foi extraído e os atributos que mais contribuíram para a classificação das pinturas foram selecionados. O espaço de projeção obtido a partir desses atributos criou a base para a análise de medidas. Essas medidas quantitativas revelaram observações sobre a evolução dos estilos artísticos, especialmente quando comparados com outras áreas do conhecimento humano já analisados. A Música parece ter evoluído com a influência de uma tradição mestre-aprendiz (i.e. por apresentar alta dialética entre os músicos estudados). A Filosofia apresenta valores altos de oposição entre os representantes escolhidos (1), sugerindo que sua evolução apresenta constante oposição de ideias. Já na Pintura nota-se um outro padrão: aumento constante da inovação, baixa oposição entre membros do mesmo período artístico e picos de oposição no momento de transição entre estes períodos. Uma diferença entre os movimentos Barroco e movimentos da Arte Moderna foi também percebido no espaço projetado: enquanto as pinturas barrocas aparecem formando um agrupamento sobreposto, as pinturas modernas apresentam quase nenhuma sobreposição e estão dispostas espalhadas ao longo da projeção, mais que as barrocas. Essa observação encontra base na história da Arte onde os pintores barrocos compartilham características estéticas de suas pinturas, enquanto os modernos tendem a desenvolver seus próprios estilos e, por conseguinte, suas próprias estéticas.

Palavras-chave: Reconhecimento de padrões. Mecânica estatística. Arte. Pintura. Barroco. Arte Moderna. Extração de atributos. Criatividade. Arte e tecnologia.

ABSTRACT

VIEIRA, V. **A Quantitative Study about Artistic Movements Evolution.** 2014. 253p. Dissertação (Mestrado) - Instituto de Física de São Carlos, Universidade de São Paulo, São Carlos, 2014.

While many studies were performed for the analysis and classification of paintings and other art venues, this study does not stop in the classification step. It extends an analysis method already applied to music and philosophy, representing the evolution of painting as a time-series where relations like *opposition*, *skewness* and *dialectics* were measured quantitatively. For that, a corpus of paintings of 12 well-known artists from Baroque and Modern art was analyzed. A set of 99 features was extracted and the features which most contributed to the classification of painters were selected. The projection space obtained from the features provided the basis to the analysis of measurements. This quantitative measures underlie revealing observations about the evolution of art styles, even when compared with other humanity fields already analyzed. While music evolved guided by a master-apprentice tradition (high dialectics) and philosophy by opposition, painting presents another pattern: constant increasing skewness, low opposition between members of the same movement and opposition peaks in the transition between movements. A difference between Baroque and Modern movements are also observed in the projected “creative space”: while Baroque paintings are presented as an overlapped cluster, the Modern paintings presents minor overlapping and are disposed more scattered in the projection than baroques. This finds basis in arts history where Baroque painters were guided by traditional rules while Modern painters tended to “break” these rules and develop their own style.

Keywords: Pattern recognition. Arts. Painting. Feature extraction. Creativity. Arts and technology.

LISTA DE FIGURAS E TABELAS

Figura 1.1 -	A imagem superior é a ilustração “Reconstrução do Templo de Jerusalém” (1200-1300) para o livro “ <i>Histoire d’Outremer</i> ”, de Guilherme de Tiro. Esta pintura antecede o método de perspectiva de Brunelleschi e portanto é possível notar a ausência de linhas que converjam para um só ponto, embora haja a intenção da representação de profundidade, pela sobreposição dos elementos. Já a imagem inferior, um afresco de Pietro Perugino (1481-1482), apresenta o estilo de perspectiva, com todas as linhas convergindo para o centro da imagem, em seu horizonte. As imagens ilustram como o estilo pode influenciar mudanças nas características das obras ao longo da história	30
Figura 2.1 -	<i>Judite e Holoferne</i> (Caravaggio), c. 1599	36
Figura 2.2 -	<i>Retrato de Isaak Abrahamsz Massa</i> (Frans Hals), c. 1626	37
Figura 2.3 -	<i>Uma Dança para a Música do Tempo</i> (Nicolas Poussin), c. 1634-1635	38
Figura 2.4 -	<i>Velha Fritando Ovos</i> (Diego Velázquez), c. 1618	39
Figura 2.5 -	<i>A Tempestade no Mar da Galiléia</i> (Rembrandt van Rijn), c. 1633	39
Figura 2.6 -	<i>A Garota com Brinco de Pérola</i> (Johannes Vermeer), c. 1665 . .	40

Figura 2.7 -	<i>Quarto em Arles</i> (Vincent van Gogh), c. 1889	42
Figura 2.8 -	<i>Em Branco</i> (Wassily Kandinsky), c. 1923	42
Figura 2.9 -	<i>A mesa de jantar: harmonia em vermelho (quarto vermelho)</i> (Henri Matisse), c. 1908	43
Figura 2.10 -	<i>Violino</i> (Pablo Picasso), c. 1911-12	44
Figura 2.11 -	<i>O Campo Cultivado</i> (Joan Miró), c. 1923-24	45
Figura 2.12 -	<i>Ritmo de Outono</i> (Jackson Pollock), c. 1950	45
Tabela 2.13 -	Sumário de características do período Barroco e de cada artista dos movimentos da Arte Moderna estudados.	47
Figura 2.14 -	<i>a)</i> Dialética: um argumento chamado tese, até então tomado como verdade, é confrontado por um argumento oposto, cha- mado antítese. O resultado do confronto destas duas ideias é a síntese que irá gerar uma nova ideia ou argumento; <i>b)</i> Oposi- ção: é um argumento que se opõe a um argumento original; <i>c)</i> Inovação: tendo-se um movimento de oposição entre dois argu- mentos originais, um movimento de inovação é aquele que se afasta desta oposição, inovando.	48
Figura 2.15 -	Etapas canônicas para processamento e análise de imagens. . . .	50
Figura 2.16 -	Coordenadas das vizinhanças-4 e 8 para um dado pixel $I_{(i,j)}$ qual- quer.	52
Figura 2.17 -	Espaço de cor CIELAB. Uma cor qualquer é representada como um ponto no espaço (L^*, a^*, b^*).	57

Figura 2.18 -	a) Rotulação das regiões após aplicação de algoritmo de segmentação segundo vizinhança-4: os rótulos identificam segmentos encontrados pela segmentação, porém não revelam necessariamente regiões conexas; b) Rotulação das regiões (ou componentes) conexas após aplicação de algoritmo para identificação de regiões conexas: esta é a rotulação desejada quando o que se pretende é identificar formas em uma imagem qualquer.	60
Figura 2.19 -	a) Imagina da pintura original. b) Imagem em escala de cinza G . c) A entropia H da imagem G mapeada em uma escala de cores. É interessante notar como regiões de borda possuem entropia maior.	65
Tabela 2.20 -	Os 14 atributos de textura de Haralick, considerando: $p(i, j) = P_d(i, j)$, $p_x(i) = \sum_{j=1}^{N_g} p(i, j)$, $p_y(j) = \sum_{i=1}^{N_g} p(i, j)$, $p_{x+y}(k = i + j) = \sum_{i=1}^{N_g} \sum_{j=1}^{N_g} p(i, j)$, $p_{x-y}(k = i - j) = \sum_{i=1}^{N_g} \sum_{j=1}^{N_g} p(i, j)$. Ainda, $H(X)$ é a entropia de X e $\text{autoval}_2(X)$ é o segundo maior autovalor de X	69
Figura 2.21 -	a) Imagina da pintura original. b) Uma região segmentada da pintura. c) A curvatura extraída a partir da região segmentada. d) A curva paramétrica $k(t)$ dado um limiar em particular, com os picos em destaque.	71
Tabela 2.22 -	Sumário de todos os 99 atributos utilizados neste estudo, considerando detalhes de contraste, textura (descritas pelas medidas de entropias e energias, assim como as medidas de Haralick) e forma (descritas pelas medidas de curvatura e medidas geométricas como perímetro, área e sua razão).	76

Figura 2.23 -	Esquema representando uma matriz de confusão. Deseja-se que a diagonal principal possua valores próximos ao número máximo de elementos em cada classe C_i , caracterizando assim uma boa classificação. C_i é uma classe do conjunto de treino e \hat{C}_i uma classe do conjunto de teste.	80
Tabela 3.1 -	Pintores escolhidos para a análise, exibidos em ordem cronológica, juntamente com o estilo artístico que melhor representa. Divididos em dois grupos: 6 pintores barrocos e 6 pintores modernos.	83
Tabela 3.2 -	Algumas das 240 pinturas juntamente com a data de sua criação. Todas as pinturas usadas no estudo estão apresentadas em forma de galeria no Apêndice B.	84
Figura 3.3 -	Pré-processamento para recorte das imagens originais em janelas de dimensão 800×800 . <i>a)</i> a imagem original, <i>b)</i> a janela em destaque, <i>c)</i> a imagem de dimensões 800×800 utilizada neste estudo. Embora se percam detalhes da imagem original, o janelamento é necessário para facilitar o processamento ao se utilizar uma dimensão única para as imagens.	85
Figura 3.4 -	Pré-processamento utilizando equalização por histograma e filtro de médias com janelamento de raio 3. <i>a)</i> a imagem original em escala de cinza, <i>b)</i> a imagem equalizada, <i>c)</i> a imagem filtrada através do filtro de médias. Pode-se perceber que a luminosidade da imagem está homogênea e seus detalhes de borda foram suavizados.	86

Figura 3.5 -	Tipos de imagens utilizadas no estudo. <i>a</i>) imagem colorida I em formato RGB, <i>b</i>) imagem em escala de cinza G , e <i>c</i>) imagem binária B	87
Figura 3.6 -	Experimentos realizados para segmentação de pinturas. <i>a</i>) a imagem original, <i>b</i>) segmentação por Watershed, <i>c</i>) Felzenswald, <i>d</i>) SLIC com $k = 10$ e <i>e</i>) SLIC com $k = 20$. O método SLIC foi escolhido por apresentar, visualmente, melhor separação dos segmentos, e os parâmetros escolhidos contribuíram para a segmentação apresentada.	88
Figura 3.7 -	Pós-processamento através da rotulação dos componentes conexos e sua filtragem, removendo as regiões com áreas menores que um dado limiar. <i>a</i>) Detalhe de regiões segmentadas através do algoritmo SLIC, <i>b</i>) objetos rotulados, <i>c</i>) objetos com área menor que limiar removidos. É a partir desta última imagem que se realizou a extração de características.	89
Figura 3.8 -	Regiões segmentadas e suas respectivas curvaturas. Os marcos em vermelho identificam os picos de curvatura no perfil e sua localização na região segmentada.	90
Figura 3.9 -	Diagrama com todos os passos tomados, desde o processamento das imagens das pinturas até a extração de características, assim como a obtenção da série temporal onde foram calculadas as medidas de oposição, inovação e dialética.	91

Tabela 3.10 -	Pares de atributos $F_{N,a}$ e $F_{N,b}$ ordenados por α . Pares com valores maiores de α mostram maior dispersão inter-classe enquanto menor dispersão intra-classe (maior agrupamento). O melhor par de atributos: <i>média dos picos de curvatura</i> e <i>média do número de segmentos</i> são selecionados para a análise e cálculo das medidas.	92
Figura 3.11 -	Matrizes esparsas para cada i -éximo par de atributos listado na Tabela 3.10 com os maiores valores para α . A primeira projeção (par 1) foi utilizado nesse estudo.	93
Figura 3.12 -	Cálculo dos índices de oposição $W_{i,j}$ — com base no deslocamento \vec{D}_i e inovação $s_{i,j}$ dados dois estados consecutivos \vec{p}_i e \vec{p}_j	95
Figura 3.13 -	Cálculo da contra-dialética $d_{i \rightarrow k}$ dados os estados consecutivos de tese \vec{p}_i , antítese \vec{p}_j e síntese \vec{p}_k . Quanto maior o valor da distância $d_{i \rightarrow k}$ de \vec{p}_k à síntese ideal formada pela bissetriz $B_{i,j}$ entre \vec{p}_i e \vec{p}_j , menor a dialética.	96
Figura 3.14 -	Projeção do <i>espaço criativo</i> considerando o melhor par de atributos <i>média de picos da curvatura</i> e <i>média do número de segmentos</i>	97
Figura 3.15 -	Série temporal considerando o melhor par de atributos <i>média de picos da curvatura</i> e <i>média do número de segmentos</i>	98

Figura 3.16 -	Histogramas dos níveis médios de cinza para todos os pintores barrocos. Vermeer e Velázquez mostram maior similaridade com Caravaggio do que os outros pintores barrocos: a proximidade em contraste encontra fundamento na história (Seção 2.1.3), tendo sido ambos pintores influenciados por Caravaggio.	101
Figura 3.17 -	Histogramas nos níveis médios de cinza para os pintores modernos. Há baixa similaridade entre os pintores modernos, diferente do que ocorre para os pintores barrocos.	102
Tabela 3.18 -	Índice de oposição $W_{i,j}$ e inovação $s_{i,j}$ para cada um dos 11 deslocamentos de um pintor a outro.	103
Figura 3.19 -	Valores de oposição $W_{i,j}$ e inovação $s_{i,j}$ considerando os dois melhores atributos.	104
Tabela 3.20 -	Índices de contra-dialética para cada um dos 10 deslocamentos entre tese, antítese e síntese, considerando os dois melhores atributos.	105
Figura 3.21 -	Valores de contra-dialética considerando os dois melhores atributos.	106
Tabela 3.23 -	Índices de oposição e inovação para cada um dos 11 deslocamentos de um pintor ao outro.	106
Figura 3.22 -	Série temporal resultante da projeção em 2 dimensões do <i>espaço criativo</i> considerando os dois primeiros componentes com maiores autovalores obtidos a partir da transformação LDA na matriz de $N = 99$ atributos.	107

Figura 3.24 -	Valores de oposição e inovação considerando a série temporal para todos os $N = 99$ atributos refletidos nos dois primeiros componentes obtidos pelo método LDA. Os mesmos padrões observados quando considerando os dois melhores atributos ainda permanecem nessa observação, como esperado.	108
Tabela 3.25 -	Índices de contra-dialética para cada um dos deslocamentos para os dois melhores componentes do LDA.	109
Figura 3.26 -	Contra-dialética (valores altos indicam baixa incidência de dialética) calculada para os componentes principais obtidos por LDA. O padrão observado anteriormente para o melhor par de atributos apresenta-se ainda mais visível aqui: é possível observar claramente que o maior valor está no ponto de transição dos movimentos artísticos (van Gogh e Kandinsky).	110

Figura 3.27 -	Matriz de confusão média para o método LDA calculada durante 100 iterações. Metade das pinturas de cada artista é usado como conjunto de treino e a metade restante como conjunto de teste. Os elementos da diagonal principal mostram o número de amostras da classe esperada que correspondem com a classe obtida pelo método. Dada a grande quantidade de valores na diagonal principal, a validação sugere que o método LDA foi suficiente para a classificação das pinturas. Além disso, detalhes já observados nos resultados desse estudo são novamente observados na matriz: deslocamento de Van Gogh e similaridade entre pintores do mesmo período, principalmente Barroco. A função de acurácia também foi calculada, equivalendo em média a 58% de acurácia.	111
Figura B.1 -	Caravaggio	127
Figura B.2 -	Frans Hals	128
Figura B.3 -	Nicolas Poussin	129
Figura B.4 -	Diego Velázquez	130
Figura B.5 -	Rembrandt Harmenszoon van Rijn	131
Figura B.6 -	Johannes Vermeer	132
Figura B.7 -	Vincent van Gogh	133
Figura B.8 -	Wassilly Kandinsky	134
Figura B.9 -	Henri Matisse	135
Figura B.10 -	Pablo Picasso	136

Figura B.11 -	Joan Miró	137
Figura B.12 -	Jackson Pollock	138
Figura C.1 -	Visualização alternativa das projeções das Figuras 3.14 e 3.15. É possível perceber detalhes de contraste e cor e sua influência no agrupamento e separação dos grupos de pintores.	140
Figura C.2 -	Detalhe da Figura C.1 do grupo onde há maior concentração de pintores. Nota-se que alguns pintores, como van Gogh, apresentam uma classificação com nenhuma sobreposição, enquanto outros, principalmente aqueles do grupo Barroco, apresentam grande sobreposição.	141
Figura C.3 -	Detalhe da Figura C.1 do grupo de pinturas pertencentes exclusivamente à Jack Pollock. Por este pintor ter características que foge aos demais artistas, suas pinturas apresentam-se distribuídas afastadas consideravelmente dos outros pintores.	142
Figura D.1 -	“Pintura” generativa.	145
Figura D.2 -	“Pintura” generativa.	146
Figura D.3 -	Fotos da exposição realizada no SIFISC 2013 com imagens geradas por algoritmo desenvolvido em paralelo a este estudo. . . .	147
Figura D.4 -	Prévia do conteúdo de publicação impressa prevista para 2014 das pinturas generativas pela editora independente Quiosque. . .	148

Sumário

1	Introdução	28
1.1	Motivação	32
1.2	Objetivos	33
1.3	Organização	33
2	Fundamentos	35
2.1	Uma breve exploração sobre o Barroco e Arte Moderna	35
2.1.1	Barroco	35
2.1.2	Arte Moderna	41
2.1.3	Sumário de características do período Barroco e de movimentos da Arte Moderna	46
2.2	Conceitos básicos em Filosofia	47
2.3	Processamento e análise de imagens	49
2.3.1	Conceitos úteis de Geometria Discreta, Morfologia Matemática e Estatística	51
2.3.2	Pré-processamento	54
2.3.3	Segmentação	56

2.3.4	Pós-processamento	59
2.4	Extração de atributos	62
2.4.1	Atributos de complexidade	63
2.4.2	Atributos de textura	67
2.4.3	Atributos de contorno e forma	68
2.5	Redução de dimensionalidade e classificação	75
2.5.1	Validação Cruzada	79
3	Desenvolvimentos e Resultados	82
3.1	Pintores escolhidos	82
3.2	Corpus de pinturas	83
3.3	Análise de imagens para extração de atributos	83
3.4	Seleção de atributos	87
3.5	Medidas de dialética, oposição e inovação	90
3.6	Análise das pinturas para atributos com maior dispersão	95
3.7	Análise por LDA de todos os atributos	102
4	Conclusões	112
REFERÊNCIAS		116
Apêndice A – Tutorial para execução dos <i>scripts Python</i> desenvolvidos para análise		123

Apêndice B – Galeria de imagens das 240 pinturas analisadas	126
Apêndice C – Visualizações complementares	139
Apêndice D – Pinturas generativas por tesselação de Delaunay. Estudo 4	143

1 *Introdução*

A história da Arte costuma ser dividida em períodos, tendências, escolas, estilos e mais recentemente, em movimentos artísticos (2). Um período compreende o limite de tempo onde certas características predominam entre as obras. Neste dado período há o desenvolvimento de tendências: características na linguagem artística (i.e. cores, texturas, materiais, composições) que tornaram-se marcantes no período e serão transmitidas para as próximas gerações, seja por sua afirmação ou refutação. Essas tendências, ao se consolidarem, podem ser chamadas de escolas ou estilos. Os movimentos artísticos também possuem ideias e características comuns, mas costumam ter bem definido sua data de criação, local e participantes, assim como um manifesto.

Seja qual for a classificação tomada para a história das artes e de seus artistas em termos de movimentos e períodos, é possível perceber algo latente: as características de suas obras estão em constante transformação, definindo os diferentes períodos ou escolas. A história da Arte é portanto permeada por uma sucessão de similaridades e oposições destas características ou ideias. A Pintura oferece inúmeros exemplos. Brunelleschi e Alberti inauguraram um estilo de pintura (3, 4) onde conseguiam representar a profundidade visível de uma cena utilizando um método geométrico: linhas paralelas convergindo em um ou mais pontos no horizonte. (Figura 1.1). Até então as pinturas, afrescos, mosaicos e desenhos não tinham noção alguma de profundidade — os elementos que compunham a pintura eram distribuídos segundo sua importância espiritual ou temática (5), utilizando por exemplo, a simples sobreposição dos elementos na tela. Esse estilo acabaria por fazer parte das características da grande maioria das pinturas

a partir do século XV (6). Porém, ela não foi suficiente para Cézanne nem seus contemporâneos da Arte Moderna, que estavam descontentes com essa “equação matemática” e usaram gradações de cores para representar a profundidade, rompendo com a tradição iniciada por Brunelleschi e Alberti (7).

Outros estilos de pintura como o *sfumato* (onde as pinceladas que definem bordas e linhas são removidas com verniz de madeira, comum nas pinturas renascentistas, sendo a “Monalisa” de Leonardo da Vinci (8, 9) seu principal exemplo), as cores da Escola de Viena (10), o movimento e a expressão (6, 11), foram criados por cada geração de artistas em uma tentativa de expressar as características que desejavam. E a cada geração, estes mesmos artistas descobriram que continuavam existindo convenções que os obrigavam a aplicar o que haviam aprendido ao invés de pintarem o que realmente viam. Os “rebeldes” da Arte Moderna acabaram por negar essas convenções, criando novos meios. Van Gogh não estava interessado em seguir exatamente as regras da perspectiva e profundidade, ao invés disso, deformava a imagem para ressaltar detalhes que lhe eram relevantes. Picasso não se importava que o resultado final de sua obra parecesse distância do modelo original, e desta forma sentia-se livre para retratar verdadeiras colagens das várias perspectivas possíveis do modelo, todas sobrepostas na mesma pintura. Miró pintava símbolos baseando-se em um dicionário que criara, sendo um dos primeiros a utilizar a pintura automática. O século XX presencia a passagem de uma geração de experimentadores, inventores, que davam maior preferência à originalidade do que à tradição. Não queriam mais a “fidelidade” de Caravaggio ou a “beleza ideal” de Poussin, buscavam “expressividade intensa, clareza de estrutura e uma simplicidade linear na técnica” (6). No modernismo não existiam estilos predominantes — como no caso do período Barroco — mas existiam sim várias abordagens, criadas ou desenvolvidas por cada artista. Como bem dito por Gombrich(6): “Qualquer afastamento da tradição que interessasse à crítica e atraísse um seguidor era saudado como um novo *ismo* ao qual o futuro pertenceria”. Essa inquietação moderna é avistada nas linhas retas e arquitetura funcional das casas e prédios do outro lado da rua, apenas para citar uma das



Figura 1.1 – A imagem superior é a ilustração “Reconstrução do Templo de Jerusalém” (1200-1300) para o livro “Histoire d’Outremer”, de Guilherme de Tiro. Esta pintura antecede o método de perspectiva de Brunelleschi e portanto é possível notar a ausência de linhas que converjam para um só ponto, embora haja a intenção da representação de profundidade, pela sobreposição dos elementos. Já a imagem inferior, um afresco de Pietro Perugino (1481-1482), apresenta o estilo de perspectiva, com todas as linhas convergindo para o centro da imagem, em seu horizonte. As imagens ilustram como o estilo pode influenciar mudanças nas características das obras ao longo da história

influências que a Arte Moderna acabou por tornar presente no dia-a-dia.

É justamente essa sucessão de oposições e similaridades entre características nas obras artísticas

que torna este estudo possível. Nele, busca-se entender essa evolução de uma maneira quantitativa, através de medidas geométricas. Estas medidas têm como base conceitos centrais no estudo da Filosofia: *oposição, inovação e dialética* (12–14). A dialética por exemplo é definida como um método de argumentação onde busca-se a síntese entre dois argumentos contraditórios: a tese e a antítese. São conceitos originalmente qualitativos. O que se promove neste estudo é um ponto de vista alternativo. Tese, antítese e síntese são definidas como estados em uma série temporal pertencente a um espaço vetorial. E a dialética torna-se assim uma medida geométrica: o inverso da distância entre o estado de síntese e a bissetriz formada pelos estados de tese e antítese. Quanto menor a distância, maior a dialética, pois o estado de síntese se aproxima da bissetriz, que modela no espaço vetorial o que seria a síntese ideal entre as ideias de tese e antítese. Pode-se agora falar em *quanto* um argumento apresenta dialética. Ou se um dado argumento possui dialética maior ou menor que outro, apresentando para isso, valores numéricos.

Para ser possível tal análise, é necessária a representação dos agentes envolvidos — nesse caso, pintores e suas obras — em um espaço geométrico onde as medidas são então realizadas. Esse mapeamento começa com a seleção de imagens de pinturas. Um grupo de 12 pintores é selecionado, sendo 6 pintores representantes reconhecidos do período Barroco e outros 6 pintores de movimentos da Arte Moderna. A escolha de grupos tão distantes cronologicamente tem seu motivo: a História das Artes reconhece diferenças contrastantes entre o período Barroco e os vários movimentos da Arte Moderna, porém tais afirmações são qualitativas. Neste estudo, busca-se afirmar ou refutar estas afirmações com base em medidas quantitativas. Um total de 20 pinturas de cada pintor é escolhido aleatoriamente, formando um conjunto de 240 pinturas a serem analisadas. Métodos de processamento e análise de imagens são aplicados para extrair atributos que caracterizam cada pintura. Através da análise de matriz de espalhamento e LDA (Linear Discriminant Analysis) (15, 16), os atributos que melhor classificam as pinturas em seus respectivos pintores são selecionados. Esses vetores de atributos, agora com dimensões

reduzidas, formam então o espaço vetorial pretendido. Considerando tais vetores em ordem cronológica, tem-se uma série temporal e é nessa série que se dá o cálculo das medidas sugeridas para a oposição, inovação e dialética.

Enquanto valores numéricos, tais medidas revelam padrões que encontram paralelo na história da Arte. Um exemplo marcante é o contraste encontrado nos grupos de estados dos pintores barrocos e modernos. Enquanto todo o grupo Barroco apresenta sobreposição entre seus pintores, o grupo de pintores modernos apresenta quase nenhuma sobreposição. Essa observação encontra base na história das artes, onde os pintores barrocos, reconhecidamente, compartilham técnicas uns com os outros — e portanto, compartilham também características estéticas em suas pinturas — enquanto os modernos são marcados pelo individualismo, cada qual definindo seu próprio estilo.

As medidas, assim como o método sugerido, são independentes de domínio, o que possibilita sua aplicação para a análise de outras áreas humanas além da Pintura. Até então, Filosofia, Música (1) e Pintura têm sido avaliadas, porém aplicações em Cinema, Literatura ou Arquitetura são possíveis. Tal flexibilidade permite também a comparação entre as medidas obtidas para cada área de conhecimento. Por exemplo, é possível notar que na Música há predomínio de valores altos para a dialética, enquanto na Filosofia, a oposição é o caráter predominante (1). Já na Pintura, há constante inovação, e ambas oposição e dialética possuem maior valor no momento de transição de um movimento artístico ao outro. Novamente, cada um desses resultados encontra fundamento na história e nas características de cada um de seus autores e obras.

1.1 Motivação

A subjetividade na análise da história das artes sugere métodos mais objetivos que complementem tal análise. É importante ressaltar que tal método não pretende esgotar ou suplantar a análise subjetiva, humana, mas sim complementá-la, somar ao ferramental metodológico já

existente. Da mesma forma, conceitos como a dialética possuem grande importância nas Ciências Humanas, mas são comumente tratados de maneira qualitativa.

Ainda, a possibilidade de automatizar o cálculo dos atributos usados para análise também motivou esse estudo. No estudo anterior (1), os atributos eram fornecidos por críticos (os próprios autores) através de notas dadas a uma determinada característica de uma obra (e.g. no caso da Música, a presença ou não de complexidade rítmica em uma peça musical era uma característica considerada). Aqui buscou-se automatizar esse processo, com o uso de processamento e análise de imagens para extrair atributos das pinturas. Procura-se assim investigar se nesta nova área de aplicação haveriam similaridades com as áreas já analisadas.

1.2 Objetivos

Em uma única sentença, modelar artefatos produzidos por artistas (no caso, pinturas, mas poderiam ser peças musicais ou poemas) como um conjunto de características passíveis de serem projetadas em um espaço geométrico onde conceitos subjetivos — antes apenas de domínio das Ciências Humanas — como dialética, oposição e inovação podem ser calculados como medidas quantitativas, oferecendo uma forma complementar à interpretação da evolução da história artística.

1.3 Organização

No Capítulo 2 são descritos os fundamentos, algoritmos, métodos canônicos e detalhes históricos sobre os quais se construiu este estudo, assim como trabalhos correlacionados e de interessante leitura. O Capítulo 3 apresenta os desenvolvimentos realizados nesse estudo: como as pinturas foram processadas a ponto de fornecerem um conjunto de características que tornou possível a representação da evolução artística em um plano geométrico assim como o cálculo de

medidas de dialética, oposição e inovação. Ainda, são apresentadas essas projeções e medidas geométricas, assim como sua interpretação em um contexto histórico e crítico. Os resultados são validados pelo cálculo dos componentes que mais separam os grupos de pintores, através do método LDA. Este, por sua vez, é validado por uma matriz de confusão. Por fim, o Capítulo 4 faz uma revisão do que foi discutido e aponta as principais contribuições e conclusões desse estudo, além de refletir sobre desenvolvimentos futuros e que já estão em andamento. Os Apêndices apresentam um tutorial para *download* e execução dos *scripts Python* que implementam os algoritmos desenvolvidos para essa análise, assim como uma galeria com miniaturas de todas as imagens das 240 pinturas usadas no estudo, além de visualizações alternativas da série temporal resultante e a descrição de uma exposição realizada no IFSC/USP com imagens geradas a partir de um algoritmo para pintura generativa desenvolvido nesse trabalho.

2 *Fundamentos*

Onde são descritos os fundamentos, algoritmos, métodos canônicos, sobre os quais se construiu os desenvolvimentos.

2.1 Uma breve exploração sobre o Barroco e Arte Moderna

É interessante levantar aqui algumas características sobre a história e estética presente no período Barroco e nos movimentos da Arte Moderna, quando relacionados à pintura. Tais pontos estão sumarizados na Seção 2.1.3 e serão confrontados com observações obtidas pela análise das medidas quantitativas, discutidas no Capítulo 3. O resumo biográfico de cada artista considerado auxilia na avaliação de tais resultados.

2.1.1 Barroco

O Barroco na pintura é marcado pela tradição, pelo desejo de retratar a verdade (encontrado nas obras de Caravaggio, Frans Hals e Velázquez), a beleza (em Poussin, Vermeer), o sagrado (Caravaggio, Rembrandt). Esteticamente, é notável o uso do contraste de luz para dar destaque a um determinado local da pintura enquanto escurece regiões menos importantes (como na técnica do “*chiaroscuro*” de Caravaggio), a preferência por oposições complexas e desprezo pelo equilíbrio simplista na composição dos elementos em uma pintura. Emprega tais estéticas para causar emoções em quem contempla os quadros, geralmente de caráter sagrado, retratando pas-

sagens bíblicas com grande fidelidade aos detalhes. A transmissão dessas técnicas ou estéticas de um pintor para o outro é comum no Barroco. Espera-se, portanto, que pintores barrocos apresentem uma grande similaridade estética em suas obras (6, 10, 17). Para o presente estudo, os seguintes pintores foram escolhidos por representarem, reconhecidamente, características do período Barroco:

Miguel Ângelo da Caravaggio, Itália, 1573-

1610. Após a Renascença, foram Annibale Carracci e Miguel Ângelo da Caravaggio (18) que, mesmo tendo métodos completamente opostos, amplificaram as ideias já apresentadas em Tintoretto e El Greco durante o chamado Maneirismo (19): ênfase sobre luz e cor, desprezo pelo simples equilíbrio, preferência por oposições complexas. Tais ideias foram apresentadas de uma nova maneira e inauguraram o que viria a ser o período Barroco (17). Caravaggio — diferente de Carracci que se preocupava em retratar o belo — queria retratar a verdade, como a via, em detalhes. Essa busca pela verdade pode ser vista em *Judite e Holoferne* (Figura 2.1). (20, 21)



Figura 2.1 – Judite e Holoferne (Caravaggio), c. 1599

O uso da luz, contrastando rigidamente com o negro fundo, colabora para ressaltar a jovialidade de Judite, que demonstra ter convicção do que faz: cortar a cabeça de Holoferne. Sua serva por outro lado, demonstra nervosismo, esperando que o pedaço de carne morta encha o saco de pano que segura. É possível sentir o horror, a surpresa e impotência de Holoferne enquanto é arrancado de seu sono por sua própria espada. Caravaggio fornece assim uma interpretação de notável detalhismo da passagem bíblica: “Então Judite se aproximou da coluna da cama,

que ficava junto à cabeça de Holoferne, e pegou a espada dele. Depois chegou perto da cama, agarrou a cabeleira de Holoferne, e pediu: Dá-me força agora, Senhor Deus de Israel. E com toda a força, deu dois golpes no pescoço de Holoferne e lhe cortou a cabeça. Rolou o corpo do leito e tirou o mosquiteiro das colunas. Depois saiu, entregou a cabeça de Holoferne para a serva, que a colocou na sacola de alimentos.” (Judite 13, 6)

Frans Hals, Holanda, 1580?-1666. Ao mesmo tempo que o Barroco era iniciado na Itália, que compreendia a metade católica da Europa — Roma foi neste período o que a França foi mais a frente: o centro de discussões e atenções artísticas — em sua parte protestante não havia espaço para pintar o sagrado. (6) Sobravam os retratos como fonte de renda e Frans Hals (22) soube bem como pintá-los — embora recebendo pouco em retorno. Sua obra é constituída em grande parte por retratos de burgueses e mercadores Holandeses, como o *Retrato de Isaak Abrahamsz Massa* (Figura 2.2), mercador e amigo próximo de Hals. Embora na época a maioria dos pintores e estudantes estivessem influenciados pela técnica do “chiaroscuro” de Caravaggio, isso não se observa em Frans Hals: o fundo possui detalhes, complementa a composição e existem variações de sombra na face do modelo (o lado direito é iluminado por uma luz direta, enquanto o lado esquerdo apresenta uma sombra de luz natural). Em Caravaggio, a luz é outra, ela é direta, penetrante, artificial (6). Ao mesmo tempo, os retratos de Frans Hals diferiam dos retratos de até então. Sua pinçelada rápida permitia capturar não o modelo, mas o momento, o instante (23). Outra diferença é a pose alternativa para



Figura 2.2 – Retrato de Isaak Abrahamsz Massa (Frans Hals), c. 1626

a época. Diferente dos retratos com olhares perdidos, Frans Hals usa os olhos do modelo para expressar e compor o momento. Ao invés de um olhar perdido, Massa olha para algo que lhe chama atenção, a ponto de virar-se na cadeira.

Nicolas Poussin, França, 1594-1665. Carracci, Reni e seus seguidores retratavam uma versão “embelezada” da natureza, que imitava as estátuas clássicas. Este programa ficou conhecido como neoclássico ou “acadêmico” (6).

Poussin foi um dos grandes mestres “acadêmicos” e desta forma, foi influenciado pelo pintor que representa a oposição a Caravaggio: Carracci. Suas pinturas querem retratar a beleza, a inocência, a pureza de épocas antigas, seus mitos e histórias (24). É possível notar essa intenção na Figura 2.3 que retrata sua obra *Uma Dança para a Música do Tempo*. É interessante aqui apontar a diferença dessa composição enquanto comparada com as obras de Caravaggio e a proximidade com as pinturas de Carracci ou Reni. Ao invés do fundo escuro, da luz artificial, encontra-se uma paisagem iluminada, que se preocupa em retratar o belo. Não há espaço para o horror, para a rigidez da verdade, como acontece com Caravaggio.



Figura 2.3 – Uma Dança para a Música do Tempo
(Nicolas Poussin), c. 1634-1635

Diego Velázquez, Espanha, 1599-1660. Mesmo ainda não tendo visitado Roma, havia conhecido e se impressionado pelos trabalhos de Caravaggio. Há grande semelhança entre suas obras e as pinturas do mestre italiano, como é possível observar na Figura 2.4 da obra *Velha Fritando Ovos*.



Figura 2.4 – Velha Fritando Ovos (*Diego Velázquez*), c. 1618

Assim como Caravaggio, retrata a natureza como ela é, sua verdade é mais importante do que sua aparente beleza. Na pintura em destaque, há uma grande preocupação com os detalhes: os ovos, as mãos, as feições dos modelos, os utensílios de cozinha, o vidro que o menino segura, todos representados com precisão fotográfica. A técnica do “chiaroscuro” de Caravaggio foi aplicada, onde uma luz intensa à esquerda da pintura ilumina com grande contraste os detalhes que Velázquez queria propositalmente ressaltar, ao mesmo tempo, o fundo é tão negro que não se pode mais observar as paredes do ambiente (6).

Rembrandt van Rijn, Holanda, 1606-69. É reconhecido como o maior pintor da Holanda, dono de uma série de autorretratos que contam de forma biográfica toda a sua vida (6, 25). Rembrandt usava a técnica do “chiaroscuro” porém de maneira diferente, como é possível ver na *A Tempestade no Mar da Galiléia* (Figura 2.5). Há grande uso de contraste, mas o fundo não está mergulhado em negro, ao contrário, o céu ajuda a complementar a composição, o mesmo pode se dizer do mar. Essa mesma abordagem está presente nos retratos e outras cenas sagradas que pintou (26). De todos os pintores do Barroco, Rembrandt parece usar as técnicas de seus antepassados, mas ao mesmo tempo, se



Figura 2.5 – A Tempestade no Mar da Galiléia (*Rembrandt van Rijn*), c. 1633

contrapor a eles adicionando nuances de seu próprio estilo.

Johannes Vermeer, Holanda, 1632-1675. Uma das grandes realizações dos pintores holandeses é a retratação da natureza-morta com incrível detalhismo (27). Vermeer é considerado o grande mestre deste estilo, mas ao invés de objetos, incluía pessoas em sua natureza-morta (6). Vermeer parece procurar a melhor vestimenta, a melhor pose da modelo e a melhor posição para o ponto de luz. Parece experimentar com os objetos da cena até encontrar o que deseja. É interessante também perceber a diferença de sua pintura comparada a dos outros pintores aqui discutidos: todas são feitas praticamente no mesmo local — sempre um cômodo doméstico — e com um número limitado de modelos, geralmente com a luz vindo de uma janela (28). Em suas pinturas há, a exemplo de Velázquez, uso extensivo do “chiaroscuro” de Caravaggio, como na *A Garota com Brinco de Pérola* (Figura 2.6).



Figura 2.6 – A Garota com Brinco de Pérola (*Johannes Vermeer*), c. 1665

2.1.2 Arte Moderna

Cada época de uma civilização cria uma arte que lhe é própria e que jamais se verá renascer. Tentar revivificar os princípios artísticos de séculos passados só pode levar à produção de obras natimortas. Assim como é impossível fazer reviver em nós o espírito e as maneiras de sentir dos antigos gregos, também os esforços tentados para aplicar seus princípios [...] só levarão à criação de formas semelhantes às formas gregas. A obra assim produzida será sem alma para sempre.

Wassily Kandinsky (29)

De Vermeer à van Gogh, passam-se por volta de 150 anos, o Rococó, o Neoclassicismo, o Realismo, chegando aos movimentos da Arte Moderna. Ao contrário do Barroco, a Arte Moderna parece não compartilhar estéticas ou técnicas (2). Cada pintor aplica ou cria novas formas de representar o que vê ou sente. Como dito por Gombrich(6): “[os pintores modernos] ansiavam por uma arte que não consistisse de truques que poderiam ser aprendidos, por um estilo que não é meramente um estilo, mas algo forte e poderoso como a paixão humana”. Van Gogh procurou por essa arte através do uso intenso de cores e aspecto caricato de suas pinturas (30). Paul Gauguin buscou no “primitivismo” (31) encontrar as raízes da representação da natureza. Outros como Seurat (4) usaram da observação de propriedades físicas da visão cromática para pintar a natureza como uma coleção de pontos coloridos e dessa forma acabou criando o pontilhismo. Os pintores modernos criam seu próprio estilo de maneira individualista, sem a influência de seus contemporâneos ou predecessores (6).

A Arte Moderna é representada nesse estudo pelos seguintes pintores, que inclui representantes dos movimentos Pós-impressionista, Expressionista, Cubista, Surrealista, Dada e Abstrato:

Vincent van Gogh, Holanda, 1853-1890. Junto com Cezanne e Gaugin, van Gogh antecede o que veio a ser conhecido como “Arte Moderna” (6).

Cada pincelada de van Gogh revela sua sensação ao estar pintando, sua emoção; e garantem movimento à composição. Não estava interessado em respeitar regras de perspectiva, de composição, ou sombra (30). É possível perceber esse menosprezo pelo clássico em sua obra *Quarto em Arles* (Figura 2.7). Os móveis não apresentam perspectiva, muito menos dimensões corretas. Não há sombra na pintura. Propunha usar as cores de maneira




Figura 2.7 – Quarto em Arles (Vincent van Gogh), c. 1889

franca, sem se render às técnicas de sombreado. As pinceladas são todas aparentes, formam a própria textura. Nada tem de parecido com as obras barrocas, ou mesmo do Impressionismo. Usava a distorção dos objetos para expressar o que sentia.

Vale complementar tal figura com as palavras do próprio van Gogh em uma de suas inúmeras cartas: “Lamentavelmente, meu caríssimo amigo, o público apenas verá nesse exagero uma caricatura — mas o que nos importa isso?” (32). Mesmo sem perceber, acabara por desempenhar um papel revolucionário para as artes, e se opõe assim a todos os pintores conhecidos até então.

Wassily Kandinsky, Rússia, 1866-1944. Possivelmente inaugurou o que veio a ser conhecido como “Arte Abstrata” onde nenhum objeto é reconhecível na pintura (33). Suas pinturas encontram ressonância




Figura 2.8 – Em Branco (Wassily Kandinsky), c. 1923

com a música cromática (encontrada já em Bach em seu “Cravo Bem Temperado”, tornando-se elemento expressivo no fim do período romântico, com Liszt, Mahler e Wagner, e acabando por impulsionar o atonalismo da música serial dodecafônica, já no século XX) no sentido do uso de toda a escala cromática em uma composição (6). Kandinsky estava interessado no efeito perceptivo da cor pura, na interpretação psicológica das cores. (34) Assim, formas que lembrassem objetos da natureza não eram necessários, como visível na Figura 2.8. Esse uso das cores de maneira direta e franca já tinha sido anunciado por van Gogh, que negava o uso de sombras para tornar as cores ainda mais aparentes e expressivas, algo visto também em Kandinsky e Matisse.

Henri Matisse, França, 1869-1954. Foi o mais famoso pintor do grupo parisiense conhecido como *Les Fauves*, ou “os selvagens”, os Fauvistas (35, 36). Tal grupo foi assim chamado pelo desprezo às formas encontradas na natureza e pelo uso de cores “violentas” em suas pinturas. Dedicou-se à “simplificação decorativa” ao estudar os esquemas de cores de tapetes orientais e transpor tais esquemas para seus quadros (6). Como visto na Figura 2.9 há harmonia entre todos os elementos da pintura, fazendo com que pareçam formar um único padrão, como em um tapete.

Figura 2.9 – A mesa de jantar: harmonia em vermelho (quarto vermelho) (*Henri Matisse*), c. 1908



Até mesmo a paisagem vista da janela parece integrar-se com a sala. Os desenhos do papel de parede são encontrados também na toalha da mesa. Os contornos simples desses desenhos são encontrados também na figura humana e em todos os utensílios da sala. Por esses motivos, o pintor a chamou de “harmonia em vermelho”, ressaltando a importância da cor na obra (37).

Pablo Picasso, Espanha, 1881-1973. Estava interessado no problema de representar uma imagem através de objetos simples, mas sem perder sua característica de solidez e profundidade (6,

38).

Influenciado por Cézanne (39), emprega de forma literal seu conselho de observar a natureza como um conjunto de esferas, cones e cilindros. Procura então representar o que vê como um complexo de peças uniformes, cada uma representando uma faceta do que está sendo retratado, fundando assim o movimento cubista (40, 41). Essa colagem geométrica é vista em *Violino* (Figura 2.10). De certa forma, remonta os desenhos “primitivos” que retratam o objeto a partir do ponto de vista que mais lhe representa. Os traços dos símbolos encontrados no instrumento musical são repetidos: como as curvas da voluta, dos efes e do corpo. O mesmo grupo de 4 cordas aparece diversas vezes, como querendo representá-las de vários pontos de vista. Essa colagem de pontos de vista remete ao que se dá quando tenta-se resgatar um objeto na memória: quando imagina-se um violino, sua forma é exagerada; não se imagina um violino específico, mas um conjunto de detalhes de todos os violinos que já foram experimentados pela visão e armazenados na memória. Embora seja uma colagem de formas desconexas, a pintura aparenta organização, como que seu todo desse sentido ao objeto conhecido previamente (6).



Figura 2.10 – Violino (Pablo Picasso), c. 1911-12

Joan Miró, Espanha, 1893-1983. Inicialmente teve sua fase fauvista mas tornou-se reconhecidamente um surrealista. Miró foi um dos primeiros artistas a desenvolver a “escrita automática”, uma técnica onde o artista deixa sua mão mover-se livremente pelo papel, transferindo-a em sequida para a tela (42).

Queria com isso se desfazer das técnicas de pintura já estabelecidas. Utilizou também um dicionário de símbolos abstratos para representar objetos reais (e.g. um triângulo para a cabeça, linhas curvas para um bigode) como é visto na Figura 2.11, onde sua obra acaba por se tornar uma colagem destes símbolos (43).



Jackson Pollock, Estados Unidos, 1912-1956. Abandonou as imagens fantásticas do Surrealismo e os métodos convencionais de pintura. Pintava com as telas jogadas no chão, gotejando ou arremessando suas tintas, em pé, sobre as telas. O complexo de linhas (visto na Figura 2.12) reflete o desejo de simplificação dos artistas modernos assim como sua busca por uma “pintura pura” (6).



Figura 2.12 – Ritmo de Outono (Jackson Pollock), c. 1950

Pollock trilhou essa busca através do que ficou conhecido como “pintura de ação”: uma pintura não premeditada, criada por impulso expontâneo. Isso é afirmado pelo próprio pintor: “Não trabalho a partir de desenhos ou esboços em cores. Minha pintura é direta. [...] O método de pintar

é o resultado natural de uma necessidade. Quero expressar meus sentimentos, e não ilustrá-los. A técnica é apenas um meio de chegar a uma declaração. Quando estou pintando, tenho uma ideia geral do que estou fazendo. Posso controlar o fluxo da pintura: não há acidentes, assim como não há começo nem fim. Eu não tenho medo de fazer mudanças, de destruir a imagem, porquê a pintura tem vida própria. Eu tento deixar ela viver.” (44).

2.1.3 Sumário de características do período Barroco e de movimentos da Arte Moderna

Dadas as características presentes nas obras dos pintores escolhidos, pode-se summarizar um conjunto de afirmações que serão confrontadas no Capítulo 3 de resultados:

- Os pintores da Arte Moderna são caracterizados por sua independência em estilo: há pouca similaridade entre suas obras e de suas obras com aquelas do período Barroco. Já os pintores do período Barroco apresentam semelhanças, por compartilharem estilos tradicionais.
- Há uma diferença considerável de tempo decorrido desde o Barroco até os movimentos da Arte Moderna, assim como diferenças estéticas marcantes entre estes dois períodos;
- Pollock apresenta pinturas que diferem de todos os outros pintores escolhidos. Suas pinturas chegam a sugerir aleatoriedade, contrastando até mesmo com pintores também surrealistas como Miró e afastando-se por completo dos artistas barrocos;
- Velázquez e Vermeer se assemelham com Caravaggio pois ambos utilizavam *chiaroscuro*. Velázquez chegou a estudar as pinturas de Caravaggio e a semelhança de suas obras é notável;
- Caravaggio é o principal expoente no uso da técnica do *chiaroscuro*, apresentando pinturas com predominância de cores escuras. Portanto há grande diferença de contraste entre

suas pinturas e àquelas mais modernas, sendo estas mais claras;

- O Barroco tem como objetivo principal retratar emoções, movimento. É possível perceber que pinturas como as de Caravaggio tinham o intuito de chocar, principalmente por se tratarem de retratações bíblicas.

Ainda, a Tabela 2.13 resume de maneira pontual as características que marcam as obras da grande maioria dos pintores do período Barroco, assim como aquelas que fazem parte das obras de cada pintor moderno:

Tabela 2.13 – Sumário de características do período Barroco e de cada artista dos movimentos da Arte Moderna estudados.

Barroco	Arte Moderna
Contraste (e.g. claro-escuro); emoção ao invés da razão; movimento; dramaticidade; sensualidade; beleza; fantasia; a verdade; o sagrado	Van Gogh Sensação; movimento; textura; cores; uso da perspectiva e profundidade de uma nova maneira; distorção
	Kandinsky Abstrato; cromatismo; interpretação psicológica; formas geométricas, puras
	Matisse Cores “violentas”; desprezo às formas naturais; decoração; simplicidade
	Picasso Solidez; simplicidade; formas geométricas; colagem de várias perspectivas
	Miró Surreal; automatismo; símbolos e seus significados; negação das técnicas de pintura existentes
	Pollock Abstrato; pintura de ação, pura, expontânea

2.2 Conceitos básicos em Filosofia

Dialética, oposição e inovação são conceitos essenciais nas discussões filosóficas. A dialética é vista como método filosófico para argumentação, central na Filosofia ocidental e oriental (12–14). Para Platão, o método dialético era o próprio método científico, onde se investiga racionalmente um determinado conceito (13). Cada conceito deve ser confrontado com outras teorias

e situações para se chegar a uma nova teoria. Hegel sumariza o método dialético (14) em três momentos bem definidos: a tese, um argumento ou ideia tomado como verdadeiro; a antítese, a contradição ou negação da tese; e a síntese, o resultado do confronto da tese com a antítese. A solução dialética, a síntese, é uma nova ideia que busca pelo equilíbrio da tese e antítese, ilustrado na Figura 2.14. Como a tradução literal sugere, “o caminho entre as ideias” é o diálogo entre ideias que leva a outras ideias ou teorias. Zenão de Eleia, Aristóteles, Platão e Sócrates foram pioneiros em seu uso, e também está presente no método dialético de Hegel e na dialética materialista de Marx, que propõe utilizar a dialética como um método propriamente científico, aplicado diretamente à realidade (45).




Figura 2.14 – a) Dialética: um argumento chamado tese, até então tomado como verdade, é confrontado por um argumento oposto, chamado antítese. O resultado do confronto destas duas ideias é a síntese que irá gerar uma nova ideia ou argumento; b) Oposição: é um argumento que se opõe a um argumento original; c) Inovação: tendo-se um movimento de oposição entre dois argumentos originais, um movimento de inovação é aquele que se afasta desta oposição, inovando.

A oposição de ideias está intimamente relacionada à dialética. Frequentemente, há grande oposição entre a tese e a antítese (Figura 2.14, detalhe *b*), sendo ideias essencialmente contraditórias. A inovação, por sua vez, relaciona-se com a oposição: uma ideia não necessariamente estará destinada a opor uma outra ideia, não participa apenas de um “jogo de oposição” pois pode também buscar um movimento novo, alternativo. Desta forma, está inovando (Figura 2.14, detalhe *c*).

Uma proposta de quantificar conceitos básicos de dialética, oposição e inovação foi iniciado

em um estudo aplicado à Filosofia e Música (1). A partir de uma matriz de atributos que descreve pesos (ou notas) dadas em conjunto pelos autores à certas características de filósofos e músicos, tem-se um espaço vetorial onde os conceitos são quantificados. Esse estudo está sendo aqui expandido, onde as mesmas medidas são aplicadas, mas não mais a atributos com notas que poderiam ser julgadas como subjetivas — já que atribuídas por humanos — mas a partir da extração de tais atributos por processamento digital de imagens (discutido nas Seções 2.3 e 3.5).

2.3 Processamento e análise de imagens

O processamento e análise de imagens envolve operações para adquirir, manipular e representar imagens digitalmente em um sistema computacional (46). Envolve uma série de etapas canônicas, summarizadas na Figura 2.15 (15). Estas operações são necessárias para traduzir o conjunto escolhido de 240 imagens de pinturas em termos de vetores de características. Na presente seção são discutidos cada uma dessas etapas que tornaram possível a realização desse estudo.

Cada imagem, após ser digitalizada, é representada como uma matriz de valores onde cada elemento armazena a intensidade de cor de uma região amostrada da imagem original. Uma imagem I representada no formato digital conhecido como RGB é definida como a matriz I de valores discretos $I_{(i,j)}$ com dimensão $N_i \times N_j \times N_c$. N_i e N_j são, respectivamente, a quantidade de *pixels* (ou *picture elements*) da linha e coluna de I , e N_c determina a quantidade de canais de cores da imagem — e.g. para uma imagem RGB de 800×800 pixels, sua ordem é $800 \times 800 \times 3$. Desta forma, cada elemento (ou pixel) $I_{(i,j)}$ da matriz corresponde a uma *tripla* (R, G, B) de valores inteiros compreendidos entre 0 e 255, onde 0 é o limite mais escuro e 255 o mais claro, para cada um dos três canais de cores: vermelho, verde e azul.

As imagens podem ainda ser representadas em escala de cinza, por uma matriz G com dimensão $N_i \times N_j$, onde cada valor $G_{(i,j)}$ é um número inteiro que determina a intensidade de cinza de cada *pixel* — como existe apenas um canal de cor, cinza, não se tem uma tupla, mas um valor




Figura 2.15 – Etapas canônicas para processamento e análise de imagens.

inteiro, para representar a cor do elemento. Alguns algoritmos de processamento, como os de segmentação, necessitam de imagens nesse formato.

Outros algoritmos necessitam representar a imagem com apenas dois valores: preto e branco. Por exemplo, elementos conexos em uma imagem segmentada são representados por imagens em preto e branco com o objetivo de facilitar a marcação de cada região conexa. A matriz é definida como B tendo dimensão $N_i \times N_j$ e cada um de seus elementos $B_{(i,j)}$ pode assumir apenas dois valores, 0 ou 255. Convenciona-se usar também os valores 0 ou 1, dado o aspecto binário da matriz e para facilitar a aplicação de operações lógicas sobre elas.

Uma imagem I , G ou B pode também ser definida como uma função $f(i, j)$ que mapeia as coordenadas (i, j) de um *pixel* em seu valor v . Sendo $S_x = \{0, 1, \dots, N_j - 1\}$ e $S_y = \{0, 1, \dots, N_i - 1\}$ o domínio espacial da imagem e $S_v = \{0, 1, \dots, 255\}$ o domínio de v , tem-se a função

$$f : S_x \times S_y \rightarrow S_v \quad (2.1)$$

onde para B o domínio é $S_v = \{0, 255\}$ ou $S_v = \{0, 1\}$, e para I e G o domínio é $S_v = \{0, 1, \dots, 255\}$, representando as gradações de cores em cinza e para cada canal de cor primária, respectivamente.

2.3.1 Conceitos úteis de Geometria Discreta, Morfologia Matemática e Estatística

Enquanto trabalhando com imagens digitais o conceito de *vizinhança* é central. (15) Algoritmos para pré-processamento (e.g. como a equalização por histograma, ou filtro de medianas) e até mesmo para extração de características (e.g. algoritmo de curvatura ou cálculo de entropia local) são ambos baseados nesse conceito. Os vizinhos de um *pixel* $I_{(i,j)}$ são os N_V pixels V_i que o circundam, e costuma-se chamar este conjunto de *vizinhança- N_V* com $0 \leq i \leq N_V$. Duas vizinhanças são comuns, a vizinhança-4 e vizinhança-8. Dado um pixel $I_{(i,j)}$, sua vizinhança-4 corresponderia aos seguintes conjuntos:

$$V_0 = (i, j+1) \quad (2.2)$$

$$V_1 = (i-1, j) \quad (2.3)$$

$$V_2 = (i, j-1) \quad (2.4)$$

$$V_3 = (i+1, j) \quad (2.5)$$

e sua vizinhança-8 seria dada pelos seguintes:

$$V_0 = (i, j+1) \quad (2.6)$$

$$V_1 = (i-1, j+1) \quad (2.7)$$

$$V_2 = (i-1, j) \quad (2.8)$$

$$V_3 = (i-1, j-1) \quad (2.9)$$

$$V_4 = (i, j-1) \quad (2.10)$$

$$V_5 = (i+1, j-1) \quad (2.11)$$

$$V_6 = (i+1, j) \quad (2.12)$$

$$V_7 = (i+1, j+1) \quad (2.13)$$

onde é importante notar que as coordenadas (i, j) são relacionadas com as linhas e colunas da matriz que representa os pixels da imagem e não com as coordenadas cartesianas (x, y) de um ponto qualquer na imagem. A Figura 2.16 ajuda a compreender tais vizinhanças.




Figura 2.16 – Coordenadas das vizinhanças-4 e 8 para um dado pixel $I_{(i,j)}$ qualquer.

Tendo uma vizinhança em torno de um pixel $I_{(i,j)}$ e uma função $f(x,y)$ que representa tal pixel (e por conseguinte, a própria imagem), pode-se definir uma função de processamento (46) da imagem como

$$g(x,y) = T[f(x,y)] \quad (2.14)$$

sendo $f(x,y)$ a imagem de entrada, $g(x,y)$ a imagem processada e T é um operador sobre f , definido sobre alguma vizinhança- N_V de (x,y) . Dessa forma, o centro (x,y) da sub-imagem que compreende os pixels da vizinhança- N_V é movido de pixel em pixel, o que corresponde a alterar os valores $f(x,y)$ do centro pelo valor obtido por $g(x,y)$. É possível usar várias formas de sub-imagens (e.g. círculos ou elipses) mas subimagens quadradas são mais comuns para vizinhanças pois são de fácil implementação.

O operador T é essencial nesse tipo de processamento, pois é ele quem mapeia os valores de f em g . Uma operação de mapeamento muito comum para T é mapear o nível de cinza r em f para o nível de cinza s em g , ou:

$$s = T(r) \quad (2.15)$$

assim os níveis de cinza da imagem processada dependerá de alguma operação definida em T . A equalização de uma imagem de entrada a partir de um operador T baseado no histograma de tons de cinza da imagem é um exemplo de aplicação, discutido em detalhes na Subseção 2.3.2.

Durante todo este estudo, serão utilizados estes conceitos, e soma-se a eles alguns outros, emprestados da Estatística. Portanto, são revisados aqui os momentos estatísticos básicos:

$$\text{média}(X) = m_x = \mu_x = \bar{x} = \frac{\sum_{i=1}^n X_i}{n} \quad (2.16)$$

$$\text{variância}(X) = var_x = \sigma_x^2 = s_x^2 = \frac{\sum_{i=1}^n (X_i - \mu_x)^2}{n-1} \quad (2.17)$$

$$\text{desvio padrão}(X) = std(X) = \sigma_x = s_x = \sqrt{\frac{\sum_{i=1}^n (X_i - \mu_x)^2}{n}} \quad (2.18)$$

$$\text{mediana}(X) = \tilde{x} = \mu_{1/2} = \begin{cases} X_{(n+1)/2} & n \text{ ímpar} \\ \text{média}(X_{n/2}, X_{n/2+1}) & n \text{ par} \end{cases} \quad (\text{estando } X \text{ ordenado}) \quad (2.19)$$

$$\text{covariância}(X, Y) = cov(X, Y) = c_{X,Y} = \frac{\sum_{i=1}^n (X_i - \mu_x)(Y_i - \mu_y)}{n} \quad (2.20)$$

2.3.2 Pré-processamento

A etapa de pré-processamento tem como objetivo melhorar certos aspectos de uma imagem digital. É possível então corrigir falhas ocorridas durante a aquisição da imagem ou realçar certos detalhes de interesse.

Costuma-se dividir o pré-processamento em operações no domínio real e das frequências. (46) No domínio real, os próprios elementos da matriz I são alterados diretamente. Já o domínio das frequências envolve a transformada de Fourier da matriz para manipular bandas de valores, necessitando da transformada inversa para levar a matriz ao espaço real novamente.

Uma operação recorrente de pré-processamento no domínio real, por ser computacionalmente barata e eficiente, é a *equalização por histograma*. O objetivo é ajustar o nível de contraste da imagem baseando-se em seu histograma de valores. O histograma de uma imagem G é dado pela função

$$\text{hist}(G) = p(R_k) = \frac{N_k}{N_G} \quad (2.21)$$

onde R_k é um nível de cinza k , N_k é a quantidade de pixels da imagem G que possuem nível de cinza $k \in \{0, 1, \dots, 255\}$, N_G é quantidade total de pixels da imagem G . Ou seja, $p(R_k)$ corresponde à probabilidade de ocorrência de um nível de cinza R_k na imagem. O gráfico de $p(R_k)$

é denominado *histograma*. Essa informação é interessante quando se deseja realçar o contraste da imagem, visto que pode-se mensurar a quantidade de pixels em regiões mais claras, mais escuras e com níveis de cinza medianos. Assim, pode-se definir uma operação T (Eq. 2.14) que equalize os níveis de cinza R_k de f , gerando uma imagem equalizada g :

$$s = T(R_k) = \sum_{j=0}^k \frac{N_j}{N_G} = \sum_{j=0}^k p(R_j) \quad (2.22)$$

à essa operação T se dá o nome de *equalização de histograma* ou *linearização de histograma*. Ao se mapear os níveis de cinza R_k de f nos níveis s de g , tem-se a imagem equalizada em contraste.

Após equalizar os níveis de contraste da imagem, é comum suavisá-la e remover ruído através de filtros, como por exemplo, o de mediana. Esse efeito de suavização e remoção de ruídos ocorre pois cada pixel terá como seu valor a mediana de seus vizinhos. Assim, quanto maior o tamanho da vizinhança, maior a suavização em relação à imagem. O filtro de média também pode ser utilizado, porém o filtro de mediana preserva detalhes de bordas que são borrados pelo filtro de média, portanto seu uso é mais interessante no caso da análise de pinturas. (46) O que se quer é a eliminação de ruído sem borrar detalhes de borda.

Para implementar o filtro por mediana, troca-se o valor do nível de cinza R_k em f pela mediana dos níveis de cinza da vizinhança- N_V desse pixel. Essa operação (Eq. 2.14) pode ser definida como

$$T[f(x,y)] = \text{mediana}(V_N(f(x,y))) \quad (2.23)$$

onde $V_N(f(x,y))$ é o conjunto de pixels na vizinhança- N_V com centro em (x,y) na imagem f .

2.3.3 Segmentação

Embora a visão humana seja capaz de distinguir formas (e dar-lhes significado, classificando-as) com relativa precisão, é preciso aplicar um procedimento conhecido como *segmentação* para identificar formas da imagem digitalizada. Assim, o processo de segmentação tem como objetivo particionar uma imagem em múltiplos segmentos que são na realidade grupos de pixels.

Há um grande número de algoritmos de segmentação, sendo uma área de pesquisa rica e em constante desenvolvimento. Portanto, não há como esgotar todo o conjunto de algoritmos existentes em via de testá-los para a segmentação das pinturas selecionadas. Uma prática comum é selecionar um grupo de algoritmos e aplicá-los exaustivamente ao conjunto de imagens e, de maneira experimental, escolher o algoritmo que mais contribui para a segmentação pretendida. O algoritmo SLIC (*Simple Linear Iterative Clustering*) (47) é baseado em superpixels e aplicado em matrizes coloridas de imagens. Portanto, para pinturas coloridas, seu uso é incentivado e demonstra segmentação esperada.

Algoritmos baseados em superpixels como o SLIC agrupam pixels em regiões que tenham maior significado do que a simples malha de pixels. Essas regiões mais significativas são chamadas superpixels. O algoritmo SLIC agrupa os pixels em superpixels através de uma adaptação do algoritmo de clusterização *k-means*. Apesar de ser uma ideia simples, se mostra comparável aos algoritmos de superpixel considerados “estado da arte” atualmente (47), chegando a superá-los para a segmentação.

O Algoritmo 1 lista os passos do procedimento SLIC. Primeiramente, uma imagem RGB I precisa ter seus elementos convertidos para o padrão CIE 1976 L^*, a^*, b^* (ou simplesmente CIELAB) (48), que representa uma determinada cor em função de um espaço definido pela base (L^*, a^*, b^*) , ilustrado na Figura 2.17. L^* determina a quantidade de luminosidade da cor enquanto o eixo a^* determina a matiz entre verde e vermelho, e b^* a matiz entre azul e amarelo.

A conversão do formato RGB para CIELAB é discutida em detalhes por Hoffmann(49).




Figura 2.17 – Espaço de cor CIELAB. Uma cor qualquer é representada como um ponto no espaço (L^*, a^*, b^*) .

Desta forma, cada pixel $I_{(x,y)}$ passa a ser representado por uma quíntupla $(L_i, a_i, b_i, x_i, y_i)$, sendo L_i , a_i e b_i as componentes da cor em formato CIELAB e x_i, y_i as coordenadas em linha e coluna do pixel. O único parâmetro do algoritmo é k , sendo o número máximo de clusters. Em um passo inicial, k clusters são amostrados tendo seus centróides $C_k = (L_k, a_k, b_k, x_k, y_k)$ distribuídos em uma malha regular de espaçamento $S = \sqrt{N_I/k}$, sendo N_I o número de pixels da imagem. No passo de atribuição, cada pixel $I_{(x,y)}$ é associado à uma região limitada em torno de C_k . Isso acaba por reduzir a complexidade desse algoritmo, pois essa atribuição de cada pixel ao seu cluster não é feita considerando-se todos os N_I pixels da imagem, mas apenas aqueles pixels dentro dessa região. Como a região de um superpixel tem como tamanho aproximadamente $S \times S$, o tamanho da região de busca pelo novo centróide do cluster (i.e. $k-means$) é $2S \times 2S$ em torno do centróide C_k atual — tal tamanho é definido por convenção do método SLIC (47). Tendo todos os pixels $I_{(x,y)}$ da região em torno do centróide, calcula-se a distância $D_{I,C}$ de cada pixel $I_{(x,y)}$ ao seu centróide C_k :

$$d_c = \sqrt{(L_k - l_i)^2 + (a_k - a_i)^2 + (b_k - b_i)^2} \quad (2.24)$$

$$d_s = \sqrt{(x_k - x_i)^2 + (y_k - y_i)^2} \quad (2.25)$$

$$D'_{I,C} = \sqrt{\left(\frac{d_c}{N_C}\right)^2 + \left(\frac{d_s}{N_S}\right)^2} \quad (2.26)$$

$$D_{I,C} = \sqrt{d_c^2 + \left(\frac{d_s}{S}\right)^2 m^2} \quad (2.27)$$

onde d_c e d_s são as distâncias do pixel $I_{(x,y)} = (L_i, a_i, b_i, x_i, y_i)$ até um centróide qualquer $C_k = (L_k, a_k, b_k, x_k, y_k)$, considerando o espaço de cor e o espaço geométrico, respectivamente. Em $D'_{I,C}$ essas duas medidas são combinadas e também normalizadas segundo as distâncias máximas em cor e espaço, dadas por N_C e N_S . Como os centróides ficam espaçados a uma distância regular S , pode-se fazer $N_S = S$. E o máximo valor de cor é dado como parâmetro m do algoritmo. Esse parâmetro acaba por permitir o controle do peso das medidas de cor e espacial: quanto maior o valor de m , maior o peso da proximidade espacial e os superpixels serão mais compactos pois sua razão área por perímetro será menor. Quando m é menor, os superpixels irão aderir mais às bordas (i.e. mais espalhados) de cada região e ao mesmo tempo terão tamanho e forma irregular. Como o algoritmo usa nativamente o formato CIELAB para cores, $m \in [1, 40]$. Cada pixel $I_{(x,y)}$ tem sua distância e rótulo atualizados, caso sua distância atual seja menor que a distância antiga. Por fim, no passo de atualização do algoritmo, os novos centróides C_k são calculados como a média de todos os pixels pertencentes ao cluster e uma nova iteração se inicia. O algoritmo pára dado um máximo especificado de iterações ou se o erro residual da distância dos centróides atuais e anteriormente calculados forem menores ou iguais a um dado limiar.

Algoritmo 1: Algoritmo de segmentação SLIC

Entrada: Imagem colorida I em formato CIELAB

Entrada: Número máximo k de clusters

Entrada: Peso m para a distância no domínio espacial *versus* geométrico

Entrada: Número máximo t de iterações

Saída: Imagem rotulada R , cada rótulo identificando uma região segmentada

```

1 para cada centróide  $C_k = (L_k, a_k, b_k, x_k, y_k)$  hacer
2   |    $C_k \leftarrow$  uma posição  $k$  de uma malha com espaçamento  $S$ 
3   fin
4   para cada pixel  $p$  hacer
5     |   rótulo( $p$ )  $\leftarrow -1$ ;
6     |   distância( $p$ )  $\leftarrow \infty$ 
7   fin
8   enquanto não atingir a iteração máxima  $t$  faça
9     |   para cada centróide  $C_k$  hacer
10    |     |   para cada para cada pixel  $p$  em uma região  $2S \times 2S$  em torno de  $C_k$  hacer
11      |       |    $D \leftarrow$  distância entre  $p$  e  $C_k$ ;
12      |       |   se  $D \leq$  distância( $p$ ) então
13        |         |   distância( $p$ )  $\leftarrow D$  rótulo( $p$ )  $\leftarrow k$ ;
14      |       |   fin
15    |   fin
16  |   fin
17  |   para cada centróide  $C_k$  hacer
18    |     |    $C_k \leftarrow$  ponto médio considerando os pixels da região
19  |   fin
20 fin
```

Após ter-se todas as regiões rotuladas pelo algoritmo SLIC, é necessário um passo de rotulação por conectividade, visto que assim como a maioria dos algoritmos de segmentação, não há a garantia do retorno de regiões conexas. Esse passo é feito então no pós-processamento.

2.3.4 Pós-processamento

Algoritmos como os de segmentação têm como saída principal uma versão da imagem original com rótulos. Esses rótulos identificam cada região segmentada, como ilustrado na Figura 3.7 – essa etapa é comumente chamada de *rotulação*.

Porém, esses rótulos identificam as regiões segmentadas (detalhe a da Figura 3.7), quando o que

a)

1	1	0	0	0	0	0	0
1	1	0	2	2	2	2	0
0	0	0	0	0	0	0	0
0	0	1	0	0	2	2	0
0	0	1	1	0	2	2	0
0	0	1	1	0	2	2	0
0	0	0	0	0	2	2	0
0	0	0	0	0	0	0	0

b)

2	2	0	0	0	0	0	0
2	2	0	4	4	4	4	0
0	0	0	0	0	0	0	0
0	0	1	0	0	3	3	0
0	0	1	1	0	3	3	0
0	0	1	1	0	3	3	0
0	0	0	0	0	3	3	0
0	0	0	0	0	0	0	0

Figura 2.18 – a) Rotulação das regiões após aplicação de algoritmo de segmentação segundo vizinhança-4: os rótulos identificam segmentos encontrados pela segmentação, porém não revelam necessariamente regiões conexas; **b)** Rotulação das regiões (ou componentes) conexas após aplicação de algoritmo para identificação de regiões conexas: esta é a rotulação desejada quando o que se pretende é identificar formas em uma imagem qualquer.

se quer é geralmente as regiões conexas (detalhe *b* da Figura 3.7). Regiões conexas são aquelas cujos pixels estão todos conectados entre entre si dada uma vizinhança de pixels qualquer — no caso da Figura 3.7, detalhe *b*, tem-se regiões conexas para vizinhança-4. Estas regiões são especialmente interessantes quando se quer identificar as formas da imagem original. Um algoritmo simples de rotulação de componentes conexos pode ser definido através do procedimento descrito no Algoritmo 2. Trata-se de um algoritmo que simula uma busca em largura em todos os pixels de mesmo rótulo k a partir de um pixel $I_{(i,j)}$ qualquer da imagem segmentada R . Faz isso com o auxílio de uma estrutura de dados do tipo fila FIFO (“primeiro a entrar, primeiro a sair”).

Algoritmo 2: Algoritmo de rotulação de regiões conexas baseado em fila FIFO

Entrada: Imagem rotulada R com cada k segmento identificado por rótulo k
Saída: Imagem rotulada S com regiões conexas identificadas por rótulo k

```

1 Inicializa todos os elementos em  $S$  com 0;
2  $F \leftarrow$  Fila FIFO;
3  $r \leftarrow 1$ ;
4 para cada pixel  $p \in R$  e  $S(p) = 0$  hacer
5    $p \leftarrow r$ ;
6   Insira  $p$  em  $F$ ;
7   enquanto  $F$  não estiver vazia faça
8     Remova  $p$  de  $F$ ;
9     para cada  $q \in vizinhança - V$  e  $S(q) = 0$  hacer
10        $S(q) \leftarrow r$ ;
11       Insira  $q$  em  $F$ ;
12     fin
13   fin
14    $r \leftarrow r + 1$ ;
15 fin

```

É comum tais imagens apresentarem deformações e ruído. Um exemplo de deformação é a presença de “buracos” ao longo de uma região segmentada. Esses espaços vazios provocam alterações em atributos que serão extraídos em um próximo passo, como a área da região. Ruídos são, por exemplo, regiões cujas áreas são ínfimas e em nada contribuem para um possível passo de extração de atributos, não sendo bons representantes das formas que compõem a imagem original. Esses erros devem ser eliminados e é esse o objetivo do passo de pós-processamento.

Para remover “buracos” de uma região R_i segmentada a partir de uma imagem original em escalas de cinza G onde a matriz binária R_i é construída a partir da segmentação de G calculada em S_G por

$$R_i = \begin{cases} 1 & \text{se } S_G(x,y) = i \\ 0 & \text{caso contrário} \end{cases} \quad (2.28)$$

aplica-se uma operação morfológica binária de dilatação.

Para remover as regiões com áreas não representativas de uma região R_i usa-se um limiar θ . Assim, regiões com áreas $\leq \theta$ são preenchidas com 0, eliminando-as de S_G . Essa operação é conhecida como filtro de área e pode ser definida através do Algoritmo 3.

Algoritmo 3: Algoritmo de eliminação de áreas menores que um limiar θ

Entrada: Imagem rotulada I e limiar θ
Saída: Imagem rotulada I com regiões com áreas $\leq \theta$ filtradas

```

1 para cada região  $R_k$  rotulada com  $k$  em  $I$  hacer
2   se  $area(R_k) \leq \theta$  então
3     para cada pixel  $p$  em  $R_k$  hacer
4       |  $I(p) \leftarrow 0$ 
5     fin
6   fim
7   senão
8     para cada pixel  $p$  em  $R_k$  hacer
9       |  $I(p) \leftarrow k$ 
10    fin
11  fim
12 fin

```

2.4 Extração de atributos

Após as etapas de preparação, segmentação e pós-processamento das imagens, estas estão prontas para a extração de atributos. Para caracterizar adequadamente uma imagem, certos aspectos devem ser considerados e são dependentes da natureza da imagem. No caso das pinturas, Romero(50) sugere o uso de complexidade de imagens para estimar características estéticas. Manovich(51–53) utiliza a análise de saturação de luz, contraste, brilho e demais atributos relacionados com a intensidade de cinza nas imagens.

Desta forma, um conjunto de descritores de imagens (ou atributos) é selecionado e aplicado experimentalmente ao conjunto de imagens já processadas. Embora os algoritmos de extração sejam eficientes em suas funções, não há a garantia de que sejam suficientes para a correta caracterização de uma imagem. Assim, o procedimento canônico é considerar um amplo con-

junto de atributos e em seguida selecionar aqueles que melhor atendem os objetivos da análise (discutido na Seção 2.5). Esse conjunto deve portanto incluir atributos que irão, inicialmente, descrever uma larga gama de características como complexidade, textura e detalhes sobre a forma dos segmentos — e.g. área, perímetro, curvatura.

Para este estudo foram utilizados 99 atributos, descritos nas próximas seções e sumarizados na Tabela 2.22.

2.4.1 Atributos de complexidade

Para descrever a complexidade, medidas de entropia e energia para diferentes combinações de elementos da imagem são consideradas. A noção de entropia é emprestada da teoria da informação. Nela, a premissa fundamental é que a geração de informação pode ser modelada como um processo probabilístico, sendo medido de forma que concorde com a intuição humana (46). Desta forma, um evento qualquer E pode ocorrer com probabilidade $P(E)$ e

$$I(E) = \log \frac{1}{P(E)} = -\log P(E) \quad (2.29)$$

sendo a *unidade de informação* de E , denominada *auto-informação* de E . Isso equivale a dizer que a quantidade de informação atribuída ao evento E é inversamente proporcional à probabilidade de E ocorrer. Se $P(E) = 1$, ou seja, se E ocorre sempre, $I(E) = 0$ e nenhuma informação é atribuída a ele. Caso E não ocorrer, ou $P(E) = 0$, tem-se $I(E) = \infty$. Quanto maior a probabilidade de E ocorrer, menor informação estará incorporada, pois esse é um resultado que espera-se ocorrer com grande frequência. Por outro lado, quanto menor a probabilidade de E ocorrer, mais informação estará incorporada, pois é um resultado menos provável de ocorrer. Se houverem J símbolos a_j associados a um evento E , a probabilidade da ocorrência de a_j é $P(a_j)$ e

$$\sum_{j=1}^J P(a_j) = 1. \quad (2.30)$$

A auto-informação associada à ocorrência de um único símbolo a_j é $I(a_j) = -\log P(a_j)$. Para a ocorrência de todos os símbolos, tem-se portanto:

$$-kP(a_1)\log P(a_1) - kP(a_2)\log P(a_2) - \dots - kP(a_J)\log P(a_J) \quad (2.31)$$

ou ainda:

$$-k \sum_{j=1}^J P(a_j)\log P(a_j). \quad (2.32)$$

Portanto, a informação média associada à ocorrência do evento E dados todos os a_j símbolos é:

$$H(E) = - \sum_{j=1}^J P(a_j)\log P(a_j) \quad (2.33)$$

onde $H(E)$ é denominada *incerteza* ou *entropia* de E .

Considerando a imagem em escala de cinza G onde cada pixel é representado por $f(i,j)$, é possível calcular sua entropia aplicando a Equação 2.33 a G :

$$R = \text{hist}(G) \quad (2.34)$$

$$P = \left\{ p_i = \frac{R_i}{\sum_i R_i} \right\} \quad (2.35)$$

$$H = - \sum_i p_i \log p_i, \quad p_i \neq 0 \quad (2.36)$$

$$\mathcal{A}_0 = H \quad (2.37)$$

sendo $hist$ o histograma dos valores dos níveis de cinza em G , P as probabilidades p_i de cada amostra i e H a entropia da imagem G . Esse portanto é o primeiro atributo \mathcal{A}_0 do conjunto de atributos \mathcal{A}_i . O valor de entropia da imagem também pode ser visualizado através de um escala de cores que corresponde aos valores de H como visto na Figura 2.19.




Figura 2.19 – a) Imagina da pintura original. b) Imagem em escala de cinza G . c) A entropia H da imagem G mapeada em uma escala de cores. É interessante notar como regiões de borda possuem entropia maior.

A densidade espectral da imagem total, por sua vez, é dada pelo cálculo da transformada de Fourier. Vale aqui introduzir tal conceito para se chegar à definição de densidade espectral. Seja $f(x)$ uma função contínua de uma variável real x , a transformada de Fourier $\mathcal{F}\{f(x)\}$ é definida pela equação

$$\mathcal{F}\{f(x)\} = F(u) = \int_{-\infty}^{+\infty} f(x) \exp[-2i\pi ux] dx \quad (2.38)$$

com $i = \sqrt{-1}$. A partir de $F(u)$ pode-se obter a função original $f(x)$ através da *transformada inversa de Fourier*:

$$\mathcal{F}^{-1}\{F(u)\} = f(x) = \int_{-\infty}^{+\infty} F(u) \exp[2i\pi ux] du. \quad (2.39)$$

A transformada de Fourier de uma função real é geralmente complexa, e pode ser expressa por

$$F(u) = \Re(u) + \Im(u)i \quad (2.40)$$

onde $\Re(u)$ e $\Im(u)$ são os componentes real e imaginário de $F(u)$, respectivamente. É conveniente expressar a Equação 2.40 em sua forma exponencial:

$$F(u) = |F(u)|e^{\phi(u)i} \quad (2.41)$$

onde $|F(u)| = [\Re^2(u) + \Im^2(u)]^{\frac{1}{2}}$ é o *espectro de Fourier* e $\phi(u) = \tan^{-1}[\frac{\Im(u)}{\Re(u)}]$ o *ângulo de fase*.

Tomando-se o quadrado do espectro tem-se a *densidade espectral*, também chamada de *espectro de potência* de $f(x)$:

$$P(u) = |F(u)|^2 = \Re^2(u) + \Im^2(u). \quad (2.42)$$

A densidade espectral da imagem G pode ser calculada com base na Equação 2.42:

$$E = |\Re(X(G))|^2 + |\Im(X(G))|^2 \quad (2.43)$$

onde X é a transformada de Fourier de G e a soma dos quadrados dos módulos da parte real e imaginária de X corresponde à energia espectral procurada. Com base nessa medida, pode-se derivar as medidas de média e desvio padrão das energias nas linhas, colunas, centróides e da imagem total:

$$\mathcal{A}_1 = \mu = \frac{\sum_j E_{(i,j)}}{N_j} \text{ média das energias nas linhas } i \quad (2.44)$$

$$\mathcal{A}_2 = \sigma = \sqrt{\frac{\sum_j (E_{(i,j)} - \mu)^2}{N_j}} \text{ desvio padrão das energias nas linhas } i \quad (2.45)$$

$$\mathcal{A}_3 = \mu = \frac{\sum_i E_{(i,j)}}{N_i} \text{ média das energias nas colunas } j \quad (2.46)$$

$$\mathcal{A}_4 = \sigma = \sqrt{\frac{\sum_i (E_{(i,j)} - \mu)^2}{N_i}} \text{ desvio padrão das energias nas colunas } j \quad (2.47)$$

$$\mathcal{A}_5 = \frac{\sum_j j E_{(i,j)}}{N_j} \text{ centróide das energias nas linhas } i \quad (2.48)$$

$$\mathcal{A}_6 = \frac{\sum_i i E_{(i,j)}}{N_i} \text{ centróide das energias nas colunas } j \quad (2.49)$$

$$\mathcal{A}_7 = \mu = \frac{\sum E_{(i,j)}}{N_i + N_j} \text{ média das energias nas linhas } i \text{ e colunas } j \quad (2.50)$$

$$\mathcal{A}_8 = \sigma = \sqrt{\frac{\sum (E_{(i,j)} - \mu)^2}{N_i + N_j}} \text{ desvio padrão das energias nas linhas } i \text{ e colunas } j \quad (2.51)$$

Essas mesmas medidas, que foram aplicadas à representação da imagem original em níveis de cinza (\mathcal{A}_{1-8}) podem ser aplicadas para cada um dos 3 canais de cor RGB da imagem I , obtendo assim o conjunto \mathcal{A}_{9-16} de atributos para o canal vermelho, conjunto de atributos \mathcal{A}_{17-24} para canal verde e \mathcal{A}_{25-32} para o canal azul.

2.4.2 Atributos de textura

Com o objetivo de analisar a textura das imagens, as 14 medidas propostas por Haralick (54) são de interesse. Elas são medidas ditas *estatísticas de segunda ordem* pois são calculadas a partir da matriz de co-ocorrência de níveis de cinza de uma dada imagem G . Uma das vantagens dessa abordagem é levar em conta a posição relativa de cada pixel da imagem. Cada uma das 14 medidas propostas procura caracterizar um aspecto de textura como contraste, homogeneidade e complexidade.

Dada uma imagem G com N_G níveis de cinza, sua matriz de co-ocorrência será uma matriz quadrada de dimensões $N_G \times N_G$ onde cada elemento $P_{\vec{d}}(i, j)$ representa a quantidade de pixels da imagem G que possuem os níveis de cinza i e j , separados por uma distância numa certa direção e sentido, determinado por \vec{d} . Para uma imagem, considera-se apenas o posicionamento relativo entre cada pixel e seus vizinhos (i.e. pixels adjacentes) e portanto, \vec{d} poderá assumir apenas 8 direções possíveis considerando os possíveis ângulos $\beta \in \{0^\circ, 45^\circ, 90^\circ, 135^\circ, 180^\circ, 225^\circ, 270^\circ, 315^\circ\}$ que tal vetor pode assumir dado que encontra-se “aprisionado” em uma malha (i.e. possui vizinhança-8). Como trata-se de uma matriz de co-ocorrência, esta é simétrica, e portanto esse conjunto de possíveis β torna-se ainda menor. Por fim, dados os possíveis ângulos $\beta \in \{0^\circ, 45^\circ, 90^\circ, 135^\circ\}$ e considerando os valores $\{-1, 0, 1\}$ como domínio das coordenadas x, y de \vec{d} , tem-se o cálculo dos 14 atributos de Haralick para cada uma das seguintes direções:

$$\beta = 0^\circ \rightarrow \vec{d} = (1, 0) \quad (2.52)$$

$$\beta = 45^\circ \rightarrow \vec{d} = (1, 1) \quad (2.53)$$

$$\beta = 90^\circ \rightarrow \vec{d} = (0, 1) \quad (2.54)$$

$$\beta = 135^\circ \rightarrow \vec{d} = (-1, 1) \quad (2.55)$$

a Tabela 2.20 lista os 14 atributos de Haralick, lembrando que estes são calculados para cada uma das 4 direções possíveis de \vec{d} . Assim, essas medidas definem os $14 \cdot 4 = 56$ atributos seguintes considerados nesse estudo, o conjunto \mathcal{A}_{33-88} .

2.4.3 Atributos de contorno e forma

Após a identificação dos componentes conexos e seu pós-processamento, pode-se partir para a descrição da forma de tais componentes. A curvatura é um destes descritores. Trata-se de um atributo que mensura a mudança de direção “relativa” entre dois pontos conectados (15).

Tabela 2.20 – Os 14 atributos de textura de Haralick, considerando:

$$\begin{aligned} p(i, j) &= P_d(i, j), \\ p_x(i) &= \sum_{j=1}^{N_g} p(i, j), \\ p_y(j) &= \sum_{i=1}^{N_g} p(i, j), \\ p_{x+y}(k = i + j) &= \sum_{i=1}^{N_g} \sum_{j=1}^{N_g} p(i, j), \\ p_{x-y}(k = |i - j|) &= \sum_{i=1}^{N_g} \sum_{j=1}^{N_g} p(i, j). \end{aligned}$$

Ainda, $H(X)$ é a entropia de X e $\text{autoval}_2(X)$ é o segundo maior autovalor de X .

Uniformidade	$f_1 = \sum_{i=1}^{N_g} \sum_{j=1}^{N_g} p(i, j)^2$
Contraste	$f_2 = \sum_{i=1}^{N_g} \sum_{j=1}^{N_g} (i - j)^2 p(i, j)$
Correlação	$f_3 = \frac{\sum_{i=1}^{N_g} \sum_{j=1}^{N_g} i j p(i, j) - \mu_x \mu_y}{\sigma_x \sigma_y}$
Variância	$f_4 = \sum_{i=1}^{N_g} \sum_{j=1}^{N_g} (i - \mu)^2 p(i, j)$
Momento inverso da diferença	$f_5 = \sum_{i=1}^{N_g} \sum_{j=1}^{N_g} \frac{1}{1+(i-j)^2} p(i, j)$
Média da soma	$f_6 = \sum_{k=2}^{2N_g} k p_{x+y}(k)$
Variância da soma	$f_7 = \sum_{k=2}^{2N_g} (k - f_6)^2 p_{x+y}(k)$
Entropia da soma	$f_8 = - \sum_{k=2}^{2N_g} p_{x+y}(k) \log(p_{x+y}(k))$
Entropia	$f_9 = - \sum_{i=1}^{N_g} \sum_{j=1}^{N_g} p(i, j) \log(p(i, j))$
Variância da diferença	$f_{10} = \text{var}(p_{x-y})$
Entropia da diferença	$f_{11} = - \sum_{k=0}^{N_g-1} p_{x-y}(k) \log(p_{x-y}(k))$
Medida de correlação (1)	$f_{12} = \frac{f_9 + \sum_{i=1}^{N_g} \sum_{j=1}^{N_g} p(i, j) \log[p_x(i)p_y(j)]}{\max\{H(p_x(i)), H(p_y(j))\}}$
Medida de correlação (2)	$f_{13} = \sqrt{1 - \exp\left[-2\left(\left(-\sum_{i=1}^{N_g} \sum_{j=1}^{N_g} p_x(i)p_y(j) \log(p_x(i)p_y(j))\right) - f_9\right)\right]}$
Coeficiente de correlação máxima	$f_{14} = \sqrt{\text{autoval}_2\left(-\sum_{k=1}^{N_g} \frac{p(i, k)p(j, k)}{p_x(i)p_y(j)}\right)}$

Esse descritor tem uma motivação biológica interessante relacionada com o sistema de visão humano — e.g. o reconhecimento de objetos é relacionado à identificação de cantos e pontos de alta curvatura. Esses pontos possuem mais informação sobre a forma do objeto do que linhas retas ou curvas suaves. Dessa forma, a curvatura é um atributo interessante para uso na caracterização das pinturas consideradas nesse estudo, pois pinturas como as de Miró parecem possuir maior quantidade de linhas retas, com poucas curvas, do que as pinturas barrocas, por exemplo. A curvatura de uma forma é calculada usando os seguintes descritores de Fourier e esquematizada na Figura 2.21.

A curvatura $k(t)$ de uma curva paramétrica $c(t) = (x(t), y(t))$ é definida como:

$$k(t) = \frac{\dot{x}(t)\ddot{y}(t) - \dot{y}(t)\ddot{x}(t)}{(\dot{x}(t)^2 + \dot{y}(t)^2)^{\frac{3}{2}}} \quad (2.56)$$

onde $\dot{x}(t)$, $\dot{y}(t)$, $\ddot{x}(t)$ e $\ddot{y}(t)$ são respectivamente as derivadas de primeira e segunda ordem dos parâmetros $x(t)$ e $y(t)$ da curva $k(t)$. Essas derivadas podem ter seus valores estimados através da transformada de Fourier e do teorema da convolução (55):

$$\dot{x} = \mathfrak{I}^{-1}(2\pi i\omega X(\omega)) \quad (2.57)$$

$$\dot{y} = \mathfrak{I}^{-1}(2\pi i\omega Y(\omega)) \quad (2.58)$$

$$\ddot{x} = \mathfrak{I}^{-1}(-(2\pi\omega)^2 X(\omega)) \quad (2.59)$$

$$\ddot{y} = \mathfrak{I}^{-1}(-(2\pi\omega)^2 Y(\omega)) \quad (2.60)$$

onde \mathfrak{I}^{-1} é a transformada inversa de Fourier, X e Y a transformada de Fourier de x e y respectivamente, ω é a frequência angular e i a unidade imaginária.

O cálculo das derivadas $(\dot{x}(t), \dot{y}(t))$ e $(\ddot{x}(t), \ddot{y}(t))$ do sinal t através do cálculo da transformada de Fourier — i.e. por um método numérico de diferenciação — acaba por realçar ruídos de alta




Figura 2.21 – a) Imagina da pintura original. b) Uma região segmentada da pintura. c) A curvatura extraída a partir da região segmentada. d) A curva paramétrica $k(t)$ dado um limiar em particular, com os picos em destaque.

frequência. Pode-se compensar este efeito através de uma filtragem (15, 56), onde as funções diferenciadas durante o processo são suavizadas a partir da convolução de um filtro gaussiano aplicado ao sinal à ser diferenciado. Ou seja, a diferenciação por Fourier acaba por criar um filtro passa-altas, necessitando de um filtro passa-baixas para amenizar o ruído. Tal filtro gaussiano é definido por

$$g(t) = \frac{1}{2\pi\sigma^2} \exp\left(-\frac{t^2}{2\sigma^2}\right) \quad (2.61)$$

e sua transformada de Fourier é dada por

$$G(\omega) = \exp\left(\frac{-(2\pi)^2\omega^2}{(2/\sigma)^2}\right) \quad (2.62)$$

Utilizando-se o teorema da convolução é possível aplicar o filtro gaussiano $g(t)$ ao sinal a ser diferenciado:

$$\hat{x}(t) = \dot{x} * g(t) = \mathfrak{I}^{-1}(\dot{X}(\omega)G(\omega)) \quad (2.63)$$

$$\hat{y}(t) = \ddot{y} * g(t) = \mathfrak{I}^{-1}(\ddot{Y}(\omega)G(\omega)) \quad (2.64)$$

$$\hat{\ddot{x}}(t) = \dddot{x} * g(t) = \mathfrak{I}^{-1}(\dddot{X}(\omega)G(\omega)) \quad (2.65)$$

$$\hat{\ddot{y}}(t) = \dddot{y} * g(t) = \mathfrak{I}^{-1}(\dddot{Y}(\omega)G(\omega)) \quad (2.66)$$

obtendo assim a diferenciação multi-escala de primeira e segunda ordem $(\hat{x}(t), \hat{y}(t))$ e $(\hat{\ddot{x}}(t), \hat{\ddot{y}}(t))$ para $x(t)$ e $y(t)$, agora sim usadas para o cálculo de $k(t)$ (Eq. 2.56) sem a presença de possíveis ruídos de alta-frequência.

É importante notar que um *pico* é definido como um ponto de alta curvatura. Um ponto a é considerado um pico se sua curvatura $k(a)$ satisfazer os seguintes critérios:

$$k(a) > k(a-1) \quad (2.67)$$

$$k(a) > k(a+1) \quad (2.68)$$

Ou seja, um ponto a é dito pico se sua curvatura $k(a)$ for maior que seus vizinhos anteriores e posteriores. Isto é suficiente para determinar todos os picos contidos no contorno de uma forma qualquer. Porém, é preciso controlar quais picos são interessantes e quais devem ser descartados. Desta forma, deve-se incluir um novo critério:

$$k(a) > \tau \quad (2.69)$$

ou seja, apenas pontos com curvaturas maiores que o limiar τ serão consideradas. Este limiar, por sua vez, pode ser definido como

$$\text{mediana}(k) \cdot \gamma \quad (2.70)$$

onde γ equivale a um fator obtido empiricamente com valores que revelam um determinado nível de detalhe de curvatura. Quanto maior o valor de γ , mais picos de curvatura e vice-versa.

Tendo-se definido a curvatura $k(t)$ e um pico de curvatura a , pode-se partir para a definição de uma série de atributos. A média e o desvio padrão das distâncias geométricas entre um pico a_i e seu próximo pico a_{i+1} compõem os atributos \mathcal{A}_{89} e \mathcal{A}_{90} , usados neste estudo:

$$\mathcal{A}_{89} = \text{média}(\sqrt{(a_i - a_{i+1})^2}) \quad (2.71)$$

$$\mathcal{A}_{90} = \text{desvio padrão}(\sqrt{(a_i - a_{i+1})^2}) \quad (2.72)$$

Também pode-se considerar tal distância dada em coordenadas do pixel da imagem associada ao pico a , o que leva aos atributos \mathcal{A}_{91} e \mathcal{A}_{92} , que representam, respectivamente, a média e desvio padrão da distância em pixels entre um pico a_i e seu próximo pico a_{i+1} .

A simples quantidade de picos a de uma dada curvatura $k(t)$ revela um novo atributo:

$$\mathcal{A}_{93} = \text{tam}(\{a_i, a_{i+1}, \dots, a_N\}) \quad (2.73)$$

sendo *tam* o tamanho do conjunto de todos os picos a de uma curvatura calculada. Da mesma forma, a quantidade de elementos $k(t)$ da curvatura permite saber o perímetro em pixels da região conexa:

$$\mathcal{A}_{94} = \text{tam}(\{k(t_i), k(t_{i+1}), \dots, k(t_N)\}) \quad (2.74)$$

Ainda, somando-se todos os elementos da região conexa $C_i = i$, onde i representa o rótulo da região, tem-se a área desta região, em pixels, e portanto define-se um novo atributo \mathcal{A}_{95} . A razão entre o perímetro e a área, ambos em pixels, oferece mais um atributo:

$$\mathcal{A}_{96} = \frac{(\mathcal{A}_{94})^2}{\mathcal{A}_{95}} \quad (2.75)$$

essa razão indica quanto uma forma se aproxima de um círculo.

A quantidade C_N de regiões conexas C_i também caracteriza um atributo de interesse \mathcal{A}_{97} . Trata-se de um atributo importante pois indica o quanto uma imagem é complexa em relação ao número de elementos que a compõe (e.g. as pinturas de Pollock possuem um número muito maior de componentes do que a maioria dos outros pintores).

A área da região convexa de uma forma fornece outro atributo. É calculado através do algoritmo *convex-hull* (15) e define o atributo \mathcal{A}_{98} . A razão entre a área da região convexa e da região original do componente (\mathcal{A}_{95}) indicam outra medida de circularidade, ou o quanto o componente possui uma forma rica em curvas acentuadas:

$$\mathcal{A}_{99} = \frac{\mathcal{A}_{98}}{\mathcal{A}_{95}} \quad (2.76)$$

O conjunto de todos os 99 atributos \mathcal{A}_i discutidos estão sumarizados na Tabela 2.22. É importante ressaltar que cada imagem de pintura acaba apresentando um número arbitrário de regiões conexas após os processos de segmentação e pós-processamento. Desta forma, para cada pintura tem-se um ou mais valores para os atributos \mathcal{A}_{89-99} , e portanto a média destes valores foi tomada para representar cada um destes atributos para uma dada imagem.

2.5 Redução de dimensionalidade e classificação

Na maioria das rotinas de análises de dados, a quantidade de atributos leva à necessidade de selecionar quais atributos são mais relevantes ao objetivo previsto (e.g. garantir máximo agrupamento das amostras em certas classes) e reduzir a dimensionalidade das amostras a um ponto que se consiga visualizá-las. Essas necessidades estão presentes também neste estudo e alguns métodos foram selecionados para supri-las.

Existe um grande número de métodos para a identificação dos melhores atributos, aqui dois deles são descritos: matriz de espalhamento e LDA (Linear Discriminant Analysis). (15, 16, 57) Esse último também pode ser utilizado para a redução da dimensão da matriz de entrada, e é portanto descrito juntamente com outro método para redução de dimensionalidade, o PCA (Principal Components Analysis). (15, 58)

Tabela 2.22 – Sumário de todos os 99 atributos utilizados neste estudo, considerando detalhes de contraste, textura (descritas pelas medidas de entropias e energias, assim como as medidas de Haralick) e forma (descritas pelas medidas de curvatura e medidas geométricas como perímetro, área e sua razão).

\mathcal{A}_i	Descrição
\mathcal{A}_1	Média das energias nas linhas i da imagem em tons de cinza
\mathcal{A}_2	Desvio padrão das energias nas linhas i da imagem em tons de cinza
\mathcal{A}_3	Média das energias nas colunas j da imagem em tons de cinza
\mathcal{A}_4	Desvio padrão das energias nas colunas j da imagem em tons de cinza
\mathcal{A}_5	Centróide das energias nas linhas i da imagem em tons de cinza
\mathcal{A}_6	Centróide das energias nas colunas j da imagem em tons de cinza
\mathcal{A}_7	Média das energias nas linhas i e colunas j da imagem em tons de cinza
\mathcal{A}_8	Desvio padrão das energias nas linhas i e colunas j da imagem em tons de cinza
\mathcal{A}_{9-16}	As mesmas medidas \mathcal{A}_{1-8} mas aplicadas ao canal vermelho da imagem
\mathcal{A}_{17-24}	As mesmas medidas \mathcal{A}_{1-8} mas aplicadas ao canal verde da imagem
\mathcal{A}_{25-32}	As mesmas medidas \mathcal{A}_{1-8} mas aplicadas ao canal azul da imagem
\mathcal{A}_{33-46}	As 14 medidas de textura de Haralick para a direção $\beta = 0^\circ$ ou $\vec{d} = (1, 0)$
\mathcal{A}_{47-60}	As 14 medidas de textura de Haralick para a direção $\beta = 45^\circ$ ou $\vec{d} = (1, 1)$
\mathcal{A}_{61-74}	As 14 medidas de textura de Haralick para a direção $\beta = 90^\circ$ ou $\vec{d} = (0, 1)$
\mathcal{A}_{75-88}	As 14 medidas de textura de Haralick para a direção $\beta = 135^\circ$ ou $\vec{d} = (-1, 1)$
\mathcal{A}_{89}	Média das distâncias (euclidiana) entre os picos de curvatura
\mathcal{A}_{90}	Desvio padrão das distâncias (euclidiana) entre os picos de curvatura
\mathcal{A}_{91}	Média das distâncias (em pixels do contorno) entre os picos de curvatura
\mathcal{A}_{92}	Desvio padrão das distâncias (em pixels do contorno) entre os picos de curvatura
\mathcal{A}_{93}	Quantidade de picos de curvatura
\mathcal{A}_{94}	Perímetro da curvatura
\mathcal{A}_{95}	Área da região conexa
\mathcal{A}_{96}	Razão entre o perímetro e a área da região
\mathcal{A}_{97}	Quantidade de segmentos de uma pintura
\mathcal{A}_{98}	Área da região convexa
\mathcal{A}_{99}	Razão entre a área da região convexa e a área da região conexa original

O método conhecido como matrizes de espalhamento procura encontrar a melhor razão de Fisher, que é um indicador quantitativo de quanto duas ou mais classes estão apresentando menor covariância interna (agrupamento) e maior covariância entre as classes (dispersão). Ou seja, busca-se a projeção que mais separa as classes umas das outras. (15, 16)

Para todas as N amostras (no caso, pinturas), considerando todas as possíveis combinações de pares de atributos $F_{N,a}$ e $F_{N,b}$, as matrizes de espalhamento S_{inter} e S_{intra} são calculadas com K classes (no caso, $K = 12$ para 12 pintores), uma classe C_i para cada pintor:

$$S_{intra} = \sum_{i=1}^K S_i \quad (2.77)$$

$$S_{inter} = \sum_{i=1}^K N_i (\vec{\mu}_i - \vec{M})(\vec{\mu}_i - \vec{M})^T \quad (2.78)$$

sendo N_i o número de amostras para a classe C_i e a matriz de espalhamento para a classe C_i definida como

$$S_i = \sum_{i \in C_i} (\vec{f}_i - \vec{\mu}_i)(\vec{f}_i - \vec{\mu}_i)^T \quad (2.79)$$

onde \vec{f}_i é uma amostra da matriz de atributos F cujas linhas e colunas correspondem às amostras e seus atributos $F = [\leftarrow f_i^T \rightarrow]$ e $\vec{\mu}_i$ e \vec{M} são os vetores de média dos atributos para as amostras da classe C_i e para todas as amostras, respectivamente:

$$\vec{\mu}_i = \frac{1}{N_i} \sum_{i \in C_i} \vec{f}_i \quad (2.80)$$

$$\vec{M} = \frac{1}{N} \sum_{i=1}^N \vec{f}_i \quad (2.81)$$

O traço da razão entre as matrizes intra- e inter-classe resulta na razão de Fisher, a constante:

$$\alpha = \text{tr}(S_{inter} S_{intra}^{-1}) \quad (2.82)$$

Se ao invés de calcular o traço for calculado os autovalores e autovetores da razão das matrizes, tem-se a projeção que melhor separa as classes, ou seja, o LDA:

$$\text{eig}(S_{inter} S_{intra}^{-1}) \quad (2.83)$$

onde eig corresponde ao cálculo dos autovetores e autovalores do produto entre as matrizes de espalhamento. Ao tomar os autovetores dos maiores autovalores, em módulo, tem-se tal projeção. É por isso que o LDA pode ser concebido como um método de redução de dimensão, reduzindo os N atributos a um número de atributos $r < N$ (geralmente $r \leq 3$ para possibilitar a projeção em 2 ou 3 dimensões visíveis) que melhor separam as classes.

Convém aqui abordar um outro método de redução de dimensionalidade, o PCA, que lembra o LDA. No PCA, se está interessado em calcular os autovalores e autovetores que mais correlacionam os dados em questão. Para isso, toma-se a matriz de atributos F e calcula-se sua matriz de covariância, que nada mais é que a operação de covariância aplicada a cada dimensão i de uma matriz X qualquer. Considerando os momentos estatísticos básicos, a matriz de covariância $C^{n \times n}(X)$ dadas n dimensões de X é dada por

$$C^{n \times n}(X) = \begin{pmatrix} cov(x_1, x_1) & cov(x_1, x_2) & \dots & cov(x_1, x_n) \\ cov(x_2, x_1) & cov(x_2, x_2) & \dots & cov(x_2, x_n) \\ \vdots & \vdots & \vdots & \vdots \\ cov(x_n, x_1) & cov(x_n, x_2) & \dots & cov(x_n, x_n) \end{pmatrix} \quad (2.84)$$

onde x_i é a i -ésima dimensão da matriz X .

Novamente, calculando os autovalores (e seus respectivos autovetores) da matriz de covariância $C^{n \times n}(F)$ e tomando os autovetores dos maiores autovalores, em módulo, tem-se os *componentes principais*

$$V = \begin{pmatrix} \text{autovetor}_0 & \text{autovetor}_1 & \dots & \text{autovetor}_n \end{pmatrix} \quad (2.85)$$

que formarão uma base para a projeção dos dados com maior correlação possível através da multiplicação da matriz original F com os componentes principais V , ambos transpostos:

$$D = V^T \times F^T \quad (2.86)$$

ou seja, D é a base que mais “reúne características” dos demais atributos. Tomando-se apenas estes $r < N$ atributos, tem-se portanto uma redução na dimensão. Os autovalores indicam o quanto cada atributo contribui para a correlação. Portanto, é sempre interessante verificar se os r autovalores em módulo somam cerca de 70% do total, o que indica serem suficientes para representar os N atributos originais (15).

2.5.1 Validação Cruzada

A projeção obtida pelo método LDA através da Equação 2.83 não garante a classificação dos dados, visto que as classes são conhecidas previamente (fazendo com que o método LDA seja utilizado como parte de um método supervisionado de classificação). Assim, é preciso validar tal projeção obtida frente a outras possíveis escolhas dos conjuntos de treinamento e teste.

Um procedimento comum neste caso é a validação cruzada ou *cross validation*. Trata-se de um método bastante simples, onde os dados de amostra são divididos em dois grupos: um *conjunto de treinamento* e um *conjunto de teste*. O método LDA é então aplicado ao conjunto de treinamento, obtendo-se a projeção (Eq. 2.83). O LDA é aplicado em seguida ao conjunto de teste,

mas utilizando a projeção obtida para o conjunto de treinamento (i.e. os mesmos autovetores). Conta-se agora quais amostras do conjunto de teste foram projetadas próximas ao conjunto de treinamento, e quais estão distantes. Essa contagem revela se o conjunto de treinamento condiz com o esperado e desta forma, valida o método LDA aplicado.

Uma forma interessante de visualizar a validação cruzada é através da *matriz de confusão*, representada na Figura 2.23. Cada linha da matriz de confusão representa uma classe C_i do grupo de treinamento (no caso deste estudo, as classes correspondem a cada um dos pintores analisados) e cada coluna representa uma classe \hat{C}_i do grupo de teste. Cada elemento da matriz representa a contagem de amostras pertencentes a uma determinada classe, ou seja, as amostras de C_i que deveriam ser classificadas como \hat{C}_i . Desta forma, espera-se que a diagonal principal desta matriz esteja o mais próximo possível do número máximo de elementos para cada classe. Ou seja, elementos de uma classe C_1 devem ser classificados como pertencentes a esta classe, e não a qualquer outra classe. Um exemplo de matriz de confusão para o método LDA pode ser vista na Figura 3.27 da Seção 3.7 de resultados deste estudo.

		Conjunto de teste			
		\hat{C}_1	\hat{C}_2	\dots	\hat{C}_K
Conjunto de treinamento	C_1	Green	Pink	Pink	Pink
	C_2	Pink	Green	Pink	Pink
\vdots		Pink	Pink	Green	Pink
C_K		Pink	Pink	Pink	Green

Figura 2.23 – Esquema representando uma matriz de confusão. Deseja-se que a diagonal principal possua valores próximos ao número máximo de elementos em cada classe C_i , caracterizando assim uma boa classificação. C_i é uma classe do conjunto de treino e \hat{C}_i uma classe do conjunto de teste.

Conhecendo-se a quantidade de amostras que foram classificadas corretamente e aquelas que

não o foram, é possível calcular a acurácia da classificação, definida como

$$acc(C_i, \hat{C}_i) = \frac{1}{N_s} \sum_{j=0}^{N_s-1} \mathbf{1}(\hat{c}_j = c_j) \quad (2.87)$$

onde N_s é o número de amostras para uma classe C_i , c_j é uma amostra pertencente à C_i e \hat{c}_j é uma amostra pertencente à \hat{C}_i . Ainda, a função $\mathbf{1}$ é a função característica ou indicadora, que indica se um elemento pertence ao conjunto Q (assumindo o valor 1) ou não (assumindo o valor 0), ou seja:

$$\mathbf{1}(x) = \begin{cases} 1 & : x \in Q \\ 0 & : x \notin Q \end{cases} \quad (2.88)$$

Assim, a acurácia pode ser interpretada como a fração das amostras que foram classificadas como corretas para um determinado grupo de treino e teste.

3 Desenvolvimentos e Resultados

3.1 Pintores escolhidos

Para a análise foram selecionados 12 pintores de grande relevância histórica. Esse grupo abrange os estilos artísticos que vão do período Barroco aos movimentos da Arte Moderna. Seis dos pintores representam o período Barroco enquanto os 6 restantes representam movimentos da Arte Moderna. O grupo é mostrado na Tabela 3.1 juntamente com seu estilo, período ou movimento artístico mais representativo. É de conhecimento que pintores como Picasso demonstraram mais de um estilo durante a vida. Porém, para tal análise, apenas o estilo mais marcante (e pelo qual melhor se conhece e define o artista) foi escolhido. No caso de Picasso, apenas pinturas de sua fase Cubista (de 1909 a 1912) foram escolhidas, com o objetivo de representar tal movimento. É importante destacar que a escolha de dois períodos distantes (cerca de 150 anos separam o período Barroco dos movimentos da Arte Moderna, escolhidos para este estudo) é proposital. A história da Arte assim como a análise estética das pinturas de ambos períodos revela características contrastantes, porém tais afirmações são qualitativas. Neste estudo, fez-se tal escolha justamente com o objetivo de refutar ou afirmar estas afirmações, mas agora com base em medidas quantitativas.

Tabela 3.1 – Pintores escolhidos para a análise, exibidos em ordem cronológica, juntamente com o estilo artístico que melhor representa. Divididos em dois grupos: 6 pintores barrocos e 6 pintores modernos.

Artistas	Estilos/Movimentos/Períodos mais marcantes	Período crono.
Caravaggio	Barroco	1593 - 1610
Frans Hals	Barroco, Idade de ouro Holandesa	1620 - 1660
Nicolas Poussin	Barroco, Classicismo	1620 - 1660
Diego Velázquez	Barroco	1618 - 1660
Rembrandt	Barroco, Idade de ouro Holandesa, Realismo	1632 - 1650
Johannes Vermeer	Barroco, Idade de ouro Holandesa	1632 - 1670
Vincent van Gogh	Pós-Impressionismo	1888 - 1890
Wassily Kandinsky	Expressionismo, Arte abstrata	1922 - 1944
Henri Matisse	Modernismo, Fauvismo	1904 - 1910
Pablo Picasso	Cubismo	1909 - 1912
Joan Miró	Surrealismo, Dada	1922 - 1958
Jackson Pollock	Expressionismo abstrato	1947 - 1950

3.2 Corpus de pinturas

Para cada pintor, foram consideradas 20 imagens de suas pinturas, obtidas de arquivos em domínio público, organizados pela Wikipedia. Uma amostra dessas pinturas e seu respectivo ano de criação está listada na Tabela 3.2. Todas as 240 pinturas são apresentadas em forma de galeria no Apêndice B. Os arquivos de imagem das pinturas assim como o código-fonte que implementa esta análise encontra-se disponível online em <http://github.com/automata/ana-pintores> e no Apêndice A há instruções de sua instalação e uso.

3.3 Análise de imagens para extração de atributos

Todas as 240 imagens foram cortadas em janelas de 800×800 pixels. Esta janela quadrada foi posicionada com seu ponto superior mais à esquerda equivalendo ao ponto superior mais à esquerda da pintura (Figura 3.3). As imagens que possuíam dimensões menores que 800×800 foram escaladas para tal dimensão, mantendo o mesmo aspecto da imagem original em todas as

Tabela 3.2 – Algumas das 240 pinturas juntamente com a data de sua criação. Todas as pinturas usadas no estudo estão apresentadas em forma de galeria no Apêndice B.

Pintores	Título da obra	Ano de criação
Caravaggio	Músicos	1595
	Judite decapitando Holofernes	1598
	Davi com a cabeça de Golias	1610
Frans Hals	Retrato de uma mulher desconhecida	1618/20
	Retrato de Paulus van Beresteyn	1620s
	Retrato de Stephanus Geeraerds	1648/50
Nicolas Poussin	Vênus e Adônis	1624
	Céfalo e Aurora	1627
	Ácis e Galateia	1629
Diego Velázquez	Três músicos	1617/18
	O almoço	1618
	La mulatto	1620
Rembrandt	O vendedor de óculos (visão)	1624/25
	Os três cantores (audição)	1624/25
	Balaão e o burro	1626
Johannes Vermeer	A leiteira	1658
	O astrônomo	1668
	Garota com brincos de pérola	1665
Vincent van Gogh	Noite estrelada sobre o Ródano	1888
	A noite estrelada	1889
Wassily Kandinsky	Auto-retrato com chapéu de palha	1887/88
	Em branco II	1923
	Composição X	1939
Henri Matisse	Pontos	1920
	Auto-retrato em uma camiseta listrada	1906
	Retrato de Madame Matisse	1905
Pablo Picasso	A dança (primeira versão)	1909
	Les Demoiselles d'Avignon	1907
	Guernica	1937
Joan Miró	Dora Maar au Chat	1941
	O fazendeiro	1921/22
	O campo lavrado	1923/24
Jackson Pollock	Bleu II	1961
	No. 5	1948
	Ritmo de outono	1950
	Pólos azuis	1952

pinturas.

a) Imagem original



b) Janela em destaque



c) Imagem recortada utilizada



Figura 3.3 – Pré-processamento para recorte das imagens originais em janelas de dimensão 800×800 .
 a) a imagem original, b) a janela em destaque, c) a imagem de dimensões 800×800 utilizada neste estudo. Embora se percam detalhes da imagem original, o janelamento é necessário para facilitar o processamento ao se utilizar uma dimensão única para as imagens.

Em seguida, as imagens foram pré-processadas aplicando-se equalização por histograma e filtro

de médias com janelamento de raio 3 (Figura 3.4), ambas descritas na Subseção 2.3.2.




Figura 3.4 – Pré-processamento utilizando equalização por histograma e filtro de médias com janelamento de raio 3. a) a imagem original em escala de cinza, b) a imagem equalizada, c) a imagem filtrada através do filtro de médias. Pode-se perceber que a luminosidade da imagem está homogênea e seus detalhes de borda foram suavizados.

Algoritmos de extração de características foram aplicados a versões coloridas, em escala de cinza e preto-e-branco das imagens (Figura 3.5), conforme necessário (i.e. para o algoritmo convex-hull, uma imagem binária B foi utilizada, enquanto para o algoritmo de textura de Haralick, uma imagem em escala de cinza G foi utilizada, já a segmentação SLIC utilizou a versão RGB, a matriz I , de cada imagem).

Com o objetivo de mensurar características de regiões das pinturas, métodos de segmentação foram utilizados, a saber: Watershed, SLIC e Felzenswald. Após experimentos (Figura 3.6), preferiu-se o método de segmentação SLIC (descrito na Subseção 2.3.3), por apresentar melhor separação das regiões de cada pintura. O parâmetro k (número de *clusters*) da segmentação SLIC foi ajustado de forma a melhor segmentar as regiões: como é possível notar no detalhe e) da Figura 3.6: outros valores que os escolhidos para parametrização do método revelaram resultados que não contribuiriam para uma boa segmentação.




Figura 3.5 – Tipos de imagens utilizadas no estudo. a) imagem colorida I em formato RGB, b) imagem em escala de cinza G, e c) imagem binária B.

Tendo-se as regiões separadas, estas foram agrupadas em componentes conexos, ou seja, em regiões conectadas e independentes umas das outras (detalhes na Figura 3.7 e Subseção 2.3.4). Com tais regiões agrupadas, partiu-se para o cálculo de curvatura de cada região e demais medidas descritas na Seção 2.4. A Figura 3.8 mostra algumas das regiões segmentadas e suas respectivas curvaturas.

Todo o processo está representado esquematicamente na Figura 3.9 e abrange todos os passos, do processamento das imagens das pinturas até o cálculo de medidas de dialética, oposição e inovação, discutidas em detalhes nos próximos capítulos, e portanto, destacadas na figura.

3.4 Seleção de atributos

Para selecionar os atributos mais relevantes, neste caso, os atributos que separassem melhor os grupos de pinturas – em outras palavras, que garantissem menor covariância interna em cada classe e maior covariância entre as classes – uma medida de dispersão é aplicada usando as matrizes esparsas discutidas na Seção 2.5.




Figura 3.6 – Experimentos realizados para segmentação de pinturas. a) a imagem original, b) segmentação por Watershed, c) Felzenswald, d) SLIC com $k = 10$ e e) SLIC com $k = 20$. O método SLIC foi escolhido por apresentar, visualmente, melhor separação dos segmentos, e os parâmetros escolhidos contribuíram para a segmentação apresentada.



Figura 3.7 – Pós-processamento através da rotulação dos componentes conexos e sua filtragem, removendo as regiões com áreas menores que um dado limiar. a) Detalhe de regiões segmentadas através do algoritmo SLIC, b) objetos rotulados, c) objetos com área menor que limiar removidos. É a partir desta última imagem que se realizou a extração de características.

Calculando α através da Eq. 2.82 para todos os possíveis pares de atributos $F_{N,a}$ e $F_{N,b}$ dos $N = 99$ atributos e ordenando os resultados por α , é possível selecionar todos os atributos mais relevantes para a classificação: pares com maiores valores de α apresentam melhor dispersão inter-classe e agrupamento intra-classe do que pares com menores valores. Como visto na Tabela 3.10 (e mais a frente, nas Figuras 3.14 e 3.15), os atributos *média dos picos de curvatura* e *média do número de segmentos* possuem maior valor de α e foram selecionados para a análise das medidas de oposição, inovação e dialética — ambos atributos se mostraram predominantes mesmo na projeção por LDA, discutida na Seção 3.7. É interessante notar a natureza dos atributos selecionados: o número de segmentos em cada pintura e os picos de curvatura são características proeminentes para a classificação das pinturas, melhores até mesmo que os atributos de textura de Haralick e de complexidade de imagens (entropia). Outros atributos que apresentaram também valores altos de α — como média da área de *convex-hull*, do perímetro dos segmentos e da área do segmento, e circularidade — também são relacionadas com características de forma. Ambos atributos apresentaram projeções e propriedades de agrupamento similares às da Figura 3.14 como mostrado na Figura 3.11.




Figura 3.8 – Regiões segmentadas e suas respectivas curvaturas. Os marcadores em vermelho identificam os picos de curvatura no perfil e sua localização na região segmentada.

3.5 Medidas de dialética, oposição e inovação

Havendo N_f atributos \vec{f}_i , define-se um espaço N_f -dimensional chamado de *espaço criativo*, pois a exemplo do espaço criativo sugerido por Deleuze (12), tem como objetivo a representação de uma superfície onde artefatos (e.g. pinturas, peças musicais, poemas) criados por agentes (e.g. pintores, compositores, escritores) caracterizam uma região que foi explorada criativamente. É neste espaço criativo que as medidas de dialética, oposição e inovação são calculadas (1).




Figura 3.9 – Diagrama com todos os passos tomados, desde o processamento das imagens das pinturas até a extração de características, assim como a obtenção da série temporal onde foram calculadas as medidas de oposição, inovação e dialética.

Para simplificar o cálculo, um protótipo \vec{p}_i é definido para cada classe C_p . Cada protótipo summariza uma classe de pinturas (ou um pintor), correspondendo ao seu *centróide*: $\vec{p}_i = \frac{1}{N_p} \sum_{i=1}^{N_p} \vec{f}_i$ calculado no espaço projetado. É importante notar que essa medida é independente de dimensão, porém métodos de redução de dimensionalidade são aplicados à matriz de atributos para

Tabela 3.10 – Pares de atributos $F_{N,a}$ e $F_{N,b}$ ordenados por α . Pares com valores maiores de α mostram maior dispersão inter-classe enquanto menor dispersão intra-classe (maior agrupamento). O melhor par de atributos: média dos picos de curvatura e média do número de segmentos são selecionados para a análise e cálculo das medidas.

Par	Atributo a	Atributo b	α
1	média do número de picos	média do número de segmentos	42.445
2	média do número de segmentos	média da área de convex-hull	37.406
3	média do perímetro do segmento	média do número de segmentos	36.703
4	média da área do segmento	média do número de segmentos	36.214
5	média do número de segmentos	média área convexa / área total	34.885
6	média de circularidade ($Per.^2/Area$)	média do número de segmentos	33.540
7	média da energia das linhas (canal verde)	média do número de segmentos	32.954
8	média da energia das linhas e colunas (canal verde)	média do número de segmentos	32.954
9	d.p. da energia das linhas (canal verde)	média do número de segmentos	32.932
10	d.p. da energia das linhas e colunas (canal verde)	média do número de segmentos	32.906
11	média de entropia local (janela de dimensão 5)	média do número de segmentos	32.898
12	entropia (Haralick adj. 4)	média do número de segmentos	32.898
13	entropia (Haralick adj. 3)	média do número de segmentos	32.883
14	entropia (Haralick adj. 1)	média do número de segmentos	32.874
15	entropia (Haralick adj. 2)	média do número de segmentos	32.869
16	média da energia das linhas (canal vermelho)	média do número de segmentos	32.865

possibilitar a visualização do *espaço criativo* em duas dimensões.

Uma sequência S de \vec{p}_i estados define uma série temporal que modela uma aproximação do que seria a linha cronológica para as pinturas e seus movimentos artísticos. Um estado médio em um dado tempo i abrangendo os estados \vec{p}_1 até \vec{p}_i é definido como

$$\vec{d}_i = \frac{1}{i} \sum_{j=1}^i \vec{p}_j. \quad (3.1)$$

O estado de oposição \vec{r}_i define uma medida de oposição à \vec{p}_i como

$$\vec{r}_i = \vec{p}_i + 2(\vec{d}_i - \vec{p}_i) \quad (3.2)$$

e dessa forma, um vetor de oposição \vec{D}_i pode ser definido como




Figura 3.11 – Matrizes esparsas para cada i -ézimo par de atributos listado na Tabela 3.10 com os maiores valores para α . A primeira projeção (par 1) foi utilizado nesse estudo.

$$\vec{D}_i = \vec{r}_i - \vec{p}_i \quad (3.3)$$

que representa propriamente o deslocamento do estado \vec{r}_i em função de \vec{p}_i .

Sabendo que qualquer deslocamento a partir de um estado \vec{p}_i até um outro estado \vec{p}_j é definido

como

$$\vec{M}_{i,j} = \vec{p}_j - \vec{p}_i \quad (3.4)$$

é possível definir um *índice de oposição* $W_{i,j}$ para quantificar quanto um protótipo \vec{p}_j se opõe a outro protótipo \vec{p}_i (ou seja, um deslocamento na direção de \vec{r}_i) ou concorda com outro protótipo p_i (um deslocamento na direção de $-\vec{r}_i$):

$$W_{i,j} = \frac{\langle \vec{M}_{i,j}, \vec{D}_i \rangle}{\|\vec{D}_i\|^2} \quad (3.5)$$

sendo portanto a projeção de $\vec{M}_{i,j}$ em \vec{D}_i , ou seja, não importa onde o deslocamento tenha sido dado, ele é considerado em relação ao vetor de oposição (ou deslocamento) \vec{D}_i . A Figura 3.12 ilustra \vec{D}_i , dados dois estados consecutivos \vec{p}_i e \vec{p}_j , o estado de oposição \vec{r}_i e o estado médio \vec{d}_i .

Porém, movimentos nesse *espaço criativo* não estão restritos à confirmação ou contradição de “ideias”. Ideias alternativas podem existir fora desse deslocamento dualístico. Isso é modelado como um *índice de inovação* que quantifica quanto um protótipo \vec{p}_j é inovador quando comparado com um outro protótipo \vec{p}_i :

$$s_{i,j} = \sqrt{\frac{|\vec{p}_i - \vec{p}_j|^2 |\vec{d}_i - \vec{p}_i|^2 - [(\vec{p}_i - \vec{p}_j) \cdot (\vec{d}_i - \vec{p}_i)]^2}{|\vec{d}_i - \vec{p}_i|^2}} \quad (3.6)$$

ou seja, quanto \vec{p}_j se afasta da linha L_i formada por \vec{p}_i e \vec{r}_i : a linha de “oposição”. A Figura 3.12 também ilustra os cálculos dos índices de oposição e inovação para dois estados consecutivos \vec{p}_i e \vec{p}_j da série temporal e uma linha L_i .

Uma outra medida surge quando consideram-se três estados consecutivos nos tempos i, j e k . Sendo \vec{p}_i a tese, \vec{p}_j a antítese e \vec{p}_k a síntese, um *índice de contra-dialética* (1) pode ser definido como sendo




Figura 3.12 – Cálculo dos índices de oposição $W_{i,j}$ — com base no deslocamento \vec{D}_i e inovação $s_{i,j}$ dados dois estados consecutivos \vec{p}_i e \vec{p}_j .

$$d_{i \rightarrow k} = \frac{|\langle \vec{p}_j - \vec{p}_i, \vec{p}_k \rangle + \frac{1}{2} \langle \vec{p}_i - \vec{p}_j, \vec{p}_i + \vec{p}_j \rangle|}{|\vec{p}_j - \vec{p}_i|} \quad (3.7)$$

ou, a distância entre \vec{p}_k e a bissetriz $B_{i,j}$ (ou um “hiperplano bissetriz” quando considerando espaços N_f -dimensionais com $N_f > 3$) entre \vec{p}_i e \vec{p}_j . Em outras palavras, um estado \vec{p}_k com grande distância $d_{i \rightarrow k}$ está afastado da síntese (possui baixa dialética) e vice-versa. A medida de contra-dialética $d_{i \rightarrow k}$ é ilustrada na Figura 3.13 para três estados consecutivos \vec{p}_i , \vec{p}_j e \vec{p}_k da série temporal, dada uma bissetriz $B_{i,j}$ formada pelos dois primeiros estados da série.

3.6 Análise das pinturas para atributos com maior dispersão

O espaço criativo projetado considerando todas as pinturas “representadas” por \vec{p}_i é apresentado na Figura 3.14. A série temporal formada pelos protótipos \vec{p}_i para cada pintor no espaço




Figura 3.13 – Cálculo da contra-dialética $d_{i \rightarrow k}$ dados os estados consecutivos de tese \vec{p}_i , antítese \vec{p}_j e síntese \vec{p}_k . Quanto maior o valor da distância $d_{i \rightarrow k}$ de \vec{p}_k à síntese ideal formada pela bissetriz $B_{i,j}$ entre \vec{p}_i e \vec{p}_j , menor a dialética.

projeto é visto na Figura 3.15, facilitando a visualização da evolução da série.

Detalhes interessantes surgem dessa projeção e confirmam algumas das hipóteses levantadas na Seção 2.1.3, aqui relembradas e confrontadas com interpretações a partir dos dados quantitativos obtidos na projeção:

- Os pintores da Arte Moderna são caracterizados por sua independência em estilo. Já os pintores do período Barroco apresentam semelhanças, por compartilharem estilos tradicionais. Essa é uma das observações mais relevantes deste estudo. É possível notar na Figura 3.14 que há maior sobreposição entre pintores barrocos do que pintores dos movimentos modernos. Esse fato é confirmado pela história da Arte onde os pintores modernos experimentam novos materiais e desenvolvem estilos próprios para representar o que desejam, enquanto os barrocos tendem a utilizar estilos tradicionais, como o *chiaroscuro*.




Figura 3.14 – Projeção do espaço criativo considerando o melhor par de atributos média de picos da curvatura e média do número de segmentos.

roscuro de Caravaggio. Os deslocamentos de um artista ao outro também são claramente contrastantes: o módulo dos vetores de deslocamento $\vec{M}_{i,j}$ para os pintores modernos é, em média, maior que os deslocamentos para os pintores barrocos. Este é mais um indicador de que os artistas barrocos compartilhavam semelhanças em estilo, enquanto que




Figura 3.15 – Série temporal considerando o melhor par de atributos média de picos da curvatura e média do número de segmentos.

os modernos distanciavam-se claramente uns dos outros. Ao contemplar a Figura 3.15 percebe-se que há uma certa exploração do que seria o *espaço criativo* por parte dos artistas barrocos, mas a largura dessa exploração não se compara à realizada pelos pintores modernos que percorrem uma região muito mais ampla, chegando a explorar regiões de

extremos opostos como no caso de Pollock.

- *Há uma diferença considerável de tempo decorrido desde o Barroco até os movimentos da Arte Moderna.* Quando se observa a série temporal da Figura 3.15, a diferença entre os períodos fica evidente: enquanto os barrocos retornam uns aos outros, há um deslocamento abrupto em van Gogh — o primeiro pintor moderno considerado nesse estudo — que o separa dos primeiros pintores. Van Gogh, embora localizado próximo aos pintores barrocos e no extremo oposto da maioria dos pintores modernos, estabelece o início do período Moderno e depois dele os deslocamentos de um vetor a outro continuam a evoluir até alcançar seu ápice, em Pollock. Essa mesma separação entre os períodos Barroco e da Arte Moderna são notados nas medidas de dialética, oposição e inovação, discutidas mais a frente.
- *Pollock apresenta pinturas que diferem de todos os outros pintores escolhidos.* De todos os *clusters* da projeção na Figura 3.14, Pollock é quem mais se distancia dos demais pintores. Isso se deve ao grande número de segmentos presentes nas pinturas de Pollock quando comparado aos demais artistas (o eixo-y corresponde à projeção desse atributo: *média do número de segmentos*). De qualquer forma, ambos eixos x (*média do número de picos da curvatura*) e y são relevantes para separar os períodos Barroco e Moderno.
- *Velázquez e Vermeer se assemelham com Caravaggio pois ambos utilizavam chiaroscuro.* A trajetória desenhada (na Figura 3.15) de Caravaggio e Frans Hals até Poussin estabelece um caminho que termina com um movimento de oposição (e de retorno) de Velázquez, que retorna a Caravaggio. Isso também é notado no movimento de retorno à Cavaraggio apresentado por Vermeer — alguns críticos (59) afirmam que pintores como Vermeer nem teriam existido se não fosse a influência de Caravaggio: os agrupamentos de pinturas de Vermeer e Caravaggio apresentam a maior sobreposição dentre todos os agrupamentos presentes no *espaço criativo*. Isso pode ser atribuído à influência do mestre do “chiaros-

curo” em ambos pintores, principalmente em Velázquez que foi reconhecidamente um estudioso das pinturas de Caravaggio (6). Ambos fatos são confirmados pelos histogramas do nível médio de cinza das pinturas mostrados na Figura 3.16. Os histogramas de Velázquez e Vermeer são os que mais se aproximam do histograma de Caravaggio quando comparados aos outros pintores barrocos.

- *Caravaggio é o principal expoente no uso da técnica do chiaroscuro.* Além da influência de Caravaggio em pintores como Velázquez e Vermeer, isso é também confirmado quando se comparam os histogramas dos pintores modernos na Figura 3.17 com os histogramas para os pintores barrocos da Figura 3.16: há baixa similaridade entre os pintores modernos considerados, contrastando diretamente com os pintores barrocos, onde as curvas tendem a Caravaggio. Assim, afirma-se que há grande diferença de contraste entre as pinturas barrocas (principalmente as de Caravaggio) e aquelas da Arte Moderna.

Quando são consideradas as medidas de oposição e inovação, outros resultados interessantes apresentam-se, como mostrado na Tabela 3.18 e Figura 3.19. Claramente, o maior valor de oposição é atribuído a Rembrandt. Esse fato é curioso por si, considerando que o mestre holandês é reconhecido como um “contraponto” ao movimento Barroco, mesmo tendo sido parte desse movimento. (6) Vermeer também apresenta forte oposição e a natureza de suas pinturas (e.g. interiores domésticos, uso de cores claras) pode explicar esse fenômeno. Um padrão torna-se visível no começo de ambos períodos Barroco e Moderno: decréscimo contínuo nos valores de oposição, seguido de acréscimo. Da mesma forma, um platô com alta oposição é observado nos pintores barrocos. Esse platô ocorre exatamente na transição de um período artístico ao outro, diminuindo gradualmente enquanto os artistas modernos começam a se estabelecer na história. Esse decréscimo dos valores de oposição refletem um aspecto de baixa oposição entre os primeiros artistas barrocos enquanto há o acréscimo da oposição presente nos deslocamentos que precedem o período Moderno, embora os valores de inovação se mantém oscilando mas




Figura 3.16 – Histogramas dos níveis médios de cinza para todos os pintores barrocos. Vermeer e Velázquez mostram maior similaridade com Caravaggio do que os outros pintores barrocos: a proximidade em contraste encontra fundamento na história (Seção 2.1.3), tendo sido ambos pintores influenciados por Caravaggio.

aumentando durante toda a série temporal.

Em resumo, no que se pode falar dos índices de oposição e inovação, o *espaço criativo* é marcado por aumento constante de inovação, grande oposição em momentos específicos de sua evolução (a transição entre o Barroco e a Arte Moderna) e menor oposição entre artistas de um mesmo movimento, principalmente no Barroco.




Figura 3.17 – Histogramas nos níveis médios de cinza para os pintores modernos. Há baixa similaridade entre os pintores modernos, diferente do que ocorre para os pintores barrocos.

No que tange a contra-dialética, mostrada na Tabela 3.20 e Figura 3.21, há um paralelo com as curvas de oposição e inovação. A contra-dialética reforça fatos já observados: pintores do mesmo período mostram inicialmente um decréscimo em seus valores, seguido por acréscimo contínuo. O pico de contra-dialética acontece em van Gogh e Kandinsky: de novo, exatamente o ponto onde o Barroco termina e a Arte Moderna começa, considerando os pintores selecionados para esse estudo.

3.7 Análise por LDA de todos os atributos

Embora os atributos *média de picos de curvatura* e *média do número de segmentos* apresentaram-se como opções interessantes para a classificação, o método LDA foi aplicado considerando todos os $N = 99$ atributos com o objetivo de testar a relevância dos atributos originalmente selecionados e a estabilidade dos resultados. O método LDA projeta os atributos em um espaço

Tabela 3.18 – Índice de oposição $W_{i,j}$ e inovação $s_{i,j}$ para cada um dos 11 deslocamentos de um pintor a outro.

Deslocamento	$W_{i,j}$	$s_{i,j}$
Caravaggio → Frans Hals	1.	0.
Frans Hals → Poussin	0.111	0.425
Poussin → Velázquez	0.621	0.004
Velázquez → Rembrandt	1.258	0.072
Rembrandt → Vermeer	1.152	0.341
Vermeer → Van Gogh	1.158	0.280
Van Gogh → Kandinsky	0.970	0.452
Kandinsky → Matisse	0.089	0.189
Matisse → Picasso	0.117	0.509
Picasso → Miró	0.385	0.325
Miró → Pollock	2.376	3.823

de $n < N$ dimensões que melhor separa as pinturas e que acaba por resultar em uma nova série temporal como feito para o caso dos melhores atributos. Nesse caso, para permitir a visualização das medidas, considerou-se a projeção com $n = 2$ componentes que resultou em um espaço de 2 dimensões, mostrado na Figura 3.22. É possível notar que os resultados para a análise por LDA são ainda mais aparentes do que aqueles obtidos na Seção 3.6: os índices de inovação (Figura 3.24) apresentam uma curva ascendente ainda mais bem definida durante toda a evolução da série. Os padrões notados na evolução de ambos índices de oposição e contra-dialética continuam visíveis nessa nova projeção por LDA, como é possível notar na Figuras 3.24 e 3.26, respectivamente.

Para validação do LDA aplicou-se *cross validation*. O grupo de 240 pinturas foi dividido em dois: um conjunto de treinamento contendo 10 pinturas selecionadas aleatoriamente para cada artista, e um conjunto de teste contendo as 10 pinturas restantes para cada artista, ambos sem repetição. A matriz de confusão indica o quanto satisfatória é a classificação. O cálculo da matriz de confusão foi repetido 100 vezes e a Figura 3.27 mostra a matriz de confusão média. Ainda, a função de acurácia foi calculada em cada uma das repetições e teve seu valor em média ultrapassando 58% de acurácia. Os elementos da diagonal principal representam o número de amostras




Figura 3.19 – Valores de oposição W_{ij} e inovação s_{ij} considerando os dois melhores atributos.

(pinturas) para as quais a classe obtida no conjunto de teste coincide com a classe esperada (obtida na fase de treinamento). Elementos localizados fora da diagonal principal indicam aquelas amostras que não foram classificados corretamente pelo método LDA. Quanto maiores os valores da diagonal principal, melhor a predição de classes. Como é possível observar, o método LDA demonstra predição esperada para o grupo de pinturas considerado. As amostras com melhor classificação são as pinturas de Pollock, o que é esperado, pois é o pintor que mais se distancia dos outros no *espaço criativo*. Em geral, a matriz de confusão reflete os resultados previamente discutidos: há similaridade entre pintores barrocos, principalmente Velázquez, Caravaggio e Rembrandt e é possível notar claramente a separação entre pintores anteriores e

Tabela 3.20 – Índices de contra-dialética para cada um dos 10 deslocamentos entre tese, antítese e síntese, considerando os dois melhores atributos.

Tese, antítese e síntese	$d_{i \rightarrow k}$
Caravaggio → Frans Hals → Poussin	0.572
Frans Hals → Poussin → Velázquez	0.337
Poussin → Velázquez → Rembrandt	0.151
Velázquez → Rembrandt → Vermeer	0.608
Rembrandt → Vermeer → Van Gogh	1.362
Vermeer → Van Gogh → Kandinsky	1.502
Van Gogh → Kandinsky → Matisse	1.062
Kandinsky → Matisse → Picasso	0.183
Matisse → Picasso → Miró	0.447
Picasso → Miró → Pollock	2.616

posteriores a van Gogh, que define a fronteira entre os períodos Barroco e Moderno.




Figura 3.21 – Valores de contra-dialética considerando os dois melhores atributos.

Tabela 3.23 – Índices de oposição e inovação para cada um dos 11 deslocamentos de um pintor ao outro.

Deslocamento	$W_{i,j}$	$s_{i,j}$
Caravaggio → Frans Hals	1.	0.
Frans Hals → Poussin	-0.101	0.132
Poussin → Velázquez	0.588	0.037
Velázquez → Rembrandt	1.526	0.050
Rembrandt → Vermeer	1.101	0.143
Vermeer → Van Gogh	1.153	0.157
Van Gogh → Kandinsky	1.279	0.512
Kandinsky → Matisse	0.179	0.149
Matisse → Picasso	-0.201	0.516
Picasso → Miró	0.432	0.163
Miró → Pollock	4.031	2.662




Figura 3.22 – Série temporal resultante da projeção em 2 dimensões do espaço criativo considerando os dois primeiros componentes com maiores autovalores obtidos a partir da transformação LDA na matriz de $N = 99$ atributos.




Figura 3.24 – Valores de oposição e inovação considerando a série temporal para todos os $N = 99$ atributos refletidos nos dois primeiros componentes obtidos pelo método LDA. Os mesmos padrões observados quando considerando os dois melhores atributos ainda permanecem nessa observação, como esperado.

Tabela 3.25 – Índices de contra-dialética para cada um dos deslocamentos para os dois melhores componentes do LDA.

Deslocamento	Contra-dialética ($d_{i \rightarrow k}$)
Caravaggio → Frans Hals → Poussin	0.587
Frans Hals → Poussin → Vel'azquez	0.317
Poussin → Vel'azquez → Rembrandt	0.268
Vel'azquez → Rembrandt → Vermeer	0.736
Rembrandt → Vermeer → Van Gogh	1.192
Vermeer → Van Gogh → Kandinsky	2.352
Van Gogh → Kandinsky → Matisse	0.974
Kandinsky → Matisse → Picasso	0.241
Matisse → Picasso → Mir'o	0.704
Picasso → Mir'o → Pollock	1.924




Figura 3.26 – Contra-dialética (valores altos indicam baixa incidência de dialética) calculada para os componentes principais obtidos por LDA. O padrão observado anteriormente para o melhor par de atributos apresenta-se ainda mais visível aqui: é possível observar claramente que o maior valor está no ponto de transição dos movimentos artísticos (van Gogh e Kandinsky).




Figura 3.27 – Matriz de confusão média para o método LDA calculada durante 100 iterações. Metade das pinturas de cada artista é usado como conjunto de treino e a metade restante como conjunto de teste. Os elementos da diagonal principal mostram o número de amostras da classe esperada que correspondem com a classe obtida pelo método. Dada a grande quantidade de valores na diagonal principal, a validação sugere que o método LDA foi suficiente para a classificação das pinturas. Além disso, detalhes já observados nos resultados desse estudo são novamente observados na matriz: deslocamento de Van Gogh e similaridade entre pintores do mesmo período, principalmente Barroco. A função de acurácia também foi calculada, equivalendo em média a 58% de acurácia.

4 Conclusões

Este trabalho propõe um método para o estudo da evolução de estilos artísticos através da quantificação de conceitos, antes exclusivamente humanos. Como caso de estudo, aplica-se tal método para o entendimento dos períodos Barroco e movimentos da Arte Moderna, na Pintura. Iniciando com a escolha de representantes de cada um destes movimentos, 12 nomes são sugeridos e 240 pinturas destes artistas são escolhidas. Rotinas de processamento digital de imagens permitem a extração de características deste corpus de pinturas. São extraídas de cada pintura um vetor de 99 atributos que caracterizam aspectos de complexidade da imagem, textura, forma e contorno. A relevância de tais atributos foi atestada pela análise do índice de dispersão α calculado através de matrizes de espalhamento para cada par possível de atributos. Uma análise baseada na medida α revelou que os atributos que melhor classificaram as pinturas foram *a) número médio de picos de curvatura e b) número médio de segmentos por imagem*, ambos relacionados com a forma dos segmentos extraídos das imagens automaticamente. Uma interpretação possível para este resultado é que as pinturas barrocas apresentam formas maiores (e.g. paisagens da natureza e formas humanas) com poucos detalhes de curvatura. Já as pinturas modernas apresentam formas menores e em maior número (e.g. os quadros de Kandinsky e Miró são repletos de pequenas formas, assim como as pinturas abstratas de Pollock). As formas encontradas na pinturas modernas também são diferentes das do barroco: apresentam maior detalhe de curvatura devido ao uso de retas e cantos agudos, como é possível perceber no Cubismo e no uso de formas geométricas por Kandinsky ou Miró. Outros atributos que apresentaram al-

tos valores para α também estavam, em geral, relacionados com a forma. Esses atributos podem ser usados satisfatoriamente para a classificação de pintores, apresentando resultados ainda melhores que descritores canônicos em processamento de imagens como as medidas de textura de Haralick ou medidas baseadas na complexidade de figuras (i.e. entropia). Essa seleção de atributos foi reforçada através da aplicação do método LDA, pela projeção dos componentes que mais dispersam os grupos de pinturas. Os resultados obtidos para essa projeção apresentaram grande similaridade com aqueles encontrados para os melhores pares de atributos, segundo os valores de α . O método LDA, por sua vez, foi validado através de validação cruzada, que acabou por reforçar as observações e padrões obtidos para as medidas de inovação, oposição e dialética. A matriz de confusão resultante, além de revelar a classificação esperada (e.g. quando se observa sua diagonal principal, a classe esperada para determinado pintor coincide com a classe obtida) ainda confirmou a separação entre os grupos de pintores barrocos e modernos e o isolamento de Pollock do resto do grupo, apresentando-o com 100% de acerto na matriz de confusão.

A caracterização das pinturas pelo uso destes atributos tornou possível a análise de medidas quantitativas (i.e. geométricas). Embora de importância central para o entendimento da evolução da humanidade, conceitos filosóficos como a dialética não são abordados comumente pelas Ciências Exatas. Enquanto tratadas como medidas geométricas, as medidas de oposição, inovação e dialética revelaram conceitos importantes que puderam ser comparados com resultados já obtidos para a Música e Filosofia (1). Compositores mostram altos valores de dialética, o que sugere a tradição mestre-aprendiz — reconhecida nas escolas musicais. Filósofos, por sua vez, mostram grandes valores de oposição, o que também encontra base em como a evolução da Filosofia se dá: geralmente, através do conflito de ideias. Pintores, como mostrado nesse estudo, exibem decréscimo nos valores de oposição e dialética no início de cada período artístico considerado. Esse decréscimo é seguido por um aumento constante até encontrar seu ápice, exatamente no momento onde há a mudança de um período (Barroco) para o outro (Moderno).

Ainda, diferente dos filósofos e músicos, na Pintura a inovação apresenta valores com acréscimo constante, durante toda a série temporal. Isso pode refletir a influência de cada movimento ou período artístico em seus representantes, juntamente com um constante desejo de inovar, presente principalmente nos pintores modernos. Dessa forma, fatos já fundamentados na história das artes são confirmados por tais medidas quantitativas. Nesse sentido, uma das observações mais sumárias é a sobreposição de pinturas barrocas enquanto nos pintores modernos isso não acontece. Pelo contrário, os grupos de pintores modernos apresentam pouca sobreposição e, ao mesmo tempo, cobrem uma região maior do espaço geométrico quando comparados aos barrocos. Essas observações encontram paralelo na história, com os barrocos compartilhando as características estéticas de suas obras uns com os outros, enquanto os modernos procuram definir cada um seu próprio estilo.

Embora insuficiente para esgotar todas as características encontradas em um artista e sua obra, esse método sugere um *framework* para o estudo das Ciências Humanas através de medidas geométricas em um espaço de atributos. Mais uma vez reforça-se que, ao invés de suplantar as discussões humanas, que tanto trazem de valor para o entendimento da sociedade, esse *framework* pretende somar, fornecendo mais um ponto de vista.

Como trabalhos futuros, o número de pintores pode ser expandido e um conjunto de pintores pode ser escolhido especificamente para investigar suas influências (e.g. pinturas dos filhos de Frans Hals podem ser incluídas para verificar a influência de seu pai e mestre, ou ainda, pinturas de Rafael, Poussin e Guido Reni (6) ou Carracci podem ser comparadas entre si com o objetivo de verificar a já reconhecida similaridade entre ambos pintores, ou a influência de Cézanne em Matisse e Picasso, que declarou: “meu primeiro e único mestre, (...) Cézanne é o pai de todos nós” (39)). A evolução de um mesmo artista pode ser analisada, assim como a evolução ocorrida dentro de uma escola específica. Pode-se assim comparar tal análise com as evoluções obtidas para outras escolas e confirmar (ou não) o mesmo aspecto observado na análise deste estudo

— onde as medidas de dialética e oposição apresentaram picos de valores nos momentos de transição do período Barroco para a Arte Moderna. Ainda, um número maior de pinturas para cada artista pode ser considerado para análise. O mesmo *framework* pode ser aplicado (como já demonstrado para a Música, Filosofia e Pintura) a outros campos de interesse humano como Cinema e Literatura. A mesma automatização aplicada aqui pode ser replicada para a Música (e possivelmente à Filosofia), dando continuidade ao trabalho realizado pelos autores (1).

REFERÊNCIAS

- 1 VIEIRA, V. et al. A quantitative approach to evolution of music and philosophy. *Journal of Statistical Mechanics: Theory and Experiment*, v. 2012, n. 08, p. P08010, 2012. Disponível em: <<http://stacks.iop.org/1742-5468/2012/i=08/a=P08010>>.
- 2 DEMPSEY, A. *Styles, Schools And Movements: The Essential Encyclopaedic Guide To Modern Art*. Thames and Hudson, 2005. (Word of art : modern and contemporary art). ISBN 9780500283769. Disponível em: <<http://books.google.com.br/books?id=C4J5QgAACAAJ>>.
- 3 ANDERSEN, K. *The geometry of an art*. [S.l.]: Springer, 2007.
- 4 KEMP, M. et al. *The Science of Art: Optical themes in western art from Brunelleschi to Seurat*. [S.l.]: Yale University Press New Haven, CT, 1990.
- 5 EDGERTON, S. Y. *The mirror, the window, and the telescope: how Renaissance linear perspective changed our vision of the universe*. [S.l.]: Cornell University Press, 2009.
- 6 GOMBRICH, E. *The story of art*. Phaidon Press, Ltd., 1995. (STORY OF ART). ISBN 9780714832470. Disponível em: <<http://books.google.com.br/books?id=CECSU2MRH4QC>>.
- 7 SEDLMAYR, H. *Art in Crisis: the lost center*. [S.l.]: Transaction Books, 2006.
- 8 PEGUS, L. Leonardo da Vinci-anatomical drawings. *Journal of Visual Communication in Medicine*, Informa UK Ltd UK, v. 1, n. 2, p. 63–69, 1978.
- 9 HALL, M. B.; GILL, M. J. et al. Color and meaning: Practice and theory in renaissance painting. *Renaissance and Reformation/Renaissance et Réforme*, v. 16, n. 4, p. 83–85, 2009.
- 10 KLEINER, F. S. *Gardner's Art through the Ages: The Western Perspective, Volume I, 14e*. [S.l.]: Cengage Learning, 2012.
- 11 GORDON, D. E. *Expressionism: Art and Idea*. [S.l.]: Yale University Press, 1987.
- 12 WILLIAMS, J. *Gilles Deleuze's difference and repetition: A critical introduction and guide*. [S.l.]: Cambridge Univ Press, 2003.
- 13 PINTO, R. C. *Argument, inference and dialectic: Collected papers on informal logic*. [S.l.]: Springer, 2001.

- 14 VAN EEMEREN, F. H.; BLAIR, J. A.; WILLARD, C. A. *Anyone who has a view: Theoretical contributions to the study of argumentation.* [S.l.]: Springer, 2003.
- 15 COSTA, L. d. F. D.; CESAR JR., R. M. *Shape Analysis and Classification: Theory and Practice.* 1st ed. Boca Raton, FL, USA: CRC Press, Inc., 2000. ISBN 0849334934.
- 16 FISHER, R. A. The use of multiple measurements in taxonomic problems. *Annals of eugenics*, Wiley Online Library, v. 7, n. 2, p. 179–188, 1936.
- 17 HILLS, H. *Rethinking the Baroque.* [S.l.]: Ashgate Publishing, Ltd., 2011.
- 18 BAYER, A.; GREGORI, M. *Painters of Reality: The Legacy of Leonardo and Caravaggio in Lombardy.* [S.l.]: Buy this book, 2004.
- 19 TATARKIEWICZ, W. *History of Aesthetics: Edited by J. Harrell, C. Barrett and D. Petsch.* [S.l.]: Continuum International Publishing Group, 2006.
- 20 PUGLISI, C. *Caravaggio.* [S.l.]: Phaidon, 1998.
- 21 CARAVAGGIO, M. M.; WARWICK, G. *Caravaggio: realism, rebellion, reception.* [S.l.]: Univ of Delaware Pres, 2006.
- 22 GRIMM, C. *Frans Hals: The Complete Work.* [S.l.]: HN Abrams, 1990.
- 23 SCHJELDAHL, P. Haarlem shuffle: The fast world of frans hals. *The New Yorker*, 2011.
- 24 UNGLAUB, J.; POUSSIN, N. *Poussin and the poetics of painting: pictorial narrative and the legacy of tasso.* [S.l.]: Cambridge University Press, 2006.
- 25 WETERING, E. van de. The multiple functions of rembrandt's self portraits. Yale Univ. Press, 1999.
- 26 WETERING, E. Van de. *Rembrandt: the painter at work.* [S.l.]: Amsterdam University Press, 1997.
- 27 WADUM, J. Johannes vermeer (1632-1675) and his use of perspective. In: THE GETTY CONSERVATION INSTITUTE. *Historical painting techniques, materials, and studio practice: preprints of a symposium, University of Leiden, the Netherlands, 26-29 June 1995.* [S.l.], 1995. p. 148–154.
- 28 WADUM, J. Contours of vermeer. *STUDIES IN THE HISTORY OF ART*, NATL GALLERY ART 6TH ST AND CONSTITUTION AVE, WASHINGTON, DC 20565 USA, v. 55, p. 201–+, 1998.
- 29 KANDINSKY, W.; CABRAL, Á.; DANESI, A. d. P. *Do espiritual na arte e na pintura em particular.* [S.l.]: Martins Fontes, 2000.
- 30 HULSKER, J. *The complete Van Gogh: paintings, drawings, sketches.* [S.l.]: Phaidon, 1980.

- 31 LOVEJOY, A. O. et al. *Primitivism and related ideas in antiquity*. [S.l.]: Johns Hopkins University Press, 1997.
- 32 VAN GOGH, V.; VAN GOUGH, V. *The complete letters of Vincent van Gogh*. [S.l.]: Thames and Hudson London, 1958.
- 33 DUCHTING, H. *Wassily Kandinsky 1866-1944: A revolution in painting*. [S.l.]: Taschen, 2000.
- 34 IONE, A.; TYLER, C. Was kandinsky a synesthete? *Journal of the History of the Neurosciences*, Taylor & Francis, v. 12, n. 2, p. 223–226, 2003.
- 35 ELDERFIELD, J. et al. *The "wild beasts": Fauvism and its affinities*. [S.l.]: Museum of modern art, 1976.
- 36 FREEMAN, J.; BENJAMIN, R.; MATTISSE, H. *The fauve landscape*. [S.l.]: Los Angeles county museum of art, 1990.
- 37 MATISSE, H. *Matisse on art*. [S.l.]: University of California Pr, 1995.
- 38 DAIX, P.; EMMET, O. *Picasso: Life and art*. [S.l.]: Thames and Hudson, 1994.
- 39 RISHEL, J. J.; SACHS, K.; BERNSTEIN, R. *Cézanne and beyond*. [S.l.]: Yale University Press, 2009.
- 40 BARR, A. H. *Cubism and abstract art: painting, sculpture, constructions, photography, architecture, industrial art, theatre, films, posters, typography*. [S.l.]: Belknap Press of Harvard University Press, 1986.
- 41 GOLDING, J. *Cubism: a history and an analysis, 1907-1914*. [S.l.]: Faber & Faber, 1988.
- 42 MONTAGU, J. *The Surrealists: revolutionaries in art & writing 1919-35*. [S.l.]: Tate Publishing, 2002.
- 43 STICH, S. *Joan Miró, the development of a sign language*. [S.l.]: Washington University, 1980.
- 44 NAMUTH, H. *Jackson Pollock*. 1951. <https://www.youtube.com/watch?v=6cgBvpjwOGo>.
- 45 WILLIAMS, H. *Hegel, Heraclitus, and Marx's Dialectic*. St. Martin's Press, 1989. ISBN 9780745005270. Disponível em: <<http://books.google.com.br/books?id=jWzdAAAAIAAJ>>.
- 46 GONZALEZ, R. C.; WOODS, R. E. *Processamento de imagens digitais*. [S.l.]: Edgard Blucher, 2000.

- 47 ACHANTA, R. et al. SLIC Superpixels Compared to State-of-the-art Superpixel Methods. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, Institute of Electrical and Electronics Engineers, Los Alamitos, v. 34, n. 11, p. 2274 – 2282, 2012. ISSN 0162-8828. A previous version of this article was published as a EPFL Technical Report in 2010: <http://infoscience.epfl.ch/record/149300>. Supplementary material can be found at: <http://ivrg.epfl.ch/research/superpixels>. Disponível em: <<http://ivrg.epfl.ch/research/superpixels>>.
- 48 BILLMEYER, F. W.; SALTZMAN, M. *Principles of color technology*. [S.l.]: J. Wiley & sons, 1981.
- 49 HOFFMANN, G. Cielab color space. *Wikipedia, the free encyclopedia. mht*, 2007.
- 50 ROMERO, J. et al. Using complexity estimates in aesthetic image classification. *Journal of Mathematics and the Arts*, v. 6, n. 2-3, p. 125–136, 2012. Disponível em: <<http://www.tandfonline.com/doi/abs/10.1080/17513472.2012.679514>>.
- 51 MANOVICH, L. *Style Space: How to compare image sets and follow their evolution (draft text)*. ago. 2011. <http://lab.softwarestudies.com/2011/08/style-space-how-to-compare-image-sets.html>.
- 52 MANOVICH, L. *Mondrian vs Rothko: footprints and evolution in style space*. jun. 2011. <http://lab.softwarestudies.com/2011/06/mondrian-vs-rothko-footprints-and.html>.
- 53 MANOVICH, L. *ArtHistory.viz | visualizing modernism*. nov. 2008. <http://lab.softwarestudies.com/2008/07/arthistoryviz-mining-200000-images-of.html>.
- 54 HARALICK, R. M.; DINSTEIN, I.; SHANMUGAM, K. Textural features for image classification. *Ieee Transactions On Systems Man And Cybernetics*, IEEE, v. 3, n. 6, p. 610–621, 1973. Disponível em: <<http://ieeexplore.ieee.org/lpdocs/epic03/wrapper.htm?arnumber=4309314>>.
- 55 PAPOULIS, A. *The Fourier integral and its applications*. Mc Graw-Hill, 1962.
- 56 GOUVEIA, L. T. de; RODRIGUES, F. A.; FONTOURA COSTA, L. da. Multiscale curvature analysis of asphaltic aggregate particles. *Journal of Computing in Civil Engineering*, American Society of Civil Engineers, v. 24, n. 6, p. 506–513, 2010.
- 57 JAIN, A.; ZONGKER, D. Feature selection: Evaluation, application, and small sample performance. *Pattern Analysis and Machine Intelligence, IEEE Transactions on*, IEEE, v. 19, n. 2, p. 153–158, 1997.
- 58 DUNTEMAN, G. H. *Principal components analysis*. [S.l.]: Sage, 1989.
- 59 LAMBERT, G.; NÉRET, G. *Caravaggio*. Ediz. tedesca.. Taschen Deutschland GmbH, 2000. (Basic Art Series). ISBN 9783822808184. Disponível em: <<http://books.google.com.br/books?id=eMWrHAAACAAJ>>.

APÊNDICE A – Tutorial para execução dos scripts Python desenvolvidos para análise

Toda a análise realizada neste estudo foi implementada em linguagem *Python*, em sistema *GNU/Linux Ubuntu*, utilizando ferramentas de *software livre*. O código-fonte, assim como todo o conteúdo usado e gerado, encontra-se distribuído nos seguintes repositórios abertos:

- <http://github.com/automata/dissertacao-ifsc>: contém o código-fonte *LAT_EX* desta dissertação e pode ser compilado através do comando *make*, gerando um arquivo *dissertacao.pdf* como saída.
- <http://github.com/automata/viz-paintings>: aplicativo Web desenvolvido em *JavaScript* para visualização interativa da Figura 3.14, onde o espaço de atributos pode ser “navegado” com *panning* e *zoom*, facilitando a identificação de cada pintura analisada e seu respectivo *cluster*. Essa mesma aplicação pode ser acessada *on-line* através do endereço <http://automata.github.io/viz-paintings>. Mais detalhes e capturas de tela do aplicativo no Apêndice C.
- <http://github.com/automata/tri-delaunay>: código-fonte em *Python* para geração de pinturas generativas baseadas em figuras usadas neste estudo e triangulação de Delaunay. Estas pinturas foram exibidas em uma exposição em 2013 (Apêndice D).

- [http://github.com/automata/ana-pintores](https://github.com/automata/ana-pintores): *scripts Python* usados para obter os resultados discutidos nesse estudo, assim como a base de figuras das 240 pinturas utilizadas. A seguir, instruções para instalação e uso de tais *scripts*.

1. Certifique-se de ter instalado as dependências:

```
sudo apt-get install python python-numpy python-matplotlib
                           python-setuptools git
sudo easy_install scikit-learn
git clone https://github.com/scikit-image/scikit-image.git
cd scikit-image
sudo python setup.py install
```

2. Clone o repositório Git da dissertação e *scripts* (o repositório inclui os arquivos de imagens das pinturas, portanto o tempo de *download* pode ser longo):

```
git clone https://github.com/automata/ana-pintores.git
cd ana-pintores/
```

3. Para analisar as pinturas por processamento de imagens, execute:

```
python analyse_pinturas.py
python analyse_segs.py
```

4. Para gerar a matriz de atributos extraídos a partir da análise anterior:

```
python feature_matrix_gen.py
```

5. Para calcular as medidas de inovação, oposição e dialética, assim como plotar a série temporal considerando os dois melhores atributos e LDA, assim como uma versão alternativa que substitui os marcadores por miniaturas das pinturas:

```
python metrics_caso1.py  
python metrics_caso3b.py  
python metrics_caso1_alternativo.py
```

6. Para validar os resultados através do LDA:

```
python valida3_r.py
```

7. Para calcular as matrizes esparsas e o índice α de separação, listando e plotando os pares de atributos que apresentaram melhor separação:

```
python scatter_matrix_pintores.py
```

8. Para plotar o comparativo dos histogramas de níveis de cinza médio das pinturas:

```
python chiaroscuro.py  
python chiaroscuro_modernos.py
```

Cada script produz arquivos de imagens e resultados de saída diversos. Seus respectivos códigos devem ser consultados para se compreender quais as saídas geradas.

***APÊNDICE B – Galeria de imagens das 240
pinturas analisadas***




Figura B.1 – Caravaggio




Figura B.2 – Frans Hals




Figura B.3 – Nicolas Poussin



Figura B.4 – Diego Velázquez




Figura B.5 – Rembrandt Harmenszoon van Rijn




Figura B.6 – Johannes Vermeer




Figura B.7 – Vincent van Gogh




Figura B.8 – Wassilly Kandinsky




Figura B.9 – Henri Matisse




Figura B.10 – Pablo Picasso



Figura B.11 – Joan Miró



Figura B.12 – Jackson Pollock

APÊNDICE C – Visualizações complementares

Ao se representar as projeções das Figuras 3.14 e 3.15 usando miniaturas das pinturas ao invés de simples marcadores, tem-se uma visualização interessante onde detalhes de variações de contraste e cor podem ser observados (Figura C.1, com detalhes destacados nas Figuras C.2 e C.3).

Como a visualização fica comprometida em mídia impressa, optou-se pela implementação de um aplicativo Web que permite interagir com a projeção encontrada para as pinturas. O aplicativo está disponível em <http://automata.github.io/viz-paintings> e pode ser visitado por navegadores que suportem *WebGL*¹. Há ainda um vídeo disponível em ... que apresenta a gravação comentada do uso do aplicativo.

¹ Os navegadores Firefox 28.0 e Chrome 35, com suporte para WebGL devidamente configurado e habilitado, suportam tal aplicação




Figura C.1 – Visualização alternativa das projeções das Figuras 3.14 e 3.15. É possível perceber detalhes de contraste e cor e sua influência no agrupamento e separação dos grupos de pintores.



Figura C.2 – Detalhe da Figura C.1 do grupo onde há maior concentração de pintores. Nota-se que alguns pintores, como van Gogh, apresentam uma classificação com nenhuma sobreposição, enquanto outros, principalmente aqueles do grupo Barroco, apresentam grande sobreposição.




Figura C.3 – Detalhe da Figura C.1 do grupo de pinturas pertencentes exclusivamente à Jack Pollock.
Por este pintor ter características que foge aos demais artistas, suas pinturas apresentam-se distribuídas afastadas consideravelmente dos outros pintores.

APÊNDICE D – Pinturas generativas por tesselação de Delaunay. Estudo 4

Tendo como base o processamento de imagens (pré-processamento e segmentação) realizado para as 240 pinturas usadas nesse estudo, foram geradas 240 novas “pinturas”. Todas as 240 pinturas generativas estão disponíveis em http://www.flickr.com/photos/auto_mata/sets/72157634660390040/.

Nos dias 30 de Setembro à 4 de Outubro de 2013, um conjunto de quadros foi aceito e exposto no espaço “Obra Artística” da 3^a Semana Integrada do Instituto de Física de São Carlos (SIFISC 3). Seguem os detalhes da obra:

Título Pinturas generativas por tesselação de Delaunay. Estudo 4

Tipo de obra Quadro

Altura 120cm

Profundidade 5cm

Largura 240cm

Descrição Imagens de pinturas originais dos movimentos Barroco e Moderno foram segmentadas. Coordenadas de pontos pertencentes a esses segmentos foram dadas como entrada

para o algoritmo de tesselação de Delaunay. O algoritmo cria uma malha a partir da triangulação das coordenadas dadas, sem cruzamentos de arestas. A cor de cada triângulo da malha equivale à cor média do segmento da pintura original.

Todo o código-fonte assim como as “pinturas” geradas, e suas versões para impressão, encontram-se em <http://github.com/automata/tri-delaunay>. A Figura D.3 mostra fotos da exposição. O objetivo foi desmistificar o processo de geração das imagens, mostrando junto com a imagem final, cada passo do algoritmo, ilustrado com imagens explicativas — como visto nas Figuras D.1 e D.2. Ainda, as instruções para o visitante acessar e executar o código-fonte para gerar suas próximas versões “remixadas” com bases em novas imagens acompanhavam cada “pintura”. As pinturas expostas foram escolhidas através da consulta à preferência de pessoas em um *thread* da lista de emails do *labMacambira.sf.net*¹ e dos próprios autores deste estudo²

Há ainda uma proposta de publicação impressa destas imagens pela editora independente *Quiosque*, com editoração de Geraldo Magela de Castro Rocha Junior, curadoria de Leticia Palaria e texto de integrantes do LabMacambira.sf.net. Uma prévia do conteúdo a ser publicado pode ser visto na Figura D.4.

¹ <http://labmacambira.sf.net>

² Em <https://etherpad.mozilla.org/genpaintings> encontra-se o *pad* com as sugestões levantadas, assim como um esboço de uma matéria sobre as pinturas que pretende-se publicar na revista aberta e independente *Quiosque*.




Figura D.1 – “Pintura” generativa.




Figura D.2 – “Pintura” generativa.





Figura D.3 – Fotos da exposição realizada no SIFISC 2013 com imagens geradas por algoritmo desenvolvido em paralelo a este estudo.



Instale & Use & Remixe

LabMacambira



929518127



92979933859

Pinturas
GenerativasPinturas
Generativas

Figura D.4 – Prévia do conteúdo de publicação impressa prevista para 2014 das pinturas generativas pela editora independente Quiosque.